

TECHNICAL REPORT

Aluno: Samuel Henrique da Silva

1. Introdução

O dataset que foi utilizado no meu projeto se chama “AB_NYC_2019” e traz informações sobre hospedagens disponíveis no Airbnb na cidade de Nova York em 2019. Ele possui cerca de 49 mil registros e reúne dados sobre localização, tipo de acomodação, disponibilidade, avaliações e preço.

Entre as principais variáveis estão: o bairro (`neighbourhood_group`), o tipo de quarto (quarto inteiro, privado ou compartilhado), o preço da diária, o número mínimo de noites, a quantidade de avaliações, a disponibilidade no ano e a quantidade de imóveis que o anfitrião possui.

O objetivo da análise é entender quais fatores mais influenciam no preço das hospedagens, como o impacto da localização, do tipo de quarto e das características dos anfitriões. Também busca-se avaliar o desempenho de modelos de regressão para prever esses preços e verificar quais variáveis são mais importantes no processo. Com isso, nossa variável alvo no código foi a coluna “price”.



2. Observações

Sim, existem algumas observações em que atrapalhou no cálculos dos dados utilizando esse dataset, mas nada que atrapalhasse no funcionamento do código. Na verdade, achei o dataset bem estruturado comparado com o anterior.

1. Valores ausentes:

A variável `reviews_per_month` apresentou alguns valores nulos, provavelmente relacionados a hospedagens que nunca receberam avaliações. Isso foi tratado preenchendo os valores ausentes com zero, o que é uma abordagem coerente nesse contexto.

2. Dados inconsistentes ou extremos:

Foi possível observar alguns preços extremamente altos, indicando a presença de outliers. Esses valores podem afetar o desempenho de modelos estatísticos, principalmente os lineares.

A variável `minimum_nights` também apresentou valores muito altos (como milhares de noites), o que não faz sentido prático e pode representar erros de cadastro ou imóveis que não estão realmente disponíveis.

3. Distribuição dos dados desbalanceada:

Grande parte das hospedagens está concentrada em Manhattan e Brooklyn, enquanto outras regiões, como Staten Island, possuem bem menos anúncios. Isso gera um certo desbalanceamento na distribuição dos dados por região.

O tipo de quarto também é desbalanceado, com uma predominância de “Entire home/apt” e “Private room”, e poucas opções de “Shared room”.

3. Resultados e discussão

Agora vou falar como foi feito cada questão presente na parte B - Regressão:

1. Questão 1 – Pré-processamento e Correlação

Na primeira etapa do projeto, foi feito todo o processo de preparação dos dados, começando pelo carregamento do dataset “AB_NYC_2019” até salvar o arquivo já reajustado. Primeiro, os dados foram carregados e analisados para verificar se havia informações faltando. Foi identificado que apenas a coluna `reviews_per_month` tinha valores nulos, o que acontece quando os imóveis nunca receberam avaliações. Para resolver isso, esses valores foram preenchidos com zero, já que faz sentido considerar que não houve nenhuma avaliação.

Depois disso, foi feita uma análise de correlação para entender quais variáveis mais influenciam no preço das hospedagens. As que mais se destacaram foram `neighbourhood_group` (grupo de bairros) e `room_type` (tipo de quarto), ambas depois de transformadas em variáveis numéricas (dummies). Outras variáveis, como `number_of_reviews`, `reviews_per_month` e `availability_365`, mostraram uma correlação bem baixa com o preço.

Em seguida, os dados foram normalizados com o `StandardScaler`, que deixa todos os dados na mesma escala, com média zero e desvio padrão um. Esse passo é muito importante para que nenhuma variável com valores muito altos tenha mais peso do que as outras na hora de treinar os modelos.

Por fim, com os dados limpos e ajustados, foi criado o arquivo `regressao_ajustado.csv`, que está pronto para ser usado nas próximas etapas de análise e construção dos modelos de regressão. Assim, garantimos que os dados estejam organizados, sem valores faltando e prontos para gerar resultados mais confiáveis.


```
('regressao_ajustado.csv',  
 price                1.000000  
 neighbourhood_group_Manhattan  0.163976  
 neighbourhood_group_Midtown    0.097781  
 neighbourhood_group_Tribeca    0.084814  
 availability_365          0.081829  
 ...  
 neighbourhood_group_Bushwick  -0.065166  
 neighbourhood_group_Queens    -0.080205  
 neighbourhood_group_Brooklyn  -0.098603  
 longitude                -0.150019  
 room_type_Private room      -0.240246  
 Name: price, Length: 234, dtype: float64)
```

2. Questão 2 – Regressão Linear Simples

Na segunda etapa, foi aplicado o modelo de Regressão Linear para tentar prever o preço das hospedagens no Airbnb com base nos dados ajustados. A variável escolhida para essa análise foi o `room_type` (tipo de quarto), que foi a que apresentou maior correlação com o preço. Através dela, foi possível plotar uma reta de regressão, mostrando a relação entre o tipo de acomodação e o preço.

Após o treinamento do modelo, os resultados não foram tão satisfatórios. O R^2 ficou em aproximadamente 2,7, o que na prática indica que o modelo não explica quase nada da variação dos preços — um valor tão baixo mostra que a regressão não se ajustou bem aos dados. Além disso, o RMSE foi de aproximadamente 237, indicando que, em média, o erro nas previsões é de 237 unidades no preço, o que é considerado um erro bem alto dentro do contexto dos dados.

Esses resultados mostram que usar apenas uma variável, como o tipo de quarto, é insuficiente para criar um modelo de previsão eficiente, já que o preço depende de muitos outros fatores, como localização, disponibilidade, quantidade de noites mínimas, entre outros. De qualquer forma, essa etapa foi importante para visualizar como uma variável isolada se comporta em relação ao preço e também para perceber a necessidade de modelos mais completos, utilizando mais informações dos dados.



3. Questão 3 – Linear vs Ridge vs Lasso

Na terceira etapa, o objetivo foi comparar diferentes modelos de regressão para tentar melhorar a previsão dos preços das hospedagens. Foram aplicados três modelos: **Regressão Linear**, **Ridge** e **Lasso**. Para fazer a comparação de forma justa, foi utilizado o método de validação cruzada com **5 folds (cross-validation)**. Esse método ajuda a avaliar os modelos de forma mais confiável, já que faz várias divisões dos dados entre treino e teste.

Durante a avaliação, foram calculadas duas métricas principais: o **R^2** e o **RMSE**. O **R^2** indica o quanto o modelo consegue explicar da variação dos preços, e o **RMSE** mostra o erro médio nas previsões.

Os resultados foram os seguintes:

Modelo	R^2 Médio	RMSE Médio
Regressão Linear	0.27	237
Ridge	0.28	236
Lasso	0.26	238

Analisando a tabela, o **modelo Ridge** teve um desempenho ligeiramente melhor, com o maior **R^2 (0.28)** e o menor **RMSE (236)**. Embora a diferença entre os modelos não tenha sido tão grande, o Ridge conseguiu um pequeno ganho de performance.


No geral, percebemos que, mesmo testando diferentes tipos de regressão, os valores de R^2 ainda ficaram baixos, mostrando que os modelos continuam com dificuldade de explicar a variação dos preços com os dados disponíveis. Isso reforça que talvez seja necessário realizar um ajuste mais profundo nas variáveis usadas ou explorar outros tipos de modelos para alcançar melhores resultados.

4. Questão 4 – Coeficientes e Seleção de Atributos

Na quarta e última etapa, o foco foi analisar os coeficientes do modelo Lasso para entender quais variáveis são mais relevantes na hora de prever o preço das hospedagens. O Lasso tem uma característica bem interessante: ele consegue zerar os coeficientes de variáveis pouco importantes, funcionando como uma forma automática de seleção de atributos.

Depois de treinar o modelo, foi criado um gráfico de barras para visualizar a importância de cada variável. As variáveis com coeficientes maiores (em valor absoluto) são as que mais impactam no preço. Nesse caso, os atributos mais relevantes foram `room_type`, especialmente o tipo de quarto, e `neighbourhood_group`, que representa o grupo de bairros. Esses dois continuam se destacando, assim como já tinham aparecido nas análises anteriores. Outras variáveis, como `number_of_reviews`, `availability_365` e `reviews_per_month`, tiveram coeficientes bem baixos ou até zerados, mostrando que têm pouca influência direta sobre o preço no modelo.

Essa análise reforça a percepção de que fatores como localização e tipo de acomodação são os que realmente fazem diferença no valor cobrado. Já outras variáveis, mesmo estando no dataset, não são tão relevantes para prever o preço e acabam não contribuindo muito para o modelo.





4. Conclusões

Em questão dos resultados, comparando com o outro dataset utilizado na parte A, mesmo esse sendo um pouco mais bem formulado, digo que os resultados esperados não foram totalmente satisfeitos. Apesar de os modelos conseguirem captar uma parte da variação do preço, os valores de R^2 ficaram baixos (em torno de 0.27 a 0.28) e o RMSE ficou relativamente alto (por volta de 236 a 238), indicando que os modelos têm uma capacidade limitada de fazer previsões precisas.

O principal motivo disso é que o preço de uma hospedagem no Airbnb depende de vários fatores complexos que não estão totalmente representados no dataset ou não foram incluídos no modelo, como: avaliações qualitativas dos hóspedes, sazonalidade, eventos na cidade, demanda em determinadas épocas, entre outros. Além disso, o preço pode ter variações que não seguem relações lineares, o que torna os modelos lineares (Regressão Linear, Ridge e Lasso) pouco eficientes para capturar essa complexidade.

Minha análise é que, embora os modelos consigam apontar tendências gerais — como a importância do tipo de quarto e do bairro —, eles não são suficientes para prever os preços com alta precisão. Para melhorar, seria interessante testar modelos mais robustos, como árvores de decisão, random forest ou até modelos baseados em aprendizado de máquina mais avançados, além de incluir mais variáveis que reflitam melhor o contexto dos preços.

5. Próximos passos

Em questão, esse dataset não vi muito proveito utilizá-lo futuramente, pois existe diversas divergências nele, mas posso futuramente utilizá-lo para por exemplo analisar seus outliers, assim removem-dos para um tratamento de dados mais adequado ou até mesmo utilizar outros datasets como complementos desse. Ademais, também seria mais adequado usar outras métricas para visualização dos dados como o MAE (Erro absoluto médio).