

PROJETO DE CLASSIFICAÇÃO COM KNN

Dayane Magalhães

Suiany Pinto

Disciplina: Inteligência Artificial

Professor: Alysson Bezerra



Introdução


- Utilização do dataset Dry Bean Dataset
- Disponível no UCI Machine Learning Repository
- Problema de classificação supervisionada
- Objetivo: identificar automaticamente tipos de feijão

13.611 amostras

16 variáveis numéricas

1 variável-resposta

7 classes de feijão



Objetivos do Projeto


Objetivo Geral

Desenvolver um modelo de classificação utilizando o algoritmo KNN (K-Nearest Neighbors) para identificar variedades de feijão.

Objetivos Específicos

- Explorar o dataset
- Tratar inconsistências
- Aplicar normalização
- Treinar o algoritmo KNN
- Avaliar o impacto do parâmetro K
- Aplicar Validação Cruzada
- Aplicar Grid Search (Técnica de otimização)


Metodologia do Projeto



Análise dos Atributos

Atributos com maior associação à classe:

- Perimeter
- EquivDiameter
- ConvexArea
- Area
- MinorAxisLength



Exploração e Pré-Processamento

Observações

- Sem valores ausentes;
- Dataset consistente;
- Necessidade de codificação da variável-alvo;

Etapas realizada

1. LabelEncoder;
 - Conversão da variável Class para números
2. Separação treino e teste;
 - 80% treino (10.888 amostras)
 - 20% teste (2.723 observações)
3. Normalização;
 - StandardScaler (Z-score)
 - MinMaxScaler
 - Log + StandardScaler

Implementação do KNN

Configuração Inicial

Técnica de Padronização Z-score


Configuração inicial:

$K = 5$

Resultado Inicial:

Acurácia 91,66%

Influência do melhor K



Validação Cruzada e Grid Search

Validação Cruzada

<u>Fold</u>	Acurácia
1	91,19%
2	92,91%
3	92,40%
4	92,95%
5	92,36%

Média : **92,36%**

Desvio padrão : **0,64%**

Grid Search

Melhores parâmetros:

n_neighbors = **13**

metric = **euclidean**

weights = **distance**

Melhor Acurácia: **92,62%**


Comparação das Normalizações

Avaliação


Modelo otimizado obtido pelo Grid Search, empregando validação cruzada estratificada de 5 folds.

Melhor abordagem:

Log + StandardScaler



Resultado Final



Classe	<u>Precision</u>	Recall	F1-score	<u>Suport</u>
BARBUNYA	0,97	0,88	0,92	265
BOMBAY	1,00	1,00	1,00	104
CALI	0,93	0,95	0,94	326
DERMASON	0,91	0,90	0,91	709
HOROZ	0,96	0,95	0,95	386
SEKER	0,94	0,95	0,94	406
SIRA	0,84	0,87	0,86	527
ACCURACY			0,92	2723
MACRO AVERAGE	0.93	0,93	0,93	2723
WEIGHTED AVERAGE	0,92	0,92	0,92	2723

Conclusão

- 
- O algoritmo KNN apresentou excelente desempenho;
 - $K = 13$ foi a melhor configuração;
 - A normalização influenciou positivamente os resultados;
 - Melhor desempenho: 92,62% de acurácia

PROJETO DE REGRESSÃO LINEAR, RIDGE E LASSO



Introdução

- Utilização Dataset Energy Efficiency
- Disponível no UCI Machine Learning Repository
- Problema de regressão preditiva em eficiência energética.
- Objetivo: prever a carga de aquecimento de edifícios.

768 amostras


10 variáveis

sendo: 8 variáveis independentes

2 variáveis-alvo



Metodologia do Projeto



Dados e Análise

Variáveis

Entradas (X):

- X1 (comp_relativa)
- X2 (area_superf)
- X3 (area_parede)
- X4 (area_telhado)
- X5 (altura_total)
- X6 (orientacao)
- X7 (area_vidro)
- X8 (dist_vidro)

Saída(Y):


- Y1 (carga_aqueci)
- Y2 (carga_resfria)

Observações

1. Variáveis (contínuas e inteiras)
2. Sem valores nulos;
3. Sem valores duplicados;
4. Variável-alvo utilizada:
carga_aqueci

Análise dos Atributos

- Forte relação linear;
- altura_total teve alta correlação;
- orientação teve menor influência.



Resultado dos Modelos

Pré-Processamento

1. Regreção Linear Tradicional
 - Sem alteração
2. Padronização StandardScaler;
 - Ridge
 - Lasso
3. Separação treino e teste;
 - 80% treino
 - 20% teste

Resultados

Modelo	RMSE	R ²
Regressão Linear	3,025	0,912
<u>Ridge</u>	3,026	0,912
Lasso	3,153	0,905

Melhor modelo:


Regressão Linear com 91,2% de variabilidade dos dados.

Real vs Previsto

Previsões

Primeiras previsões do modelo:

	Real	Previsto
0	16.47	18.862960
1	13.17	14.049380
2	32.82	31.315603
3	41.32	35.900510
4	16.69	15.335197




Importância das Variáveis

Variáveis mais relevantes:

- altura_total
- area_vidro

Menor influência:

- orientacao
- dist_vidro



Regressão Linear Simples

Resumo


Melhor atributo encontrado:

altura_total

RSME: 4.656

R^2 : 0.792

Apenas uma variável explicou
79,2% dos dados.



Validação Cruzada e Grid Search

Validação Cruzada

Modelo	R^2 médio
Regressão Linear	0,890
<u>Ridge</u>	0,890
Lasso	0,885

Dataset dividido em 5 (folds)

Testa 1 [■][■][■][■][□]

Treina 4

Grid Search

Modelo	Melhor alpha
<u>Ridge</u>	0,0001
Lasso	0,0001

Valores do alpha variando entre -4 a 2
com multiplicação em escala
logarítmica.

Conclusão

- 
- Objetivos alcançados
 - Regressão Linear foi o melhor modelo
 - R^2 superior a 90%
 - Dataset apresentou forte linearidade
 - Baixo overfitting

OBRIGADO!