

**TECHNICAL REPORT**

Aluno: Madson Luan Dias Nascimento

1. Introdução

O conjunto de dados utilizado para essa análise é o Breast Cancer Wisconsin Diagnostic Dataset, onde é muito utilizado em pesquisas e estudos sobre a detecção de câncer. Ele contém informações clínicas extraídas de imagens digitalizadas. Cada amostra desse arquivo corresponde a um paciente e descreve suas características físicas. Esses dados possuem 569 amostras, onde cada uma delas representa a análise de pacientes. Cada um dos registros é composto por um identificador numérico, seguindo de uma variável categórica para distinguir o tipo de câncer, M para o tipo maligno e B para do tipo benigno.

Esse dataset é interessante para análises estatísticas e para contribuir com o desenvolvimento e avaliação de modelos de aprendizado máquina, pois ele apresenta duas classes já definidas com um valores equilibrados de exemplos e com variáveis numéricas que possuem uma boa correlação entre si.

Em resumo, esse dataset representa um conjunto de dados clássico, que combina informações relevantes para a área da saúde, sendo ideal para estudos clínicos e análise exploratória, pré-processamento de dados, redução de dimensionalidade como utilizado nessa pesquisa, clusterização e classificação.


2. Observações

Algum problema que aconteceu? Alguma observação? Algum imprevisto? Se não houve problemas, deixe em branco.

3. Resultados e discussão

Questão 1 - Análise Exploratória com Foco em Redução de Complexidade.

PROBLEMA 1. FLUXOGRAMA



Na imagem abaixo, é possível visualizar a distribuição das classes de tumores que compõem a base de dados do dataset.




Figura 1 - Distribuição das classes de tipos de câncer.

Observa-se, a partir desse gráfico, que os tumores cancerígenos do tipo benigno representam uma quantidade significativamente superior do que os do tipo maligno. Esse desbalanceamento entre as categorias é bem evidenciado e pode resultar em impactos em análises futuras. Logo, ressalta-se a importância de avaliar esse fator durante o pré-processamento, para reduzir esses vieses e garantir uma avaliação justa.

1.2 Identificação de Outliers





Figura 2 - distribuição do raio médio Figura 3 - Distribuição da área média

Após a análise da distribuição das variáveis, foram identificados valores questionáveis em algumas delas, como nas métricas relacionadas ao tamanho do próprio tumor, como o raio médio e área média. Esses valores aparecem como observações extremas nas caudas das distribuições, sugerindo a presença de casos com tumores significativamente maiores que a maioria dos demais.

1.3 Avaliação do Raio Médio.

Seu limite inferior normal obteve 5,58, e seu limite superior é de 21,90. Visando também a identificação de 14 valores outliers acima do limite superior, variando de 22,01 e 28,11. Esses valores indicam que em algumas amostras possuem um raio médio significativamente maior do que a maioria dos dados, onde como já mencionado pode representar casos de tumores com maior dimensão.

1.4 Avaliação da Área Média


Limite inferior calculado negativamente -123,30, o que não é possível devique que a área não pode se pressupor de valores negativos. Assim, considera-se esse limite como 0 e seu limite superior atinge 1326,30. E foram encontrados 25 valores outliers acima do limite superior, os quais atingem 2501, indicando amostras com médias bem elevadas que o padrão.

A detecção desses outliers é extremamente fundamental para garantir a qualidade da análise e dos modelos.

1.5 Matriz de correlação

Para obter uma maior compreensão da relação entre as variáveis desse conjunto de dados, foi elaborada a matriz de correlação. Seu objetivo é que nos seja possível identificar a intensidade das relações lineares positivas ou negativas entre pares de variáveis, sendo os valores próximos de 1 indicativos de uma forte correlação positiva, próximos de -1 uma correlação forte negativo e próximo de 0 a ausência de correlação.

Figura 4 - Matriz de correlação das variáveis



A matriz de correlação acima retrata padrões entre algumas variáveis.

Por exemplo, nota-se correlações fortes e positivas entre variáveis relacionadas ao tamanho e forma dos tumores, como seu raio médio e área média, indicando que tumores com um raio maior tendem a apresentar uma área maior, o que é coerente do ponto de vista analítico.

Algumas variáveis apresentaram correlações moderadas e baixas, o que sugere que apenas medem aspectos variados dessa amostra, o qual pode contribuir para um diagnóstico mais assertivo.

1.6 Proposta de Normalização como Pré-Processamento para PCA


Para manter uma aplicação adequada do PCA, foi realizada a normalização dos dados como a etapa de pré-processamento. Essa normalização foi feita utilizando o método StandardScaler, o qual sua função é padronizar cada variável para que apresente média igual a zero e desvio padrão igual a um.

Essa normalização é intuitivamente essencial, pois no conjunto de dados que foi analisado, algumas variáveis, como a área média, por exemplo, apresentaram valores muito maiores do que os outros, uma vez que o PCA é sensível a diferenças de escala entre as variáveis.

Ou seja, aplicando essa padronização, todas as variáveis passam a ter a mesma grandeza, garantido que cada uma contribua de maneira proporcional. Logo, o PCA conseguiria identificar os padrões de forma mais justa.

Questão 2 - Redução de Dimensionalidade Múltipla: PCA vs T-SNE

2.1 - Fluxograma da análise





2.2 Aplicação do PCA

Com a aplicação do PCA utilizando apenas 2 componentes principais no dataset normalizado, foi observado que esses componentes conseguiram explicar 63,24% da variância total dos dados.

Porém, mesmo com essa explicação da variância, é sugerido também que cerca de 36,76% da variância ainda está presente em métricas que não foram consideradas.

2.3 Aplicação do T-SNE

O T-SNE foi aplicado para reduzir a dimensionalidade do dataset normalizado para 2 componentes, com parâmetros configurados com perplexidade 30, e 1000 iterações. O resultado obtido confirma que essa redução gerou um novo conjunto de dados com 569 amostras em 2 dimensões, ideal para a visualização de dados complexos.

Uma vez que, o PCA, busca formas de preservar a variância global dos dados, o T-SNE foca intuitivamente na preservação das relações entre os pontos, onde resulta em agrupamentos mais definidos e uma melhor separação visual. No entanto, o T-SNE emite um custo computacional mais elevado e pode demandar ajustes nos parâmetros para obter resultados mais otimizados.




Figura 5 - Ilustração do PCA e T-SNE

Os gráficos gerados do PCA e TSNE apresentam visualizações distintas dos dados em duas dimensões, evidenciando diferenças significativas entre os dois métodos.

Olhamos para o gráfico do PCA, note que os pontos estão distribuídos de forma dispersa, refletindo uma redução linear que busca capturar uma maior variância possível nesses dados. Mesmo que seja possível identificar a separação entre as classes de tumor, existe uma sobreposição considerável entre os grupos, mostrando que o PCA, ao focar na variância global, não pode separar totalmente as classes quando existem relações mais complexas entre as variáveis.

Já no gráfico do T-SNE, a separação das classes é mais evidente, com agrupamentos mais definidos. Essa mudança ocorre porque o T-SNE é um método não linear que preserva as relações locais e visa aproximar pontos semelhantes no espaço a qual é reduzido, facilitando o agrupamento.

Resumindo, enquanto o PCA oferece uma visão mais geral e interpretativa da variação dos dados, o T-SNE entrega uma visualização mais clara dos agrupamentos, completando essa análise exploratória e facilitando a interpretação dessas relações internas do conjunto de dados.



O PCA por sua vez torna-se vantajoso, devido ao que emite uma redução linear e interpretável, transformando as variáveis originais em vários componentes que são combinações lineares, facilitando a interpretação estatística dos dados. Mantendo também uma preservação da variância, como já mencionado anteriormente esse método explicou 63%, ou seja, captura uma boa parte das informações relevantes do dataset.

Por outro lado, o PCA mantém suas desvantagens de implementação, ele não é capaz de capturar relações não lineares, onde ele pode perder informações importantes quando os padrões entre as classes são bem mais complexos e não lineares, a qual limita a separação entre as classes, as quais foram ilustradas anteriormente.

Por sua vez, o T-SNE tem suas vantagens devido a sua capacidade de capturar relações não lineares, ou seja, ele consegue mostrar estruturas e agrupamentos mais elaborados. Facilitando também a distinção visual entre as classes de tumores, evidenciando agrupamentos que podem se esconder em espaços de altas dimensões. E também é útil para detectar anomalias dentro das classes, o que é importante para na elaboração de diagnósticos.


Suas desvantagens fazem parte do que necessita de um alto custo computacional, ou seja, sua implementação é mais lenta, exige mais recursos, principalmente para com dataset com grande volume de dados.

Para a análise desse dataset, o PCA tornou-se útil para um resumo rápido e interpretação da variância dos dados, enquanto o T-SNE ofereceu uma visualização mais rica e bonita para identificar agrupamentos e diferenças locais entre os tipos de tumor.

Questão 3 - Clusterização com K-Means e Hierárquico

3.1 Fluxograma de desenvolvimento

PROBLEMA 3. FLUXOGRAMA



O objetivo da Inertia é medir a soma das distâncias quadráticas dentro dos clusters. Quanto menor a inertia, melhor os pontos estão agrupados. Porém ela sempre tende a diminuir conforme aumentamos a quantidade de clusters, logo, procuramos o cotovelo no gráfico para escolhermos um bom valor de K.

Já o Silhouette Score tende a medir o quão bem cada ponto está dentro do seu cluster, variando sempre de -1 a 1. Quanto mais próximo de 1, melhor a separação dos clusters. Nesse caso, buscamos o valor de k que maximize o Silhouette Score.




Figura 6 - Gráfico da Inertia e Silhouette Score

3.2 Avaliação da Inertia

Como já mencionado, a inertia diminui conforme o número de clusters aumenta. Essa queda é mais acentuada até $k = 3$ e/ou $k = 4$. Após $k = 4$, a redução da inertia se torna mais lenta.

Ou seja, esse certo padrão sugere um cotovelo próximo a 3 ou 4, indicando que, além desse ponto, adicionar mais clusters não traz uma melhoria significativa na composição desses grupos.

3.3 Avaliação do Silhouette Score

No gráfico do Silhouette Score por número de clusters, vemos que o score é no máximo para $k = 2$, com um valor de 0.34. Para $k = 3$ e/ou $k = 4$, o score ainda é relativamente bom, mas decresce. A partir do $k = 5$, o score cai para aproximadamente 0.15 e não melhora.

Logo, o maior valor do Silhouette Score ocorre em $k = 2$, indicando que, para a métrica de coesão e separação, 2 clusters são mais bem definidos.

Em resumo, o método do cotovelo sugere que $k = 3$ e/ou $k = 4$ pode ser um bom valor de k . E para o Silhouette Score sugere que $k = 2$ é a melhor escolha, pois a coesão entre pontos dentro dos clusters e a separação são maiores.

Os resultados indicam que os dados possuem uma estrutura mais bem representada por 2 ou 3 grupos. O K-Means consegue captar essa estrutura, mas aumentar o número de clusters não traz benefícios e pode prejudicar a qualidade dos grupos formados.

3.4 Análise dos Dendrogramas Hierárquicos

Inicialmente na clusterização hierárquica, os métodos de ligação determinam como calcular a distância entre dois clusters quando eles são unidos no processo de formação hierárquica. Os mais comuns são:


- Average (Ligação média)

Esse método calcula a média das distâncias entre todos os pontos de um cluster com todos os pontos de outro cluster.

- Complete (Ligação completa)

Esse método considera a maior distância entre qualquer par de pontos pertencentes aos dois clusters. Ou seja, essa ligação só ocorre se todos os pontos estiverem próximos.


Figura 7 - Dendrograma Average



3.5 Análise do Dendrograma (Average)

O dendrograma que foi gerado com o método average mostra que os clusters se unem a distâncias menores, o que reflete a média das distâncias entre os pontos. Essa abordagem resulta em grupos mais homogeneizados em tamanho e bem mais flexíveis quanto ao formato. A fusão dos dois grandes grupos ocorre em torno de uma distância de aproximadamente 18.

Figura 8 - Dendrograma Complete




3.6 Análise do Dendrograma Complete

O dendrograma gerado com o método complete apresenta uma fusão final a uma distância um pouco superior a 25, demonstrando que os grupos são formados apenas quando todos os pontos estão relativamente próximos. Isso leva a uma separação mais elaborada e rígida entre os clusters e a grupos potencialmente mais desiguais em relação a tamanho.

3.7 Visualização com projeção do PCA e T-SNE por método.

Os três gráficos apresentados demonstram os resultados dos diferentes métodos de clusterização aplicados nos dados, projetados intuitivamente em duas dimensões usando o PCA para fácil visualização.

Figura 9 - Projeção do PCA e T-SNE por método



3.8 Análise da projeção K-means

O gráfico mostra que o algoritmo K-Means conseguiu identificar bem as duas regiões distintas no espaço dos dados, é notório a separação clara entre os dois clusters, com os pontos relativamente bem agrupados e pouca sobreposição entre essas regiões. Isso indica que os dados possuem uma estrutura que é bem capturada pelo critério de minimização de variância do K-Means.

3.9 Análise da projeção Hierárquico - Average

Nesse gráfico, o método não conseguiu fazer a separação adequadamente dos grupos. A maior parte dos pontos foi classificada em um único cluster, com apenas poucos pontos isolados em um segundo grupo. Isso sugere que esse método pode ter sido sensível à forma e a densidade dos dados, a qual resultou em uma divisão pouco representativa.


3.10 Análise da projeção Hierárquico - Complete

Já no Hierárquico - Complete, o comportamento foi bem semelhante ao Average, pois a maioria dos pontos pertenceu a um único cluster, enquanto poucos pontos extremos aparecem em um outro grupo. Como no caso anterior, a separação dos grupos não foi tão satisfatória quanto no gráfico do K-means, indicando que esse método hierárquico, nesse contexto, também não capturou bem a estrutura desses dados.

Questão 4 - Interpretação Semântica dos Agrupamentos

Nessa etapa, foi realizada a aplicação do algoritmo de clusterização K-means para esse conjunto de dados para identificar possíveis agrupamentos entre as amostras. O método foi configurado para encontrar 2 clusters, considerando que o conjunto de dados trata de tumores que são classificados como benignos e malignos.

PROBLEMA 4. FLUXOGRAMA



4.1 Discussão dos resultados obtidos

Para a interpretação dos agrupamentos obtidos pelo o K-means, foram selecionadas as seguintes variáveis: raio médio, textura média, perímetro médio e área média. Essas variáveis foram escolhidas devido a sua alta relevância em contextos médicos e por apresentarem uma clara discrepância entre os clusters identificados, permitindo assim uma análise mais objetiva dos grupos.

Tabela 1 - Avaliação de médias de variáveis por cluster.

Cluster	ID	Raio Médio	Textura Média	Perímetro Médio	Área média
0	2.6013	12.4266	18.2624	79.8220	486.7722
1	3.8797	17.4114	21.2752	115.4528	979.8572

A análise dessas médias por cada cluster mostrou que o radio médio apresentou diferenças notáveis entre os grupos, com valores consideravelmente menores no cluster 0, e maiores no cluster 1. Assim, o raio médio está relacionado diretamente ao tamanho dos tumores, núcleos maiores tendem a ser associados a tumores malignos devido ao seu crescimento anormal. Logo, o cluster 1, com maior raio médio, apresenta um perfil mais sugestivo em relação a tumores malignos, enquanto o cluster 0, possui mais compatibilidade com tumores benignos.



A variável textura média, a qual mede a variação na intensidade do tumor, também apresentou diferenças entre os clusters. Valores mais elevados de textura no cluster 1 o define com irregularidade de tumores malignos. Entretanto, o cluster 0 apresenta uma textura média mais baixa, refletindo comportamento uniforme, características de um tumor benigno.

Já o perímetro médio, que representa os contornos das células, seguiu a mesma tendência que as variáveis anteriores, com valores elevados no cluster 1. Isso ocorre porque núcleos maiores, têm perímetros mais extensos. Já núcleos pequenos que foram encontrados no cluster 0 resultam em perímetros médios menores.


Por fim, a área média, que mede a extensão que foi ocupada pelo núcleo, apresentou resultados mais incríveis entre os clusters. O cluster 1 mostrou valores médio de área significativamente superiores aos do cluster 0, confirmando a hipótese de que esse grupo está mais associado à amostra de tumores malignos, enquanto o cluster 0 apresenta áreas mais compatíveis com núcleos benignos.

Em resumo, apenas essas quatro variáveis fornecem uma análise clara da diferença entre os clusters: o cluster 0 concentra amostras com núcleos menores, mais uniformes e regulares, que são características de tumores benignos. E no cluster 1 agrupa amostras com núcleos mais elevados, irregulares, que são associados a tumores malignos.

4.2 - Avaliação com Boxplot

A seguir, apresenta-se a análise dos boxplot a qual é permitido observar diferenças claras entre os dois clusters identificados pelo K-Means para as variáveis radio médio, textura média, perímetro médio e área média.

Figura 10 - Comparação das médias com Boxplot





Observa-se na variável raio médio, que o cluster 0 apresenta valores médios mais baixos, próximos de 12 e 13, enquanto o cluster 1 exibe valores médios mais altos, variando de 18 a 19. Essa diferença sugere que os núcleos celulares agrupados no cluster 1 são maiores, refletindo um crescimento desordenado, típico de tumores malignos, enquanto o cluster 0 permanece menor, padrão de benignos.

A variável textura média apresenta um breve comportamento semelhante. O cluster 0 concentra valores medianos em torno de 18, com baixa dispersão, enquanto o cluster 1 apresenta valores bem mais elevados, próximo de 22. A textura mede a heterogeneidade interna do núcleo, e valores mais altos, como encontrados no cluster 1, indicando uma maior irregularidade, característica de tumores malignos.

O gráfico do perímetro médio reforça esse padrão, com o cluster 0 exibindo valores mais baixos, ao redor de 80, e o cluster 1 apresentando valores medianos superiores, próximos de 120. Isso se deve ao fato de núcleos maiores e mais irregulares terem contornos mais longos, como é comum em células malignas, ao passo que núcleos pequenos e regulares, típicos de tumores benignos, possuem perímetros mais curtos.

Por fim, a variável área média apresenta diferenças mais marcantes entre os grupos. O cluster 0 mostra áreas mais baixas, com mediana em torno de 500, enquanto o cluster 1 alcança valores medianos em torno de 1000. A maior dispersão no cluster 1 também é notório, indicando que a heterogeneidade é típica das amostras malignas.


4. - Avaliação com centróides

Para complementar a interpretação dos clusters que foram identificados pelo K-Means, foi realizada a análise de centróides. Eles representam a média padronizada das variáveis para cada grupo identificado, a qual nos permite compreender melhor as características de cada média dos cluster.

Foram analisadas as seguintes variáveis principais: raio médio, textura média, perímetro médio e área média, por serem relevantes no contexto clínico.

Os valores obtidos serão apresentados no gráfico abaixo.

Figura 11 - Análise com Centróides



O gráfico demonstra a diferença de perfil entre os dois clusters. O cluster 0 apresenta valores médios negativos em todas as variáveis analisadas, indicando que essas amostras tendem a ter tumores com núcleos menores, características de tumores benignos.

Por outro lado, o cluster 1 apresenta valores médios positivos, bem maiores em todas as variáveis, compatíveis com tumores com maior dimensão, mais irregulares, típicos de tumores malignos.

Essa análise reforça a interpretação dos agrupamentos que foram realizados anteriormente. O K-Means conseguiu separar bem as amostras benignas e malignas, capturando bem as diferenças relevantes entre elas.

4.3 Avaliação das classes com CrossTab

Para avaliar o desempenho do método de clusterização K-Means em relação aos diagnósticos, foi elaborada uma matriz de contingência entre os rótulos das amostras (benignos e malignos) e os agrupamentos identificados. Essa tabela permite verificar o grau de alinhamento entre os clusters gerados e as classes de diagnóstico conhecidas. Dessa forma, é possível interpretar semanticamente os clusters e confirmar se eles capturam de fato os padrões dos dados.


Tabela 2 - Avaliação com Crosstab

Cluster	0	1
B	339	18
M	36	176

Observa-se que o cluster 0 concentra-se mais em amostras benignas, com 339 casos classificados corretamente e apenas 36 malignos alocados a esse cluster. Por outro lado, o cluster 1 agrupa as amostras malignas, com 176 casos diagnosticados corretamente e apenas 18 benignos atribuídos incorretamente. Essa métrica mostra que o algoritmo conseguiu separar razoavelmente os dois grupos.

O desempenho do K-Means em sua missão de agrupamento sugere que as variáveis utilizadas apresentam informações suficientes para diferenciar as amostras benignas e malignas. Embora existam casos de sobreposição entre os grupos, o método conseguiu capturar padrões, com a maioria das amostras corretamente agrupadas.

Esses resultados reforçam a interpretação semântica que foram atribuídas aos clusters nas etapas anteriores. Assim sendo, o alinhamento utilizado no crosstab valida a escolha do método do K-Means para esse conjunto de dados específico.

Questão 5 - T-SNE ou PCA como Pré-processamento para Classificação**PROBLEMA 5. FLUXOGRAMA**

Para avaliar o impacto de diferentes técnicas de pré-processamento na tarefa de classificação, foi utilizada como variável alvo a variável *diagnóstico*, categorizada em 0 para benigno e 1 para maligno. Três técnicas foram utilizadas e testadas: normalização, redução de dimensionalidade com PCA e redução de dimensionalidade com T-SNE.


No primeiro teste, utilizando apenas normalização dos atributos numéricos, a acurácia do modelo KNN foi de 95,61%, indicando que os dados originais, devidamente escalados, já possuem um bom potencial para separar as duas classes. Esse resultado demonstra que a normalização é fundamental, pois garante que variáveis em diferentes escalas não dominem o processo de aprendizagem do modelo, especialmente em algoritmos baseados em distância como o KNN.



Já com a aplicação do PCA para reduzir os dados em duas dimensões, a acurácia caiu para 94,74%. Embora alta, houve uma pequena redução a qual sugere que as duas componentes principais capturam uma boa parte da variância explicativa, mas perdem algumas informações presentes nas dimensões descartadas. Esse resultado mostra que o PCA pode ser útil para simplificar o modelo e sua dimensionalidade.

A aplicação do T-SNE produziu uma visualização bidimensional dos dados que permite observar a distribuição e separação dos casos de tumores. O gráfico gerado mostrou que, mesmo que existam agrupamentos locais similares, as classes não ficaram perfeitamente separadas, o que indica que a separação das classes não é trivial em todas as dimensões

. Figura 12 - Distribuição dos dados com T-SNE



Por se tratar de uma técnica não supervisionada mais focada em visualização, o T-SNE não foi utilizado como pré-processamento para o modelo de classificação, uma que não permite a transformação consistente dos dados de teste e não gera métricas quantitativas de desempenho.



4. Conclusões

A análise exploratória e os métodos que foram aplicados nesse conjunto de dados permitiram identificar padrões consistentes e relevantes. O método de clusterização K-Means, mesmo sendo não supervisionado, conseguiu separar adequadamente as amostras em dois grupos, com um bom alinhamento em relação aos diagnósticos reais, conforme foi mostrado pela matriz de contingência. Os resultados apresentaram características evidentemente diferentes, com cluster associado a amostras benignas exibindo núcleos menores, mais regulares e uniformes, ao contrário do cluster que correspondia a amostras malignas onde por sua vez apresentava núcleos maiores e irregulares.

Em adição da análise das variáveis consideradas relevantes - raio médio, textura média, perímetro médio e área média - contribuíram com a interpretação semântica dos clusters, reforçando a associação entre os padrões de diagnósticos. Também os boxplots exibiu a separação clara entre esses grupos, ilustrando de maneira visual as diferenças dessas distribuições.

A avaliação do impacto de diferentes técnicas de pré-processamento sobre a classificação confirmou que a normalização simples por si só já era suficiente para atingir altos resultados de acurácia, indicando que as informações estão bem distribuídas nas variáveis. A aplicação do PCA como redução de dimensionalidade preservou boa parte dessas informações com uma pequena perda de desempenho. Além disso, o T-SNE usado como pré-processamento não se mostrou uma escolha adequada para a classificação, devido que o seu foco é em visualização local, onde ele mantém o detrimento da preservação de relações globais entre as variáveis.

De modo geral, a aplicação dessas técnicas de análise exploratória, clusterização e classificação demonstrou que esses dados possuem dados bem definidos e capacidade o suficiente para distinguir amostras benignas e malignas. Esse estudo mostrou a importância de uma boa escolha de variáveis, de tipos de pré-processamento e de métodos bem alinhadas com os objetivos do modelo, garantindo assim resultados consistentes e interpretativos.



5. Próximos passos

Os resultados obtidos já mostram que as técnicas que foram usadas tanto como clusterização e classificação deram conta de separar bem as amostras benignas e malignas. Porém existe bastante espaço para explorar outras métricas e possibilidades nesse projeto.

Um próximo passo ideal seria testar outras variáveis além das quatro que foram selecionadas. Pode ser que algumas das outras trinta também ajudem a diferenciar as classes, ou que tragam até novas informações.

Então, no geral, para análises futuras seria interessante ampliar a escolha de variáveis, testar novos métodos, experimentar novos modelos para validar tudo em outros dados para garantir que o que foi encontrado até aqui realmente faça sentido.