

TECHNICAL REPORT

Aluno: Abimael Gomes Mesquita Filho - 583351

Kaue Cruz Gomes - 585384

1. Introdução

O presente projeto tem como objetivo desenvolver um modelo de classificação utilizando o algoritmo K-Nearest Neighbors (KNN) com o dataset Online Shoppers Intention. Esse dataset contém informações sobre o comportamento de usuários durante a navegação em um site de comércio eletrônico, buscando prever se o usuário irá realizar uma compra ou não.

O algoritmo KNN foi escolhido por ser um método bastante conhecido e relativamente simples de aprendizado supervisionado, funcionando com base na distância entre os dados. Além disso, ele permite analisar como diferentes técnicas de normalização e diferentes valores do parâmetro k influenciam no desempenho do modelo.

Durante o desenvolvimento do projeto foram realizadas etapas de tratamento e preparação dos dados, normalização, treinamento do modelo, validação cruzada, Grid Search e análise dos resultados utilizando métricas de classificação.

O objetivo principal do trabalho foi montar um processo completo de classificação utilizando KNN, comparando os resultados obtidos com diferentes formas de normalização e diferentes configurações do modelo.

2. Observações

Algum problema que aconteceu? Alguma observação? Algum imprevisto? Se não houve problemas, deixe em branco.

Durante o desenvolvimento do projeto foi observado que o dataset possuía variáveis categóricas e booleanas que precisaram ser convertidas para valores numéricos antes da aplicação do algoritmo KNN.

Também foi identificado que o dataset apresentava desbalanceamento entre as classes da variável-alvo, o que influenciou diretamente os resultados do modelo, principalmente na classificação da classe positiva.

Não foram encontrados valores nulos no dataset. Entretanto, foram encontrados valores duplicados, que foram removidos durante o pré-processamento.

3. Resultados e discussão

Nesta seção deve-se descrever como foram as resoluções de cada questão. Crie sessões indicando a questão e discuta a implementação e resultados obtidos nesta. Explique o fluxograma do processo de cada questão, indicando quais processamentos são realizados nos dados. Sempre que possível, faça gráficos, mostre imagens, diagramas de blocos para que sua solução seja a mais completa possível. Discuta sempre sobre os números obtidos em busca de motivos de erros e acerto.

3.1 Exploração inicial do dataset

Inicialmente foi realizado o carregamento e exploração do dataset utilizando a biblioteca Pandas.

Foram utilizadas funções como:

- *head()*
- *info()*
- *describe()*
- *shape()*

Essas funções permitiram analisar:

- *quantidade de linhas e colunas;*
- *tipos de dados;*
- *estatísticas descritivas;*
- *distribuição geral dos atributos.*

O dataset possui atributos relacionados ao comportamento de navegação dos usuários, como quantidade de páginas visitadas, tempo gasto nas páginas, taxa de rejeição, valores de página, tipo de visitante, mês da sessão, entre outros.

A variável-alvo utilizada foi a coluna Revenue, responsável por indicar se o usuário realizou uma compra.

3.2 Tratamento de dados

Na etapa de pré-processamento foi realizada a verificação de valores ausentes utilizando o método `isnull().sum()`.

Não foram encontrados valores nulos no dataset.

Também foi realizada a verificação de possíveis inconsistências nos dados, incluindo:

- valores negativos em atributos numéricos;
- análise de valores únicos em variáveis categóricas;
- identificação de valores duplicados.

Foram encontrados registros duplicados no dataset, que foram removidos utilizando o método `drop_duplicates()`.

As variáveis categóricas foram convertidas para formato numérico utilizando `get_dummies()`, permitindo que o algoritmo KNN pudesse trabalhar corretamente com os dados.

As variáveis booleanas também foram convertidas para valores inteiros.

3.3 Separação dos dados

Após o pré-processamento, o dataset foi dividido em:

- atributos de entrada (X);
- variável-alvo (y).

A variável-alvo utilizada foi Revenue.

Posteriormente os dados foram divididos em conjuntos de treino e teste utilizando `train_test_split()`, sendo:

- 80% para treino;
- 20% para teste.

Foi utilizado `random_state = 42` para garantir reprodutibilidade dos resultados.

3.4 Técnicas de normalização

Foram aplicadas três técnicas diferentes de normalização:

Min-Max

A técnica Min-Max transforma os dados para um intervalo entre 0 e 1.

Essa técnica busca reduzir diferenças de escala entre os atributos.

Z-score

A normalização Z-score padroniza os dados utilizando média zero e desvio padrão igual a 1.

Essa abordagem é bastante utilizada em algoritmos baseados em distância.

Log

A transformação Log foi utilizada para reduzir a influência de valores extremos e diminuir a assimetria presente nos dados.

Os resultados mostraram que essa técnica apresentou o melhor desempenho entre as normalizações analisadas.

3.5 Treinamento do modelo KNN

O algoritmo KNN foi treinado utilizando diferentes valores do parâmetro k .

Foram realizados testes com valores de k variando de 1 até 20.

O objetivo dessa etapa foi analisar como o número de vizinhos influencia diretamente no desempenho do modelo.

A métrica utilizada para avaliação foi a acurácia.

3.6 Resultados das normalizações

Os melhores resultados obtidos foram:

Normalização	Melhor Acurácia	Melhor k
Min-Max	86.27%	7
Z-score	87.91%	13
Log	89.39%	18

Os resultados mostram que a normalização Log apresentou o melhor desempenho geral.

Isso indica que a redução da influência de valores extremos contribuiu positivamente para o cálculo de distância realizado pelo algoritmo KNN.

3.7 Gráfico de acurácia por valor de k

Foi construído um gráfico relacionando os valores de k com a acurácia obtida pelo modelo.

O gráfico permitiu identificar visualmente o melhor valor de k para cada técnica de normalização.

Observou-se que valores muito baixos de k podem gerar maior sensibilidade a ruídos, enquanto valores muito altos podem reduzir a capacidade de diferenciação entre classes.

A melhor parametrização encontrada visualmente foi:

- *k = 18 utilizando normalização Log.*

3.8 Validação cruzada e Grid Search

Foi aplicada validação cruzada utilizando `cross_val_score()` com `cv = 5`.

Essa técnica permite avaliar o modelo de forma mais confiável, reduzindo a dependência de uma única divisão treino/teste.

Também foi utilizado `GridSearchCV` para seleção automática do melhor valor de `k`.

Os resultados obtidos pelo Grid Search apresentaram comportamento semelhante ao encontrado na análise visual do gráfico.

Isso mostrou consistência na escolha do melhor hiperparâmetro.

3.9 Matriz de confusão e Classification Report

A matriz de confusão obtida foi:

	Previsto 0	Previsto 1
Real 0	2001	78
Real 1	181	181

Os resultados mostraram que o modelo apresentou excelente desempenho na classificação da classe 0.

Entretanto, foi observada maior dificuldade na classificação da classe 1.

O Classification Report apresentou os seguintes resultados principais:

- Accuracy: aproximadamente 89%;
- Precision da classe 1: 70%;
- Recall da classe 1: 50%;
- F1-score da classe 1: 58%.



Esses resultados indicam que o modelo conseguiu identificar corretamente boa parte das compras realizadas, porém ainda apresentou dificuldade em detectar todos os casos positivos.

Isso ocorre principalmente devido ao desbalanceamento entre as classes do dataset.

4. Conclusões

Os resultados esperados foram satisfeitos? Se não, qual o motivo? Qual a sua análise?

Os resultados obtidos foram satisfatórios para o problema de classificação proposto.

O algoritmo KNN apresentou bom desempenho geral, alcançando aproximadamente 89,39% de acurácia utilizando normalização Log com $k = 18$.

Foi possível observar que a técnica de normalização utilizada influencia diretamente no desempenho do modelo.

A transformação Log apresentou melhores resultados quando comparada às técnicas Min-Max e Z-score.

Também foi possível perceber a importância da escolha adequada do parâmetro k , já que diferentes valores influenciaram significativamente os resultados obtidos.

Apesar da boa acurácia geral, a análise da matriz de confusão e do Classification Report mostrou que o modelo apresentou maior dificuldade na classificação da classe positiva.

Isso ocorreu principalmente devido ao desbalanceamento presente no dataset.

Mesmo assim, os resultados demonstraram que o algoritmo KNN pode ser utilizado de forma eficiente em problemas de classificação quando acompanhado de técnicas adequadas de pré-processamento e normalização.

5. Próximos passos

Depois desse relatório, quais os próximos passos você sugere para este projeto?

Como possíveis melhorias futuras para o projeto, sugere-se:



- *aplicar técnicas de balanceamento de classes;*
- *testar outros algoritmos de classificação;*
- *utilizar seleção automática de atributos;*
- *testar métricas adicionais além da acurácia;*
- *aumentar o intervalo de valores de k analisados;*
- *comparar o desempenho utilizando outros métodos de validação.*

Essas melhorias podem contribuir para aumentar ainda mais a capacidade preditiva do modelo.