



TECHNICAL REPORT

Aluno: Luiza de Melo Nogueira e Ana Julia da Silva Freitas

1. Introdução

Descrição do dataset informando suas características relevantes e informação do que se deve analisar neste neste.

2. Observações

Algum problema que aconteceu? Alguma observação? Algum imprevisto? Se não houve problemas, deixe em branco.

3. Resultados e discussão

Nesta seção deve-se descrever como foram as resoluções de cada questão. Crie sessões indicando a questão e discuta a implementação e resultados obtidos nesta. Explique o fluxograma do processo de cada questão, indicando quais processamentos são realizados nos dados. Sempre que possível, faça gráficos, mostre imagens, diagramas de blocos para que sua solução seja a mais completa possível. Discuta sempre sobre os números obtidos em busca de motivos de erros e acerto.

4. Conclusões

Os resultados esperados foram satisfeitos? Se não, qual o motivo? Qual a sua análise?

5. Próximos passos

Depois desse relatório, quais os próximos passos você sugere para este projeto?



1. Introdução

*O dataset analisado refere-se ao comportamento de clientes em um shopping center. Ele contém 200 registros com informações como **idade, gênero, renda anual e pontuação de gastos** dos clientes. O objetivo do trabalho foi explorar os dados, aplicar técnicas de **redução de dimensionalidade, clusterização** e por fim **realizar uma tarefa de classificação supervisionada** usando os agrupamentos descobertos.*

O fluxo de trabalho foi dividido em cinco etapas, cada uma resolvida em scripts independentes, cobrindo desde a análise exploratória até a comparação de classificadores baseados em PCA e t-SNE.

2. Observações

Não houve problemas técnicos relevantes durante a execução das etapas. Para facilitar a integração entre os scripts, os resultados intermediários (como a variável cluster gerada no K-Means) foram salvos em arquivo .csv para reutilização nos scripts seguintes.


3. Resultados e discussão



3.1 QUESTÃO 1 — Análise Exploratória



Foram exploradas estatísticas descritivas com `describe()` e `value_counts()`, além de histogramas, boxplots e matriz de correlação. A variável `Gender` foi convertida para valores numéricos (0 para masculino, 1 para feminino). As variáveis principais analisadas foram:



- *Age*: idade dos clientes
- *Annual Income (k\$)*: renda anual
- *Spending Score (1–100)*: pontuação de gasto

Foi aplicado `StandardScaler` para padronização dos dados numéricos. A análise indicou que as variáveis têm escalas diferentes, justificando a normalização antes de PCA ou t-SNE.











3.2 QUESTÃO 2 — Redução de Dimensionalidade (PCA vs t-SNE)

Foram aplicados os métodos **PCA** e **t-SNE**, cada um com $n_components=2$. As projeções foram visualizadas por meio de scatterplot. Os resultados indicaram:

- **PCA** explicou mais de **95% da variância** nos dois primeiros componentes, porém com separações de grupos menos evidentes.
- **t-SNE** apresentou separações mais claras entre grupos, preservando bem as **relações locais** dos dados.
- O tempo de execução do t-SNE foi maior, mas a visualização foi superior.

Ambos os métodos se mostraram úteis: PCA para compressão e visualização da estrutura geral, e t-SNE para análise exploratória de agrupamentos.









3.3 QUESTÃO 3 — Clusterização com K-Means e Hierárquico

Foram aplicados os seguintes métodos:


- **K-Means**, com validação por Elbow Method (inércia) e Silhouette Score. O valor ideal de $k=4$ foi escolhido.
- **Hierárquico**, com os métodos de ligação average e complete, visualizados com dendrogramas.
- Visualizações dos clusters foram feitas sobre a projeção PCA.

K-Means apresentou agrupamentos mais compactos e definidos. O método **Hierárquico Completo** também formou bons grupos, enquanto o **Average** mostrou maior equilíbrio interno. A separação visual dos grupos foi consistente com as análises exploratórias anteriores.







Dendrograma - Ligação Completa



Hierárquico (Average) - PCA








3.4 QUESTÃO 4 — Interpretação Semântica dos Grupos

Com base nas médias e boxplots das variáveis Age, Annual Income e Spending Score por cluster, os grupos foram interpretados como:

- **Cluster 0:** Jovens gastadores – idade baixa, gasto alto.
- **Cluster 1:** Poupadores – renda alta, gasto baixo.
- **Cluster 2:** Clientes com perfil econômico – baixa renda e baixo gasto.
- **Cluster 3:** Clientes Premium – alta renda e alto gasto.

Esses perfis ajudam a entender o comportamento dos clientes e podem ser usados em estratégias de marketing segmentado.





3.5 QUESTÃO 5 — Classificação Supervisionada com PCA e t-SNE

A variável cluster foi usada como alvo (y) para treinar classificadores. Três cenários foram testados usando **Random Forest**:

Pré-processamento	Acurácia
Dados normalizados	91,67%
PCA (2 componentes)	95,00%
t-SNE (2 componentes)	93,33%

O modelo com PCA teve o melhor desempenho, seguido de t-SNE. Isso mostra que a clusterização foi eficaz em identificar padrões e que a redução de dimensionalidade pode melhorar a performance preditiva.

4. Conclusões

Todas as etapas foram concluídas com sucesso. O processo de análise exploratória permitiu entender a estrutura do dataset. O uso de PCA e t-SNE revelou padrões importantes que ajudaram a guiar a clusterização.

A classificação final com Random Forest mostrou que os agrupamentos obtidos com K-Means representam bem os dados e podem ser usados para prever perfis de novos clientes com alta precisão.

O uso conjunto de métodos não supervisionados e supervisionados foi eficaz e demonstrou como técnicas de aprendizado de máquina podem se complementar.



5. Próximos passos

- *Implementar outros algoritmos de clusterização (DBSCAN, GMM) para comparar com K-Means.*
 - *Aplicar validação cruzada nos modelos de classificação para testar estabilidade.*
 - *Testar classificadores adicionais como SVM, XGBoost ou KNN.*
 - *Criar um dashboard visual com os clusters e perfis.*
 - *Integrar essa análise com dados reais de marketing para segmentação personalizada.*
-