


PROJETO DE INTELIGÊNCIA ARTIFICIAL



Classificação com KNN • Regressão Linear Supervisionada

Kauê Cruz Gomes | Abimael Gomes M. Filho

Disciplina: Inteligência Artificial • 2026

Roteiro da Apresentação

VISÃO GERAL

Primeiro o modelo de classificação; depois o modelo de regressão.

01

Classificação com KNN

Dataset, tratamento, normalizações e treinamento

02

Resultados KNN

Acurácia, matriz de confusão e classification report

03

Regressão Supervisionada

Dataset Energy, correlações, Linear, Ridge e Lasso

04

Resultados e Conclusões

Métricas, validação cruzada, Grid Search e próximos passos

PARTE 1 — CLASSIFICAÇÃO COM KNN

Online Shoppers Intention Dataset • Predição de compra em e-commerce



Classificação — Dataset e Objetivo

KNN aplicado ao comportamento de navegação de usuários em e-commerce.

KNN

Objetivo do Modelo

- Prever se o usuário realizará uma compra ou não.
- Variável-alvo: Revenue (comprou / não comprou).
- O KNN foi escolhido por ser supervisionado e baseado em distância.
- A análise compara normalizações e valores de k para medir o desempenho.

Dados analisados

- Páginas visitadas e tempo gasto nas páginas.
- Taxa de rejeição, Page Values, mês, tipo de visitante e outros atributos.
- Sem valores nulos; registros duplicados foram removidos.

Revenue

variável-alvo

80/20

treino e teste

k = 1 a 20

faixa testada

cv = 5

validação cruzada

Mensagem-chave

O modelo transforma o comportamento de navegação em uma previsão: o usuário comprou ou não comprou.

Pipeline do Projeto de Classificação

PROCESSO

Etapas realizadas do carregamento dos dados até a avaliação final.

Por que esse pipeline importa?


Como o KNN mede distância entre pontos, variáveis fora de escala e categorias não convertidas podem distorcer o resultado. Por isso, pré-processamento e normalização são etapas decisivas.



Normalização & Escolha do k

Comparação da acurácia do KNN para diferentes técnicas de normalização.

RESULTADOS



Normalização	Melhor acurácia	Melhor k	Interpretação
Min-Max	86,27%	7	Boa base, mas sensível a outliers
Z-score	87,91%	13	Melhora com escala padronizada
Log ★	89,39%	18	Melhor resultado geral

Interpretação

A transformação Log reduziu a influência de valores extremos e melhorou o cálculo de distância do KNN.

89,39%
acurácia final

k = 18
melhor parâmetro

Log
melhor escala

Validação Cruzada e Grid Search

KNN

Como foi confirmada a melhor configuração do KNN.

Validação Cruzada (cv = 5)

- Aplicada com `cross_val_score()`.
- Reduz a dependência de uma única divisão treino/teste.
- Fornece estimativa mais confiável da generalização.
- Confirmou consistência do desempenho obtido.

Grid Search


- Usado para escolher automaticamente o melhor valor de k .
- O resultado foi semelhante ao observado no gráfico.
- A melhor parametrização foi $k = 18$ com Log.
- Mostrou robustez na escolha do hiperparâmetro.

Conclusão: Log + $k=18$ foi a configuração mais consistente para o KNN.

Matriz de Confusão — KNN

Modelo KNN com normalização Log e k = 18.

AVALIAÇÃO



2001
verdadeiros negativos

181
verdadeiros positivos

78
falsos positivos

181
falsos negativos

Leitura do resultado

O modelo acerta muito bem a classe 0, mas ainda perde compras reais por causa dos falsos negativos.

89,39%
acurácia geral

Classification Report

MÉTRICAS

Métricas por classe: Precision, Recall, F1-score e Support.

CLASSIFICATION REPORT

Modelo KNN - Normalização Log (k = 18)

CLASSE	PRECISION (Quando prevê a classe, quantas vezes acerta)	RECALL (Dos casos reais da classe, quantos encontra)	F1-SCORE (Equilíbrio entre Precision e Recall)	SUPPORT (Quantidade real de exemplos)
0 (Não comprou) 	0,92 92%	0,96 96%	0,94 94%	2079 (85,1%)
1 (Comprou) 	0,70 70%	0,50 50%	0,58 58%	362 (14,9%)
ACURÁCIA (ACCURACY)	0,89 89,39% Proporção total de previsões corretas do modelo.			2441 (Total de exemplos)



DESEMPENHO – CLASSE 0 (NÃO COMPROU)

O modelo foi excelente em identificar usuários que não compraram.



DESEMPENHO – CLASSE 1 (COMPROU)

O modelo teve mais dificuldade em identificar corretamente os usuários que realizaram compra.



OBSERVAÇÃO

O desbalanceamento do dataset impactou os resultados da classe 1.

Precision: quando o modelo prevê a classe, quantas vezes ele acerta.

Recall: quantos casos reais da classe o modelo consegue encontrar.

F1-Score: equilíbrio entre Precision e Recall.

Support: quantidade real de exemplos da classe.

Pontos importantes

- Classe 0: precision 0,92 e recall 0,96.
- Classe 1: precision 0,70, recall 0,50 e F1 0,58.
- O support mostra desbalanceamento: 2079 vs 362.
- A acurácia é alta, mas a classe positiva exige atenção.

Acurácia ≠ desempenho completo

Classificação — Conclusões e Próximos Passos

CONCLUSÕES

Síntese do desempenho do KNN e melhorias possíveis.

Conclusões

- Resultados satisfatórios para o problema de classificação.
- Normalização Log superou Min-Max e Z-score.
- A escolha adequada de k influenciou diretamente o desempenho.
- O principal desafio foi detectar todos os casos positivos.

Próximos Passos

- Aplicar balanceamento de classes (ex.: SMOTE).
- Testar Random Forest, SVM e outros classificadores.
- Usar seleção automática de atributos.
- Avaliar AUC-ROC, F1-macro e métricas além da acurácia.
- Aumentar a faixa de k e comparar validações.

PARTE 2 — REGRESSÃO SUPERVISIONADA

Appliances Energy Prediction Dataset • Consumo energético residencial em Wh



Regressão — Dataset e Pré-processamento

DATASET

Predição do consumo de energia dos eletrodomésticos: Appliances.

Energy Data Complete

- Dados de uma residência na Bélgica.
- Coleta a cada 10 minutos durante cerca de 4,5 meses.
- Target: Appliances, consumo dos eletrodomésticos em Wh.
- Features: temperaturas T1–T9, umidades RH_1–RH_9, clima externo, vento, pressão, visibilidade e outros.


Tratamento aplicado

- Remoção das colunas não preditivas: date, rv1 e rv2.
- Nenhum valor ausente relevante após o tratamento.
- Dataset final: ~19.735 amostras × 26 features + 1 target.
- StandardScaler aplicado apenas nas features, não no alvo.
- Lasso configurado com max_iter = 10000 para convergência.

Correlação com Appliances

ANÁLISE

Correlação de Pearson de cada atributo com o consumo de energia.




Principais insights

- lights aparece como maior correlação positiva ($\sim 0,20$).
- T2, T6, T_out e Windspeed também têm correlação positiva.
- RH_out apresenta a maior correlação negativa ($\sim -0,15$).
- Nenhuma variável isolada explica fortemente o consumo.
- O problema é multivariado e provavelmente não-linear.

Mapa de Correlação entre Atributos

HEATMAP

Heatmap usado para enxergar relações entre todos os pares de variáveis.




Como interpretar

- Vermelho: correlação positiva forte.
- Azul: correlação negativa forte.
- Branco/cinza: correlação fraca ou nula.
- Temperaturas internas formam blocos de alta correlação.
- Umidades relativas também apresentam grupos correlacionados.
- Appliances mantém correlações fracas com a maioria das features.

Regressão Linear Simples

MODELO SIMPLES

Relação entre lights e Appliances: uma variável isolada não explica o consumo.



$$R^2 = 0,049$$

somente 4,9% da variância explicada

Leitura do gráfico

- A tendência é positiva, mas fraca.
- Os pontos estão muito dispersos em torno da reta.
- O consumo tem picos e outliers.
- A regressão simples serve para interpretação, mas não para alta predição.

Modelos de Regressão e Métricas

RESULTADOS

Comparação entre Linear, Ridge e Lasso no split treino/teste.

Regressão Linear

Modelo base sem regularização. Captura relações lineares entre atributos e consumo.

Ridge

Regularização L2: penaliza coeficientes grandes e reduz instabilidade.

Lasso

Regularização L1: pode zerar coeficientes e realizar seleção implícita de atributos.

Modelo	RMSE	MAE	R ²
Linear	~92 Wh	~54 Wh	~0,15
Ridge	~92 Wh	~54 Wh	~0,15
Lasso	~93 Wh	~55 Wh	~0,14

Interpretação dos resultados

R² em torno de 0,15 indica que os modelos lineares explicam apenas cerca de 15% da variação do consumo. A limitação principal não foi overfitting, e sim a natureza não-linear e comportamental do problema.

Validação Cruzada e Grid Search — Regressão

AVALIAÇÃO

Estabilidade dos modelos e busca do hiperparâmetro alpha.

Modelo	R ² médio (CV)	Desvio padrão	Observação
Linear	~0,15	~0,01	Estável
Ridge	~0,15	~0,01	Estável
Lasso	~0,14	~0,01	Esparsidade

Modelo	Melhor alpha	R ² (CV)	Regularização
Ridge	~0,01 a 1,0	~0,15	L2
Lasso	~0,1	~0,14	L1

O que os testes mostram?

- A validação cruzada confirma estabilidade entre os folds.
- O desvio baixo (~0,01) indica pouca variação de desempenho.
- Ridge e Linear ficaram muito próximos, sugerindo que a regularização não trouxe ganho expressivo.
- Lasso promove esparsidade, mas perdeu um pouco de desempenho.

Conclusão técnica: o gargalo está na linearidade do modelo, não em overfitting severo.

Regressão — Conclusões e Próximos Passos

CONCLUSÕES

Por que os resultados foram modestos e como evoluir o projeto.

Conclusões

- Pipeline completo de regressão supervisionada foi executado.
- $R^2 \approx 0,15$ mostra poder preditivo limitado dos modelos lineares.
- Nenhuma variável isolada é preditor forte de Appliances.
- Fatores comportamentais humanos não aparecem nas features.
- Ridge/Lasso não trouxeram ganhos significativos sobre o baseline linear.

Evoluções sugeridas

- Testar Random Forest, XGBoost, LightGBM e Redes Neurais.
- Criar atributos temporais: hora, dia da semana e mês.
- Investigar e tratar outliers de alto consumo.
- Aplicar SHAP/permutation importance para seleção de features.
- Testar transformação logarítmica da variável-alvo.
- Explorar séries temporais: ARIMA ou LSTM.

Síntese Final do Projeto

FECHAMENTO

O que foi aprendido com os dois modelos.

Classificação com KNN

89,39%

acurácia final

k=18

melhor parâmetro

- Melhor normalização: Log.
- Bom desempenho geral, mas recall da classe positiva precisa melhorar.
- Desbalanceamento foi o maior desafio.

Regressão Supervisionada

$R^2 \approx 0,15$


Linear/Ridge

$R^2 = 0,049$

regressão simples

- Modelos lineares funcionam como baseline interpretável.
- Consumo energético exige modelos não-lineares e engenharia de atributos.
- Correlação fraca reforça a natureza multivariada do problema.

Mensagem final: pré-processamento, validação e interpretação dos resultados são tão importantes quanto o algoritmo escolhido.



OBRIGADO!

Perguntas?

Kauê Cruz Gomes • Abimael Gomes Mesquita Filho

Projeto de Inteligência Artificial — Classificação com KNN e Regressão Linear

