

TECHNICAL REPORT

Aluna: Dayane Magalhães Ferreira – 587972

Aluna: Suiany Pinto Gomes - 582147

1. Introdução

O presente trabalho utiliza o dataset Energy Efficiency, disponibilizado pela base de dados da UCI Machine Learning Repository, com o objetivo de analisar fatores relacionados à eficiência energética de edificações por meio de técnicas de regressão. Esse conjunto de dados é amplamente utilizado em estudos de aprendizado de máquina voltados para previsão de consumo energético e desempenho térmico de edifícios.

O dataset é composto por 768 registros e 10 variáveis, sendo oito atributos independentes relacionados às características físicas e construtivas dos edifícios e duas variáveis-alvo referentes ao desempenho energético.

A Tabela 1 apresenta a descrição das variáveis presentes no dataset.

Colunas (renomeada)	Variáveis	Tipo	Descrição
X1 (comp_relativa)	Entrada	Contínuo (float)	Compacidade relativa
X2 (area_superf)	Entrada	Contínuo (float)	Área da superfície
X3 (area_parede)	Entrada	Contínuo (float)	Área da parede
X4 (area_telhado)	Entrada	Contínuo (float)	Área do telhado
X5 (altura_total)	Entrada	Contínuo (float)	Altura total
X6 (orientacao)	Entrada	Inteiro (int)	Orientação
X7 (area_vidro)	Entrada	Contínuo (float)	Área envidraçada
X8 (dist_vidro)	Entrada	Inteiro (int)	Distribuição da área envidraçada
Y1 (carga_aqueci)	Alvo	Contínuo (float)	Carga de aquecimento
Y2 (carga_resfria)	Alvo	Contínuo (float)	Carga de resfriamento

Fonte: UCI Machine Learning Repository – Energy Efficiency Dataset (2012).

Neste estudo, optou-se por utilizar a variável carga de aquecimento (carga_aqueci) como variável-alvo principal do problema de regressão. O objetivo da análise consiste em compreender a relação entre as características físicas dos edifícios e a carga de aquecimento, identificando os atributos mais relevantes para a predição dessa variável.

Para isso, serão aplicados modelos de Regressão Linear, Ridge e Lasso, permitindo comparar o desempenho das abordagens, analisar a relevância dos atributos, aplicar validação cruzada e otimização de hiperparâmetros por meio do Grid Search, visando obter modelos preditivos mais robustos e confiáveis.

2. Observações

Durante o desenvolvimento do projeto, não foram identificados problemas significativos relacionados à qualidade dos dados, uma vez que o dataset apresentou ausência de valores nulos e registros duplicados, permitindo a aplicação direta das técnicas de regressão propostas.

Entretanto, observou-se a necessidade de aplicação de padronização dos dados (StandardScaler) para os modelos Ridge e Lasso, visto que métodos de regularização são sensíveis à escala das variáveis. Esse procedimento foi realizado com o objetivo de garantir maior estabilidade e melhor desempenho dos modelos.

Além disso, foi necessário definir uma única variável-alvo para o problema de regressão, sendo escolhida a variável carga de aquecimento (carga_aqueci), devido ao foco da análise e à adequação aos objetivos do projeto.

Também foi observado que a variável altura total (altura_total), utilizada na regressão linear simples, apresenta valores discretos no dataset, resultando em agrupamento dos pontos no gráfico de dispersão. No entanto, tal comportamento não comprometeu a análise, pois a relação linear permaneceu evidente.

3. Resultados e discussão

3.1 Carregamento e exploração do dataset


Inicialmente, realizou-se o carregamento do dataset Energy Efficiency por meio da biblioteca Pandas, utilizando a função `read_excel()`. Após o carregamento, foi realizada a renomeação das variáveis com nomes mais intuitivos, facilitando a interpretação dos dados ao longo do desenvolvimento do projeto. Posteriormente, foram exibidas as primeiras linhas do conjunto de dados utilizando a função `head()`, permitindo verificar a estrutura inicial do dataset e confirmar a correta importação dos dados.

A exploração inicial mostrou que o conjunto de dados possui 768 registros e 10 variáveis, sendo oito atributos preditores relacionados às características físicas dos edifícios e duas variáveis-alvo associadas ao desempenho energético. Também foi realizada a inspeção estrutural do dataset por meio da função `info()`, possibilitando verificar os tipos de dados presentes em cada variável. Observou-se predominância de variáveis do tipo `float64`,

representando atributos contínuos, além de duas variáveis inteiras (orientacao e dist_vidro).

As estatísticas descritivas foram obtidas utilizando a função `describe()`, permitindo analisar medidas como média, desvio padrão, mínimo, máximo e quartis das variáveis. Observou-se que a variável carga de aquecimento apresentou média de aproximadamente 22,31, variando entre 6,01 e 43,10, indicando ampla variabilidade no comportamento energético dos edifícios analisados.

Além disso, a variável carga de resfriamento apresentou média de 24,59, com valores entre 10,90 e 48,03, sugerindo diferenças relevantes no desempenho térmico das construções presentes no conjunto de dados.



```
Estadísticas descritivas:
      comp_relativa  area_superf  ...  carga_aqueci  carga_resfria
count      768.000000    768.000000  ...    768.000000    768.000000
mean        0.764167    671.708333  ...    22.307195    24.587760
std         0.105777     88.086116  ...    10.090204     9.513306
min         0.620000    514.500000  ...     6.010000    10.900000
25%         0.682500    606.375000  ...    12.992500    15.620000
50%         0.750000    673.750000  ...    18.950000    22.080000
75%         0.830000    741.125000  ...    31.667500    33.132500
max         0.980000    808.500000  ...    43.100000    48.030000

[8 rows x 10 columns]
```

Figura 1 – Primeiras linhas do dataset e estatísticas descritivas.

3.2 Verificação de inconsistências e valores ausentes

Após a exploração inicial, realizou-se a análise da qualidade dos dados com o objetivo de identificar possíveis inconsistências que pudessem comprometer o desempenho dos modelos de regressão. Inicialmente, foi executada a verificação de valores ausentes utilizando a função `isnull().sum()`. Os resultados indicaram ausência total de dados faltantes em todas as variáveis, eliminando a necessidade de aplicação de técnicas de imputação ou remoção de registros.

Também foi realizada a verificação de registros duplicados por meio da função `duplicated().sum()`. O resultado demonstrou zero instâncias duplicadas, indicando consistência do conjunto de dados e reduzindo riscos de enviesamento dos modelos. A inexistência de dados ausentes e duplicados representa uma característica positiva do dataset, permitindo que o processo de modelagem ocorresse sem necessidade de tratamentos corretivos complexos.

3.3 Análise dos atributos relevantes

Com o objetivo de compreender a relação entre as variáveis independentes e a variável-alvo carga de aquecimento, foi construída uma matriz de correlação, representada visualmente por um mapa de calor (*heatmap*).

A análise de correlação permitiu identificar relações positivas e negativas entre os atributos do dataset, destacando variáveis potencialmente mais relevantes para o problema de regressão.

Observou-se que a variável altura total (*altura_total*) apresentou uma das maiores correlações positivas com a variável-alvo, aproximadamente 0,89, indicando forte relação linear com a carga de aquecimento. Em contrapartida, variáveis como orientação e distribuição da área envidraçada apresentaram menor influência linear direta.

Além da correlação, utilizou-se o modelo Lasso para análise da importância das variáveis, observando os coeficientes atribuídos a cada atributo após a regularização. Os resultados indicaram novamente altura total como uma das variáveis mais relevantes para predição, corroborando os resultados observados na matriz de correlação.

A Figura 2 apresenta o mapa de correlação entre as variáveis do dataset.




Figura 2 – Mapa de correlação do dataset Energy Efficiency

Posteriormente, a Figura 3 apresenta os coeficientes obtidos pelo modelo Lasso para avaliação da importância das variáveis.




Figura 3 – Importância dos atributos obtida pelo modelo Lasso

3.4 Definição das variáveis de entrada e saída

Após a etapa de exploração dos dados, foi realizada a separação entre as variáveis preditoras e a variável-alvo do problema de regressão.

As variáveis independentes (X) foram compostas pelos atributos físicos e estruturais dos edifícios, excluindo-se as variáveis de saída relacionadas ao desempenho energético. A variável-alvo (y) escolhida para o estudo foi carga de aquecimento (carga_aqueci), devido ao foco da análise na previsão do consumo energético relacionado ao aquecimento dos edifícios.

Essa etapa foi necessária para preparar os dados para treinamento e avaliação dos modelos supervisionados de regressão.

O fluxograma geral do processo realizado no projeto é apresentado na Figura 4.



Figura 4 – Fluxograma do pipeline do projeto

3.5 Pré-processamento dos dados

Antes do treinamento dos modelos, foi aplicada uma etapa de pré-processamento utilizando a técnica de padronização dos dados (*StandardScaler*). Esse procedimento foi aplicado especialmente aos modelos Ridge e Lasso, pois métodos baseados em regularização são sensíveis à escala das variáveis. A padronização transforma os atributos para uma mesma escala, reduzindo possíveis distorções provocadas por diferenças de magnitude entre as variáveis.

A Regressão Linear tradicional não exige necessariamente esse procedimento, razão pela qual foi treinada utilizando os dados originais. Esse processo contribui para maior estabilidade do treinamento e melhor desempenho dos modelos regularizados.

3.6 Divisão entre treino e teste

Após o pré-processamento, o conjunto de dados foi dividido em subconjuntos de treinamento e teste, utilizando a função `train_test_split()` da biblioteca Scikit-Learn.

Foi adotada uma proporção de:

- 80% dos dados para treinamento
- 20% dos dados para teste

Além disso, foi utilizado o parâmetro `random_state = 42`, garantindo reprodutibilidade dos experimentos e consistência dos resultados obtidos. A separação treino/teste é

importante para avaliar a capacidade de generalização dos modelos, evitando que sejam avaliados utilizando os mesmos dados empregados no treinamento.

3.7 Implementação do modelo de Regressão Linear

Inicialmente, foi implementado o modelo de Regressão Linear, considerado uma das abordagens mais tradicionais para problemas de regressão supervisionada. O modelo foi treinado utilizando os dados de treinamento e posteriormente avaliado no conjunto de teste por meio das métricas com os seguintes resultados:

- RMSE (*Root Mean Squared Error*) $\rightarrow 3,025$
- R^2 (*Coefficiente de Determinação*) $\rightarrow 0,912$

O valor de $R^2 = 0,912$ indica que aproximadamente 91,2% da variabilidade da carga de aquecimento foi explicada pelo modelo, representando um desempenho elevado. Por outro lado, o valor de RMSE = 3,025 sugere erro médio relativamente baixo entre os valores reais e previstos, indicando boa capacidade preditiva.

A Figura 5 apresenta a relação entre valores reais e previstos pelo modelo de Regressão Linear.




Figura 5 – Valores reais versus previstos da Regressão Linear

Observa-se que os valores previstos se aproximam da linha ideal de previsão, sugerindo boa aderência do modelo aos dados.

3.8 Implementação dos modelos Ridge e Lasso

Posteriormente, foram implementados os modelos Ridge e Lasso, ambos variantes da Regressão Linear que utilizam técnicas de regularização para reduzir problemas relacionados ao sobreajuste (*overfitting*).

O modelo Ridge utiliza regularização do tipo L2, penalizando coeficientes elevados sem eliminá-los completamente. Já o modelo Lasso emprega regularização L1, podendo reduzir alguns coeficientes a zero, funcionando também como mecanismo de seleção de atributos.

Os resultados obtidos foram:

Modelo Ridge

- RMSE (*Root Mean Squared Error*) → 3,026
- R^2 (*Coeficiente de Determinação*) → 0,912

Modelo Lasso

- RMSE (*Root Mean Squared Error*) → 3,153
- R^2 (*Coeficiente de Determinação*) → 0,905

Os resultados demonstram que o modelo Ridge apresentou desempenho praticamente idêntico ao da Regressão Linear tradicional, indicando que o conjunto de dados possui forte comportamento linear e baixa necessidade de regularização. Por outro lado, o modelo Lasso apresentou leve redução no desempenho, o que pode ser explicado pelo fato de a regularização L1 reduzir a influência de algumas variáveis relevantes, tornando o modelo mais simples, porém ligeiramente menos preciso.

3.9 Comparação entre os modelos

A Tabela 3 apresenta uma comparação direta entre os modelos implementados.

Modelo	RMSE	R^2
Regressão Linear	3,025	0,912
Ridge	3,026	0,912
Lasso	3,153	0,905

Tabela 3 – Comparação de desempenho dos modelos

3.10 Regressão Linear Simples

Com o objetivo de analisar a influência de um único atributo na variável-alvo, foi implementada uma Regressão Linear Simples.

A escolha do atributo foi realizada com base na matriz de correlação, sendo selecionada a variável altura total (altura_total), por apresentar a maior correlação positiva com a carga de aquecimento (0,89).

Os resultados obtidos foram:

- RMSE (*Root Mean Squared Error*) $\rightarrow 4,656$
- R^2 (*Coefficiente de Determinação*) $\rightarrow 0,792$

O resultado de $R^2 = 0,792$ indica que, mesmo utilizando apenas uma variável, o modelo conseguiu explicar aproximadamente 79,2% da variabilidade da carga de aquecimento, demonstrando forte influência da altura do edifício no desempenho energético.

A Figura 6 apresenta a reta de regressão obtida.




Figura 6 – Regressão linear simples utilizando altura total

3.11 Validação cruzada

Com o objetivo de avaliar a capacidade de generalização dos modelos de forma mais robusta, foi aplicada a técnica de validação cruzada (*Cross Validation*), utilizando 5 folds ($cv=5$). Nesse procedimento, o conjunto de dados é dividido em cinco subconjuntos, onde, a cada iteração, uma parte é utilizada para teste e as demais para treinamento. Esse processo reduz a dependência de uma única divisão treino/teste e permite estimativas mais confiáveis do desempenho do modelo.

A métrica utilizada para avaliação foi o coeficiente de determinação (R^2). Os resultados obtidos são apresentados na Tabela 4.

Modelo	R^2 médio
Regressão Linear	0,890
Ridge	0,890
Lasso	0,885

Tabela 4 – Resultados da validação cruzada

Os resultados mostram que os três modelos mantiveram desempenho elevado durante a validação cruzada, apresentando valores de R^2 próximos de 0,89, o que demonstra boa estabilidade e capacidade de generalização. Observa-se também que os valores obtidos na validação cruzada foram ligeiramente inferiores aos observados no conjunto de teste ($R^2 \approx 0,91$), comportamento considerado esperado em problemas de aprendizado supervisionado.

Essa pequena diferença sugere baixa ocorrência de overfitting, indicando que os modelos conseguem manter desempenho consistente ao serem avaliados em diferentes subconjuntos dos dados. Além disso, a proximidade dos resultados entre os modelos reforça a evidência de que o dataset apresenta forte comportamento linear, favorecendo técnicas tradicionais de regressão.

3.12 Otimização de hiperparâmetros com Grid Search

Após a validação cruzada, foi aplicada a técnica de Grid Search (*GridSearchCV*), com o objetivo de encontrar os melhores hiperparâmetros para os modelos Ridge e Lasso. O hiperparâmetro analisado foi o valor de alpha, responsável por controlar a intensidade da regularização aplicada aos coeficientes do modelo.

Foi utilizada uma grade de busca contendo múltiplos valores de alpha, variando entre valores muito pequenos e maiores intensidades de penalização. Os melhores resultados encontrados são apresentados na Tabela 5.

Modelo	Melhor alpha	Melhor R ²
Ridge	0,0001	0,890
Lasso	0,0001	0,890

Tabela 5 – Resultados do Grid Search

Os resultados demonstraram que o melhor valor de regularização encontrado para ambos os modelos foi $\alpha = 0,0001$, correspondendo a uma penalização extremamente baixa. Esse resultado sugere que o dataset apresenta estrutura linear forte e pouca necessidade de regularização, visto que penalizações maiores não contribuíram para melhora significativa do desempenho.

Em outras palavras, os dados já apresentam comportamento suficientemente estável para serem modelados com pouca restrição sobre os coeficientes, explicando o desempenho elevado observado também no modelo de Regressão Linear tradicional.

3.13 Discussão geral dos resultados

A comparação entre os modelos permitiu observar que a Regressão Linear apresentou o melhor desempenho geral, obtendo $RMSE = 3,025$ e $R^2 = 0,912$, explicando aproximadamente 91,2% da variabilidade da carga de aquecimento. O modelo Ridge apresentou desempenho praticamente equivalente, indicando que a aplicação da regularização L2 não trouxe ganhos expressivos para o problema estudado. Esse comportamento pode ser explicado pela boa qualidade do dataset, ausência de inconsistências e forte linearidade entre os atributos e a variável-alvo.

Já o modelo Lasso apresentou leve redução de desempenho, obtendo $R^2 = 0,905$, resultado ainda considerado elevado. A pequena redução pode ser atribuída à característica do método de simplificar o modelo por meio da penalização L1, reduzindo a influência de algumas variáveis potencialmente relevantes. A análise da regressão linear simples mostrou que a variável altura total (altura_total) apresentou forte influência sobre a carga de aquecimento, sendo capaz de explicar aproximadamente 79,2% da variabilidade da variável-alvo, mesmo quando utilizada isoladamente.

Além disso, os coeficientes do modelo Lasso reforçaram a relevância de atributos relacionados às características estruturais dos edifícios, especialmente altura total e área envidraçada, demonstrando forte relação com o desempenho energético.

De maneira geral, os resultados obtidos evidenciam que o problema analisado apresenta forte comportamento linear, favorecendo modelos clássicos de regressão e reduzindo a necessidade de técnicas mais complexas de regularização.

4. Conclusões

Os modelos implementados apresentaram desempenho elevado na previsão da variável carga de aquecimento (*carga_aqueci*), com destaque para a Regressão Linear, que obteve $R^2 = 0,912$, demonstrando elevada capacidade de explicação da variabilidade dos dados. O modelo Ridge apresentou desempenho praticamente equivalente, indicando baixa necessidade de regularização, enquanto o modelo Lasso apresentou leve redução de desempenho, embora ainda tenha mantido resultados considerados satisfatórios.

A aplicação da validação cruzada reforçou a robustez dos modelos, evidenciando boa capacidade de generalização e baixa ocorrência de *overfitting*, uma vez que os resultados permaneceram consistentes entre diferentes divisões dos dados.

Além disso, a análise dos atributos permitiu identificar altura total (*altura_total*) como uma das variáveis mais relevantes para previsão da carga de aquecimento, fato confirmado tanto pela matriz de correlação quanto pela regressão linear simples, que conseguiu explicar aproximadamente 79,2% da variabilidade da variável-alvo utilizando apenas um atributo.

5. Próximos passos

Como próximo passo, recomenda-se a utilização da segunda variável-alvo do dataset, carga de resfriamento (*carga_resfria*), permitindo uma análise comparativa entre os fatores que influenciam os sistemas de aquecimento e resfriamento das edificações. Essa abordagem possibilitaria uma compreensão mais ampla do desempenho energético dos edifícios.

Outro possível avanço seria a realização de uma análise mais aprofundada de engenharia de atributos (*feature engineering*), investigando combinações entre variáveis estruturais e energéticas que possam melhorar o desempenho preditivo dos modelos.