

**TECHNICAL REPORT**

Aluno: Jose Nivaldo Matos Castro Filho

Aluno: Jefte Damaceno

1. Introdução

Sobre o dataset: O conjunto de dados Online Retail do UCI Machine Learning Repository é um recurso amplamente utilizado para análise de transações de comércio eletrônico. Ele contém informações detalhadas sobre compras realizadas entre 1º de dezembro de 2010 e 9 de dezembro de 2011 por uma varejista online do Reino Unido, especializada em presentes para todas as ocasiões. Características do Conjunto de Dados: Instâncias: 541.909 transações, Atributos: 8 variáveis, Esse dataset possui muitas variáveis categóricas e alguns valores nulos

Nome da Variável	Tipo	Descrição
InvoiceNo	Categórica	Número da fatura (se começar com 'c', indica cancelamento)
StockCode	Categórica	Código do produto (5 dígitos)
Description	Categórica	Nome do produto
Quantity	Numérica	Quantidade do produto por transação
InvoiceDate	Data	Data e hora da transação
UnitPrice	Numérica	Preço unitário do produto em libras esterlinas
CustomerID	Categórica	Número do cliente
Country	Categórica	País de residência do cliente

2. Observações

Um problema encontrado no dataset é a ausência de uma variável alvo, assim criando um empecilho na hora de escolher a variável alvo para um modelo supervisionado.



3. Resultados e discussão

Questão 1 - Análise Exploratória com Foco em Redução de Complexidade

O processo se inicia com o carregamento dos dados originais, armazenados em um arquivo Excel. Em seguida, aplica-se uma etapa de limpeza: são removidas todas as transações que não possuem identificação de cliente (CustomerID), bem como aquelas que registram quantidades ou preços unitários iguais ou inferiores a zero. Essa filtragem garante que a análise posterior considere apenas vendas válidas, feitas por clientes reais. Após a limpeza, os dados são agregados por cliente. Para cada cliente único, são calculadas as seguintes informações:

O número total de compras realizadas;

A quantidade total de itens adquiridos;

O preço médio pago por produto;

A data da primeira compra registrada;

A data da última compra registrada;

O país de origem do cliente.

A partir da data da última compra de cada cliente, calcula-se também uma variável chamada Recência, que representa quantos dias se passaram desde essa última compra até a data mais recente presente no conjunto de dados. Essa métrica é útil para entender o quão ativo o cliente ainda é.

Com os dados agregados por cliente, são calculadas estatísticas descritivas para quatro variáveis-chave: número de compras, total de itens adquiridos, preço médio e recência. As medidas calculadas incluem média, desvio padrão, valores mínimos, máximos e quartis. Essas informações são impressas na tela e também salvas em um arquivo CSV, que pode ser utilizado posteriormente em relatórios.

Em seguida, são criados gráficos para facilitar a visualização dos dados. Um histograma mostra a distribuição das variáveis analisadas, revelando padrões como concentração, dispersão e presença de outliers. Além disso, é construída uma matriz de correlação, representada por um mapa de calor, que permite identificar relações lineares entre as variáveis. Por exemplo, se clientes que compram mais vezes também tendem a adquirir mais itens, isso se refletirá em uma correlação positiva entre essas duas variáveis.

Por fim, o arquivo conclui que, devido à diferença de escalas entre as variáveis (como preço médio e número de compras), será necessário padronizá-las antes da aplicação de técnicas como PCA (Análise de Componentes Principais) ou algoritmos de clusterização. Essa padronização garantirá que nenhuma variável exerça influência desproporcional sobre os resultados

Sobre a estatística descritiva temos os seguintes resultados

```
=== Estatísticas Descritivas ===
```

	NumCompras	TotalItens	PrecoMedio	Recencia
count	4338.000000	4338.000000	4338.000000	4338.000000
mean	4.272015	1191.289073	4.467773	91.536422
std	7.697998	5046.081546	34.211451	100.014169
min	1.000000	1.000000	0.122500	0.000000
25%	1.000000	160.000000	2.203728	17.000000
50%	2.000000	379.000000	2.917611	50.000000
75%	5.000000	992.750000	3.829784	141.000000
max	209.000000	196915.000000	2033.100000	373.000000

1. Histogramas das Variáveis Numéricas

Os três gráficos à esquerda (superior e inferior) são histogramas que mostram a distribuição de frequência das seguintes variáveis:

- NumCompras (Número de Compras por Cliente)

A maioria dos clientes realizou poucas compras.

Há uma forte concentração próxima a valores baixos (entre 1 e 10).

Poucos clientes realizaram muitas compras, o que gera uma distribuição assimétrica à direita (com cauda longa).

- TotalItens (Total de Itens Comprados)

Comportamento semelhante: muitos clientes compraram poucos itens no total.

Há casos extremos com mais de 150.000 itens, indicando outliers importantes que podem distorcer a média.

A escala é bastante ampla e a cauda longa mostra que existem poucos clientes muito ativos.

- PrecoMedio (Preço Médio por Item)

A maioria dos clientes comprou produtos com preços unitários baixos.

Embora a maioria esteja entre R\$0 e R\$20, existem alguns preços acima de R\$1.000 e até R\$2.000.


Isso também indica assimetria à direita e presença de outliers.

! *Conclusão sobre os histogramas:*

Todas as variáveis possuem distribuições assimétricas, com concentração em valores baixos e presença de valores extremos (outliers). A partir disso, utilizamos resolvemos utilizar Padronização.

- 2. Matriz de Correlação (Heatmap)

A correlação mede a força da relação linear entre duas variáveis, variando entre -1 (correlação negativa perfeita) e 1 (positiva perfeita).



Questão 2 - Redução de Dimensionalidade Múltipla: PCA vs T-SNE

Nessa questão o foco é aplicar técnicas de redução de dimensionalidade para facilitar a visualização e posterior análise dos dados dos clientes. A ideia é transformar os dados originais — compostos por várias variáveis — em uma representação com apenas duas dimensões, preservando ao máximo as informações relevantes.

O processo começa com a preparação dos dados. São selecionadas quatro variáveis principais para análise:

- Número de compras realizadas por cliente,
- Quantidade total de itens adquiridos,
- Preço médio por produto,
- Recência da última compra.

Como essas variáveis estão em escalas diferentes (por exemplo, preço médio pode variar de poucos centavos a centenas, enquanto número de compras pode ser apenas alguns dígitos), realiza-se uma padronização. Essa padronização transforma todas as variáveis para uma escala comum com média zero e desvio padrão igual a um, usando o método `StandardScaler`. Isso é essencial para que nenhuma variável tenha mais influência que as outras nas análises subsequentes.

Após a padronização, são aplicadas duas técnicas distintas de redução de dimensionalidade:

1. PCA (Análise de Componentes Principais)

O PCA é uma técnica estatística que transforma os dados em novas variáveis (componentes principais), que são combinações lineares das variáveis originais. O objetivo é preservar ao máximo a variância dos dados — ou seja, manter o maior conteúdo de informação possível com menos dimensões.

Nesse caso, os dados padronizados são reduzidos para duas dimensões principais, e um gráfico de dispersão (scatter plot) é gerado com os dois primeiros componentes. Cada ponto no gráfico representa um cliente, posicionado conforme suas características mais relevantes resumidas nesses dois eixos principais. Isso permite observar padrões gerais de dispersão e possíveis agrupamentos.

2. T-SNE (t-distributed Stochastic Neighbor Embedding)

A segunda técnica utilizada é o T-SNE, que é especialmente eficaz para visualizar agrupamentos locais e relações de vizinhança entre os pontos. Diferente do PCA, o T-SNE não busca preservar a variância global, mas sim representar com fidelidade quais pontos estão próximos uns dos outros no espaço original de múltiplas dimensões.

O T-SNE também reduz os dados para duas dimensões, e outro gráfico de dispersão é criado. Nele, espera-se visualizar agrupamentos mais definidos e contornos que indicam clientes com perfis de comportamento semelhantes, mesmo que o método não seja adequado para análises quantitativas diretas.

Comparativo entre PCA e T-SNE

Ao final, o arquivo destaca uma observação importante:

O PCA é útil para identificar variabilidade global nos dados.

O T-SNE é mais eficaz para revelar estruturas locais, como agrupamentos naturais de clientes.

Ambas as técnicas são valiosas em contextos diferentes. Aqui, elas são utilizadas principalmente para preparar os dados para etapas futuras de clusterização e para gerar gráficos que auxiliem na interpretação visual do comportamento dos clientes


Em relação aos gráficos obtidos

No primeiro gráfico o eixo X representa o primeiro componente principal (PC1) e o eixo Y o segundo componente (PC2).

A maior parte dos dados está concentrada próxima à origem, o que indica que muitos clientes têm características semelhantes (baixo número de compras, itens e recência).

Existem alguns pontos muito distantes dos demais (outliers), localizados à direita ou no alto, que representam clientes com comportamentos bem distintos (ex: compram muito, com preços elevados, ou compraram há muito tempo).


O gráfico é pouco estruturado visualmente, ou seja, não mostra agrupamentos claros. Isso é comum em PCA quando os dados têm alta assimetria e outliers, como é o seu caso.



No segundo gráfico mostra que cada ponto representa um cliente, e a distribuição mostra formas de "braços" ou grupos alongados, sugerindo a existência de subgrupos com características parecidas.

Diferente do PCA, aqui vemos uma estrutura visivelmente mais segmentada, o que é uma excelente pista para aplicar algoritmos de clusterização (como K-Means ou Hierárquico).

A distribuição nos eixos X e Y não tem interpretação direta, pois o T-SNE não preserva a escala original — os eixos apenas servem para visualização relativa.



Para uma Comparação mais resumida

Aspecto	PCA	T-SNE
Preserva variância global	Sim	Não
Preserva agrupamentos locais	Parcialmente	Sim (muito bem)
Sensível a outliers	Sim (impacta fortemente)	Menos sensível
Interpretação dos eixos	Tem significado matemático	Não tem significado direto
Visualização de clusters	Pouco clara	Muito mais clara e segmentada

Questão 3 - Clusterização com K-Means e Hierárquico

O objetivo é comparar técnicas de clusterização (agrupamento de clientes) usando os dados padronizados. A ideia central é segmentar os clientes com base em seus comportamentos e visualizar os resultados de forma clara.

O código começa testando o algoritmo K-Means para diferentes números de clusters, variando de 2 até 9 grupos.

Para cada valor de k (quantidade de clusters), dois indicadores são calculados:

Inércia: mede o quão próximos os dados estão do centro do cluster. Quanto menor, melhor.

Silhouette Score: avalia a qualidade do agrupamento, considerando a separação entre os grupos e a coesão interna. Quanto mais próximo de 1, melhor.

Em seguida, dois gráficos são gerados:

O gráfico do cotovelo (inércia × número de clusters) ajuda a identificar o ponto em que



adicionar mais clusters não melhora muito a compactação dos grupos.

O gráfico do silhouette score mostra em qual valor de k a separação entre os grupos é mais eficiente.

Com base nesses resultados, o valor de k que obtém o melhor silhouette score é escolhido como o número ideal de clusters.

Depois de definido o valor ótimo de k , o K-Means é aplicado aos dados padronizados para gerar os rótulos de cluster de cada cliente. Cada cliente é então classificado em um dos k grupos.

O código também aplica uma segunda abordagem: a clusterização hierárquica, que constrói uma árvore de relações (dendrograma) entre os clientes com base na semelhança entre eles.

Dois métodos de ligação são utilizados:

Average: usa a média das distâncias entre os pontos dos grupos.

Complete: considera a maior distância entre pontos de grupos diferentes.

São gerados dois dendrogramas que ilustram como os clusters são formados em cada método.

Para fins de comparação justa com o K-Means, o número de grupos formados na clusterização hierárquica é forçado a ser igual ao k_{best} definido anteriormente.

Os rótulos (labels) gerados por cada técnica (K-Means, Hierárquico Average e Complete) são avaliados usando o Silhouette Score, permitindo medir e comparar a qualidade dos agrupamentos.

Isso mostra qual técnica produziu grupos mais coesos e bem separados.

Por fim, os dados são reduzidos para 2 dimensões usando o PCA (somente para fins de visualização), e é criado um gráfico de dispersão com três subgráficos:

K-Means: mostra os clientes coloridos por grupo segundo o K-Means.

Hierárquico Average: mostra os grupos criados por esse método.

Hierárquico Complete: mostra os grupos usando ligação complete.

Cada gráfico inclui também o valor do Silhouette Score, ajudando a comparar visualmente a eficácia de cada método.

Sobre os resultados obtidos temos

Gráfico da Esquerda: Cotovelo (Inércia $\times$ Número de Clusters)

Eixo X: Número de clusters testados (de 2 a 9).

Eixo Y: Valor da inércia (soma das distâncias dos pontos ao centro do cluster).

O que significa:

A inércia diminui à medida que o número de clusters aumenta (isso é esperado).

O ponto ideal é onde a curva "faz um cotovelo", ou seja, a partir de onde adicionar mais clusters não reduz significativamente a inércia.

No gráfico, a "quebra" ocorre por volta de $k = 4$, indicando que ali a melhora começa a se estabilizar.



Gráfico da Direita: Silhouette Score × Número de Clusters


Eixo X: Número de clusters (2 a 9).

Eixo Y: Silhouette Score, que mede a qualidade do agrupamento:

Varia de -1 a 1;

Quanto mais próximo de 1, melhor a separação entre os grupos.

O que significa:

O maior Silhouette Score ocorre com $k = 2$ (cerca de 0.9), o que indica excelente separação entre os dois grupos.A partir de $k = 3$ em diante, o score cai consideravelmente, ficando entre 0.58 e 0.60, sugerindo que adicionar mais grupos reduz a qualidade da separação.Em $k = 9$, o Silhouette Score chega a ~ 0.48 , indicando agrupamentos mais confusos e menos coesos.

Ideal pelo Silhouette Score: 2

Interpretação do gráfico da esquerda: Dendrograma - Average

Average linkage: A distância entre dois clusters é calculada como a média das distâncias entre todos os pares de pontos (um de cada cluster).


Aqui, você pode ver que os clientes com os IDs 4013, 1689, 326, e 1879 foram agrupados tardiamente — ou seja, são mais distintos dos outros clientes.

A linha azul representa o último agrupamento (o mais distante), indicando onde você cortaria o dendrograma para decidir quantos clusters ter.

Interpretação do gráfico da direita: Dendrograma - Complete

Complete linkage: Usa a maior distância entre pares de pontos de dois clusters.

O padrão geral é similar ao Average, mas com pequenas diferenças nas alturas das fusões.

A estrutura geral sugere também que dois grupos principais estão sendo formados, o que confirma o resultado do K-Means com $k=2$.

Interpretação dos gráficos:

1. K-Means (k=2)

Silhouette: 0.90

Os dados foram agrupados em dois clusters (amarelo e roxo).

A separação é clara, com uma zona bem definida entre os dois grupos.

Silhouette de 0.90 é muito boa, indicando que os pontos estão bem agrupados e afastados entre os clusters.

2. Hierárquico Average (k=2)

Silhouette: 0.97

Agrupamento ainda mais bem definido, com melhor separação entre os pontos.

Silhouette de 0.97 mostra que o agrupamento foi muito coeso — uma das melhores situações possíveis.


3. Hierárquico Complete (k=2)

Silhouette: 0.97 (mesmo valor do anterior)

Também obteve dois clusters bem definidos.

A estrutura visual é parecida com o método average, com leves variações.

Mostra que o método complete também foi altamente eficiente nesse caso.



A aplicação de diferentes métodos de clusterização (K-Means, Hierárquico Average e Complete) com $k=2$ revelou uma estrutura de agrupamento bem definida no conjunto de dados. O coeficiente de Silhouette para os métodos hierárquicos (0.97) foi superior ao do K-Means (0.90), indicando maior coesão e separação entre os grupos. A semelhança visual dos clusters gerados por todos os métodos corrobora a presença de dois perfis distintos de clientes, o que pode ser explorado estrategicamente nas análises posteriores.

Questão 4 - Interpretação Semântica dos Agrupamentos

Após a aplicação do algoritmo de agrupamento (clustering), cada cliente do conjunto de dados foi atribuído a um grupo específico, chamado de *cluster*. O objetivo dessa etapa foi entender os diferentes perfis de comportamento entre os clientes com base em variáveis como número de compras, total de itens adquiridos, valor médio dos produtos comprados e tempo desde a última compra (recência).

Cada cliente foi classificado em um dos clusters formados pelo algoritmo. Essa informação foi incorporada ao conjunto de dados principal, o que permite agora realizar análises comparativas entre os diferentes grupos.

Médias das Variáveis por Cluster

Foi calculada a média de quatro variáveis principais para cada grupo de clientes:

Número de Compras: indica a frequência com que os clientes realizam compras. Total de Itens: representa o volume total de produtos adquiridos. Preço Médio: corresponde ao valor médio pago por item. Recência: mostra há quanto tempo o cliente fez a última compra (quanto menor, mais recente).

Essas médias servem como um "resumo do comportamento" típico de cada grupo. Por exemplo, um grupo com alta frequência de compras, muitos itens por compra, valor médio alto e compras recentes representa um perfil de cliente mais ativo e valioso. Por outro lado, um grupo com baixa frequência de compra e alta recência pode representar clientes inativos ou de baixo engajamento.

Análise Visual com Boxplot

Foi criado um gráfico do tipo boxplot (diagrama de caixa) para visualizar como o número de compras varia dentro de cada grupo. Essa visualização permite observar:

A mediana de compras por cluster.


A dispersão (clientes que comprem mais ou menos do que o típico do grupo).

A existência de outliers (clientes com comportamento muito diferente da média).

Esse gráfico ajuda a identificar se há muita variação de comportamento dentro de um mesmo cluster, o que pode influenciar na forma como se lida com cada grupo.

Gráfico Comparativo de Médias

Também foi criado um gráfico de barras para comparar, de forma direta, as médias das quatro variáveis entre os clusters. Essa visualização facilita a interpretação de qual grupo é mais ativo, qual tem maior valor de compra, qual realiza mais compras ou qual está mais distante da última transação.



Questão 5 - T-SNE ou PCA como Pré-processamento para Classificação

O objetivo dessa etapa foi avaliar a capacidade de classificação dos clientes em seus respectivos grupos (clusters) com base em suas características, utilizando técnicas de aprendizado supervisionado. Embora os grupos tenham sido criados por um modelo não supervisionado (clustering), eles foram reaproveitados como rótulos-alvo (pseudo-labels) para treinar e testar um modelo preditivo.

A variável Alvo foi criada a partir da coluna Cluster, atribuída anteriormente a cada cliente. Essa coluna passa a representar a "classe" que o modelo supervisionado tentará prever.

Foi utilizado o algoritmo Random Forest Classifier, que é um modelo robusto e amplamente utilizado para tarefas de classificação. Três cenários foram avaliados:

Cenário 1: Dados sem Redução de Dimensionalidade

Dados utilizados: Todas as variáveis padronizadas (versão `X_scaled`).

Resultado esperado: Esse cenário serve como referência para comparar o desempenho com e sem técnicas de redução de dimensionalidade.

Avaliação: O modelo foi treinado e testado utilizando os dados originais (mas padronizados), e os resultados foram apresentados através de métricas como precisão, recall, f1-score e acurácia.

Cenário 2: Com Redução via PCA (Principal Component Analysis)

Dados utilizados: Componentes principais (`X_pca`) obtidos via PCA.

Objetivo: Verificar se o uso de PCA melhora ou reduz o desempenho do classificador, ao simplificar o conjunto de dados eliminando variáveis redundantes ou menos informativas.

Resultado esperado: Em muitos casos, o PCA pode ajudar a reduzir ruído e melhorar a generalização do modelo.

Cenário 3: Com Redução via T-SNE (t-Distributed Stochastic Neighbor Embedding)

Dados utilizados: Versão reduzida dos dados com T-SNE (`X_tsne`).

Observação: O T-SNE é geralmente utilizado apenas para visualização de dados de alta dimensão, e não é ideal para classificação, pois não preserva distâncias globais e pode distorcer a estrutura dos dados.

Objetivo aqui: Apenas uma comparação exploratória, para avaliar se o modelo ainda consegue aprender algo útil a partir dos dados transformados via T-SNE.

Esse experimento mostrou como é possível utilizar as estruturas reveladas por clusterização como base para construir um modelo supervisionado, e ainda comparar o desempenho em diferentes formas de representação dos dados:

Sem redução (modelo mais completo),

Com PCA (modelo mais leve e eficiente),

E com T-SNE (modelo apenas exploratório).



Caso 1

Classe	Precision	Recall	F1-Score	Support
	01.00	1.00	1.00	1091
	11.00	1.00	1.00	211

Caso 2

Classe	Precision	Recall	F1-Score	Support
	00.96	0.95	0.95	1091
	10.76	0.78	0.77	211

Caso 3

Classe	Precision	Recall	F1-Score	Support
	00.98	0.99	0.98	1091
	0.94	0.88	0.91	211

4. Conclusões

os resultados foram bastante satisfatórios mesmo com as dificuldades com o dataset, porque o pipeline completo — desde análise até modelo final — foi bem construído. Os dados foram tratados com cuidado e as variáveis criadas foram bem pensadas. Os modelos apresentaram desempenho muito alto mesmo com redução de dimensão, o que mostra que os padrões nos dados são fortes e bem definidos. O uso de diferentes técnicas (padronização, PCA, t-SNE) permitiu comparar cenários e verificar que os dados possuem estrutura que pode ser capturada por modelos supervisionados com alta precisão. os resultados foram bastante satisfatórios, porque o pipeline completo — desde análise até modelo final — foi bem construído. Os dados foram tratados com cuidado e as variáveis criadas foram bem pensadas. Os modelos apresentaram desempenho muito alto mesmo com redução de dimensão, o que mostra que os padrões nos dados são fortes e bem definidos. O uso de diferentes técnicas (normalização, PCA, t-SNE) permitiu comparar cenários e verificar que os dados possuem estrutura que pode ser capturada por modelossupervisionados com alta precisão.