



TECHNICAL REPORT

Aluno(a): Elyson Caique Alves Brito

Aluno(a): Maria de Fátima Brandão de Andrade

1. Introdução

Neste projeto foi desenvolvido um pipeline completo de regressão utilizando técnicas de aprendizado de máquina supervisionado. O principal objetivo foi analisar o desempenho de diferentes modelos de regressão para prever a temperatura do ambiente utilizando informações relacionadas à qualidade do ar.

Os modelos utilizados foram:

- *Regressão Linear*
- *Ridge Regression*
- *Lasso Regression*

O dataset utilizado foi o Air Quality, disponível na UCI Machine Learning Repository. Esse conjunto de dados contém medições de sensores químicos responsáveis por monitorar gases e variáveis ambientais em uma cidade da Itália.

O dataset possui informações como:

- *concentração de CO*
- *concentração de NOx*
- *concentração de NO2*
- *umidade relativa*
- *umidade absoluta*
- *respostas de sensores químicos*
- *temperatura*

O objetivo do projeto foi prever a variável temperatura (T) utilizando os demais atributos do dataset.

Além da construção dos modelos, também foram realizados:

- *análise exploratória dos dados*
- *tratamento de valores inconsistentes*
- *análise de correlação*
- *normalização dos atributos*

- *validação cruzada*
- *busca de hiperparâmetros com Grid Search*
- *comparação crítica entre os modelos*

Todo o projeto foi implementado em arquivo .py, conforme solicitado na atividade.

2. Observações

Durante o desenvolvimento do projeto não ocorreram problemas relevantes que comprometessem os resultados obtidos.

3. Resultados e discussão

3.1 Exploração Inicial do Dataset

Inicialmente foi realizada uma análise exploratória do conjunto de dados para entender sua estrutura e características principais.

O dataset apresentou:

- *9357 instâncias*
- *15 atributos*
- *variáveis numéricas e textuais*

As colunas Date e Time foram mantidas apenas para inspeção inicial e posteriormente removidas do treinamento, já que os modelos utilizados trabalham melhor com atributos numéricos.

Também foram analisadas estatísticas como:

- *média*
- *desvio padrão*
- *valores mínimos e máximos*

Essa etapa foi importante para compreender o comportamento geral dos dados antes do treinamento dos modelos.

3.2 Tratamento dos Dados

Durante a análise foi identificado que o dataset utilizava o valor -200 para representar dados ausentes.

Isso foi percebido porque vários atributos apresentavam médias extremamente negativas, o que não fazia sentido para variáveis como temperatura e umidade.

Por exemplo:

- *temperatura mínima igual a -200*

- *umidade mínima igual a -200*

Esses valores não representam medições reais.

*Por isso, os valores **-200** foram substituídos por **NaN**. Em seguida, os dados ausentes foram preenchidos utilizando a média de cada coluna.*

Esse tratamento foi essencial para evitar que os modelos aprendessem padrões incorretos.


Também foi realizada verificação de linhas duplicadas, mas nenhuma duplicata foi encontrada.

*Além disso, foi observado que a variável **NMHC(GT)** possuía uma quantidade muito elevada de valores ausentes. Mesmo assim, optou-se por manter essa variável após o preenchimento pela média para preservar as informações originais do dataset*

3.3 Análise de Correlação

Após o tratamento dos dados foi realizada a análise de correlação entre os atributos.

A Figura 1 apresenta o mapa de correlação gerado durante o projeto.



A análise mostrou que algumas variáveis possuem forte relação com a temperatura.

Os principais resultados foram:

- **AH** apresentou correlação positiva forte com temperatura
- **RH** apresentou correlação negativa considerável
- **PT08.S4(NO2)** também apresentou relação relevante

*A variável **AH** (umidade absoluta) apresentou uma das maiores correlações positivas com a temperatura, indicando que conforme a temperatura aumenta, a umidade absoluta tende a aumentar também.*

*Já a variável **RH** (umidade relativa) apresentou correlação negativa, indicando comportamento inverso em relação à temperatura.*

Essa análise foi importante porque ajudou a entender quais atributos influenciam mais a variável alvo.

3.4 Pré-processamento

Após a separação entre atributos de entrada e variável alvo, foi aplicada a normalização Min-Max.

A normalização transforma os valores para uma escala entre 0 e 1.

Esse processo foi importante principalmente para os modelos Ridge e Lasso, já que esses algoritmos utilizam penalizações nos coeficientes e podem ser influenciados pela escala dos atributos.

A variável alvo escolhida foi:

- **T (Temperatura)**

Os atributos utilizados no treinamento foram os demais atributos numéricos do dataset.

3.5 Treinamento dos Modelos

Os dados foram divididos em:

- 80% para treino
- 20% para teste

Em seguida foram treinados os modelos:

- Regressão Linear

- Ridge Regression
- Lasso Regression

As métricas utilizadas para avaliação foram:

- MAE
- MSE
- RMSE
- R^2

3.6 Resultados dos Modelos

3.6.1 Regressão Linear

A Regressão Linear apresentou os seguintes resultados:

- $MAE = 1.6735$
- $MSE = 5.1157$
- $RMSE = 2.2618$
- $R^2 = 0.9332$

O valor de R^2 próximo de 1 indica que o modelo conseguiu explicar grande parte da variabilidade da temperatura.

Isso mostra que existe uma relação linear significativa entre os atributos e a variável alvo.

Além disso, os baixos valores de erro indicam que as previsões realizadas ficaram próximas dos valores reais.

3.6.2 Ridge Regression

O modelo Ridge apresentou:

- $MAE = 1.6672$
- $MSE = 5.1374$
- $RMSE = 2.2666$
- $R^2 = 0.9329$

Os resultados foram muito próximos aos da regressão linear tradicional.

A principal diferença é que o Ridge adiciona uma penalização aos coeficientes do modelo, reduzindo possíveis problemas de multicolinearidade.

Mesmo sem alterar drasticamente os resultados, o Ridge tornou o modelo mais estável.

3.6.3 Lasso Regression

O modelo Lasso apresentou:

$MAE = 1.6857$

$MSE = 6.3889$

$RMSE = 2.5276$

$$R^2 = 0.9166$$

O desempenho foi um pouco inferior em comparação aos outros modelos.


Isso pode ter ocorrido porque o Lasso reduz alguns coeficientes para zero, removendo parte das informações utilizadas pelo modelo.

Mesmo com uma pequena perda de desempenho, o Lasso possui vantagem na seleção automática de atributos e na simplificação do modelo .

3.7 Regressão Linear Simples

*Também foi realizada uma regressão linear simples utilizando apenas o atributo **AH**.*

A Figura 2 mostra o gráfico gerado.



Os resultados obtidos foram:

- $MAE = 5.1348$
- $MSE = 43.1078$
- $RMSE = 6.5657$
- $R^2 = 0.4372$

O desempenho foi significativamente inferior em relação aos modelos multivariados.

Isso mostra que utilizar apenas um atributo não é suficiente para explicar adequadamente a temperatura.

Apesar disso, o gráfico mostra uma tendência linear positiva entre AH e temperatura.

3.8 Validação Cruzada

Foi aplicada validação cruzada com 5 folds para avaliar a robustez dos modelos.

As médias de R^2 foram:

- *Linear Regression* = 0.7172
- *Ridge Regression* = 0.7250
- *Lasso Regression* = 0.6993

Os resultados mostraram que o Ridge apresentou a melhor média geral.

Também foi possível perceber que os resultados da validação cruzada ficaram menores do que os obtidos na divisão treino/teste tradicional.

Isso acontece porque a validação cruzada realiza múltiplas divisões do dataset, fornecendo uma avaliação mais rigorosa e menos otimista do desempenho dos modelos.

A validação cruzada foi importante porque reduz a dependência de apenas uma única divisão dos dados.

3.9 Grid Search

Também foi utilizado Grid Search para encontrar os melhores hiperparâmetros.

Os melhores valores encontrados foram:

- *Ridge*: $\alpha = 10$
- *Lasso*: $\alpha = 0.01$

A utilização do Grid Search permitiu encontrar configurações mais adequadas para os modelos regularizados.

Além disso, foi possível perceber que pequenos ajustes no parâmetro α influenciam diretamente o desempenho dos modelos.

4. Conclusões

Os resultados obtidos foram satisfatórios e atenderam aos objetivos propostos pela atividade.

A Regressão Linear apresentou excelente desempenho na previsão da temperatura, mostrando que existe uma forte relação linear entre os atributos do dataset e a variável alvo.

O modelo Ridge apresentou desempenho semelhante, porém com maior estabilidade devido à regularização aplicada aos coeficientes.

Já o Lasso apresentou desempenho um pouco inferior, mas contribuiu para simplificar o modelo e reduzir a influência de atributos menos importantes.



Outro ponto importante foi perceber como o pré-processamento influencia diretamente o desempenho dos modelos. O tratamento dos valores -200 foi essencial para evitar distorções nos resultados.

A análise de correlação também ajudou bastante na compreensão dos dados, principalmente para identificar atributos mais relacionados à temperatura.

Além disso, a regressão linear simples mostrou que utilizar apenas um único atributo reduz significativamente a capacidade de previsão do modelo.

A validação cruzada mostrou resultados mais rigorosos do que a divisão treino/teste tradicional, permitindo uma avaliação mais confiável dos modelos.

De forma geral, o projeto permitiu compreender não apenas a execução dos algoritmos, mas também a importância de cada etapa do pipeline de aprendizado de máquina.

5. Próximos passos

Como continuidade do projeto, alguns próximos passos interessantes seriam:

- *testar outros algoritmos de regressão*
- *utilizar técnicas mais avançadas de tratamento de dados*
- *realizar seleção automática de atributos*
- *testar diferentes técnicas de normalização*
- *analisar possíveis outliers*
- *utilizar modelos não lineares*
- *criar visualizações mais detalhadas*

Também seria interessante comparar modelos baseados em árvores, como Random Forest Regressor e XGBoost, para verificar se conseguem melhorar ainda mais os resultados obtidos.