

TECHNICAL REPORT

Aluno: Kevin Emmanuel Sousa Pontes

1. Introdução

O dataset Heart Disease é uma base de dados clássica para a previsão de doença cardíaca com base nos resultados de uma série de exames associados. Foram coletados dados de 303 pacientes da cidade de Cleveland, EUA, para compor o dataset. Por mais que outras amostras em diferentes cidades tenham sido coletadas, a escolha da base de Cleveland se deve ao fato de ser a base mais explorada e testada pelos cientistas de dados. Seguem abaixo os campos que a base possui.


Sexo	Resultado ECG	Resultado Talassemia	Frequência cardíaca máxima
Idade	Tipo de dor no peito	Pressão arterial	Colesterol sérico
Angina induzida por exercício	Depressão ST por exercício	Inclinação do pico ST	N* de vasos principais coloridos

Além destes um campo informando o grau de doença cardíaca: (0-4), sendo 0 saudável.

2. Observações

Foi constatada uma distribuição desbalanceada da variável alvo, com alguns grupos tendo pouquíssimas observações, o que prejudica muito a performance do modelo adotado na pesquisa. Em razão disso, optamos por binarizar o alvo, simplificando da escala (0-4) para (0-1), onde 1 agora representa todas as classes (1-4). Isso nos permite responder a questão mais fundamental - presença de doença - mas limita a avaliação do grau da mesma.

Após a transformação, os grupos 0 e 1 ficaram respectivamente com 164 e 139 elementos.



3. Resultados e discussão

3.1 Análise exploratória

A análise exploratória teve como objetivo compreender a estrutura, distribuição e qualidade dos dados antes de qualquer etapa de modelagem. O dataset Heart Disease possui 13 variáveis preditoras, que já foram apresentadas na introdução.

Estatísticas Descritivas

A inspeção das estatísticas descritivas revelou dois pontos de atenção. Primeiro, a variável *chol* (colesterol sérico) apresentou valor máximo de 564, muito acima do terceiro quartil, indicando a presença de outlier. Segundo, a variável *target* apresentou mediana 0 com média 0,94, confirmando dominância da classe saudável no conjunto original.


	count	mean	std	min	25%	50%	75%	max
age	303.0	54.438944	9.038662	29.0	48.0	56.0	61.0	77.0
sex	303.0	0.679868	0.467299	0.0	0.0	1.0	1.0	1.0
cp	303.0	3.158416	0.960126	1.0	3.0	3.0	4.0	4.0
trestbps	303.0	131.689769	17.599748	94.0	120.0	130.0	140.0	200.0
chol	303.0	246.693069	51.776918	126.0	211.0	241.0	275.0	564.0
fbs	303.0	0.148515	0.356198	0.0	0.0	0.0	0.0	1.0
restecg	303.0	0.990099	0.994971	0.0	0.0	1.0	2.0	2.0
thalach	303.0	149.607261	22.875003	71.0	133.5	153.0	166.0	202.0
exang	303.0	0.326733	0.469794	0.0	0.0	0.0	1.0	1.0
oldpeak	303.0	1.039604	1.161075	0.0	0.0	0.8	1.6	6.2
slope	303.0	1.600660	0.616226	1.0	1.0	2.0	2.0	3.0
ca	299.0	0.672241	0.937438	0.0	0.0	0.0	1.0	3.0
thal	301.0	4.734219	1.939706	3.0	3.0	3.0	7.0	7.0
target	303.0	0.937294	1.228536	0.0	0.0	0.0	2.0	4.0

Valores Ausentes

A verificação de valores ausentes identificou valores ausentes nas variáveis *ca* (número de vasos principais coloridos), 4 ausentes e *thal* (talassemia, 2 ausentes). A estratégia de tratamento adotada foi a imputação pela moda, realizada dentro do pipeline de modelagem para que o valor de imputação fosse calculado exclusivamente a partir do conjunto de treino e aplicado ao teste, evitando data leakage. O detalhamento desta etapa é apresentado na seção de pré-processamento.


Outliers nas Variáveis Contínuas

Os boxplots das variáveis contínuas (*age*, *trestbps*, *chol*, *thalach* e *oldpeak*) confirmaram a presença de pontos fora dos limites interquartis, especialmente em *chol* e *trestbps*. Por se tratarem de dados clínicos confiáveis, optou-se por manter esses valores e mitigar seu impacto por meio de transformações e normalização, posteriormente realizadas.



Distribuição das Variáveis Categóricas por Target


Para as variáveis categóricas (*sex*, *cp*, *fbs*, *restecg*, *exang*, *slope*, *ca* e *thal*), foram gerados countplots estratificados pela variável alvo binária, permitindo identificar visualmente quais categorias se associam mais fortemente à presença de doença cardíaca.



Por mais que claras relações possam ser observadas como nas variáveis x e x , essa observação foi tratada apenas de forma exploratória, e a seleção das variáveis mais importantes foi realizada exclusivamente por meio dos valores de correlação linear identificados na próxima seção.


Distribuição das Variáveis Contínuas

Os histogramas com curvas de densidade das variáveis contínuas evidenciaram assimetrias em algumas distribuições, notadamente em *oldpeak* e *chol*, com cauda à direita. Essas assimetrias motivam diretamente as transformações logarítmicas e de potência aplicadas no pré-processamento, na tentativa de mitigar os valores extremos sem removê-los diretamente.



3.2 Seleção de variáveis relevantes

A seleção de variáveis foi realizada com base na análise de correlação entre todas as features e a variável alvo binarizada. O heatmap gerado permitiu identificar, de forma visual, quais atributos apresentaram correlação mais expressiva com o diagnóstico.



Foram selecionadas as 7 variáveis com correlação média ou forte com *target*, descritas na Tabela 1. As demais variáveis *age*, *sex*, *trestbps*, *chol*, *fbs* e *restecg*, apresentaram

correlação fraca com o alvo e foram descartadas, reduzindo a dimensionalidade sem perda expressiva de poder preditivo.

Variáveis selecionadas para modelagem

Variável	Descrição	Tipo	Correlação com target
<i>ca</i>	Nº de vasos principais coloridos	Ordinal	Forte positiva
<i>thal</i>	Resultado de talassemia	Nominal	Forte positiva
<i>cp</i>	Tipo de dor no peito	Nominal	Média positiva
<i>exang</i>	Angina induzida por exercício	Binária	Média positiva
<i>oldpeak</i>	Depressão ST por exercício	Contínua	Média positiva
<i>thalach</i>	Frequência cardíaca máxima	Contínua	Média negativa
<i>slope</i>	Inclinação do pico ST	Ordinal	Média negativa

3.3 Pré-processamento

O pré-processamento foi estruturado em quatro etapas principais: binarização da variável alvo, divisão treino/teste, transformações nas variáveis contínuas e construção de um pipeline de codificação e normalização. Novamente reforçando, todas as etapas que envolvem ajuste de parâmetros foram realizadas exclusivamente sobre o conjunto de treino e aplicadas ao teste, prevenindo vazamento de dados.

Divisão treino/teste


O dataset foi dividido em 80% para treino e 20% para teste (*test_size=0.2*, *random_state=42* para reprodução). O parâmetro *stratify=y* foi utilizado para garantir que a proporção entre as classes seja preservada tanto no conjunto de treino quanto no de teste, evitando que uma divisão aleatória desfavorável concentre observações de uma só classe em um dos conjuntos.

Transformações nas variáveis contínuas

As distribuições assimétricas e a presença de outliers observados na análise exploratória motivaram a aplicação de transformações matemáticas nas variáveis contínuas, com o objetivo de aproximar suas distribuições de uma normal e reduzir o peso desproporcional de valores extremos - o que é especialmente relevante para o KNN, cujo cálculo de distâncias é diretamente afetado pela escala e distribuição dos dados. A Tabela abaixo detalha cada transformação aplicada e sua justificativa.

Variável	Transformação	Justificativa
<i>trestbps</i>	$\log_{10}(x)$	Distribuição assimétrica à direita com outliers. A transformação logarítmica comprime a cauda, aproximando a distribuição de uma normal e reduzindo a influência de valores extremos no cálculo de distâncias.
<i>chol</i>	$\log_{10}(x)$	Outlier identificado (564) e forte assimetria à direita. A transformação logarítmica atenua o peso desproporcional do valor extremo e comprime a variação, sem remover o dado clínico.
<i>oldpeak</i>	$\log_{10}(x + 1)$	A variável contém valores zero, o que inviabiliza o log direto. O deslocamento de +1 garante que $\log(0+1)=0$, preservando os zeros sem gerar indefinição, e ao mesmo tempo corrige a assimetria à direita.
<i>thalach</i>	PowerTransformer	Distribuição ligeiramente assimétrica sem zeros. O <i>PowerTransformer</i> estima automaticamente o expoente ótimo para aproximar a distribuição de uma normal, sendo mais flexível que o log para casos de assimetria moderada.

O efeito dessas transformações pode ser verificado comparando os histogramas antes e depois do processamento. As distribuições resultantes são visivelmente mais simétricas e concentradas, o que favorece o cálculo de distâncias.



Pipeline de codificação, imputação e normalização

As demais etapas de pré-processamento foram encapsuladas em um *ColumnTransformer* com três grupos de colunas, cada um com tratamento específico:

(1) **Colunas numéricas** (*oldpeak, thalach, ca, slope*): recebem imputação pela moda seguida de escalonamento. Três normalizações foram testadas em paralelo para comparação no treinamento, como requisitado: *MinMaxScaler* (escala [0,1]), *StandardScaler* (média 0, desvio 1) e transformação Log ($\log_{1p}$).

Detalhe: O uso de Log nesta etapa seguiu a exigência do trabalho, mas por não ser apenas um escalonador como os dois demais e transformar diretamente a geometria dos dados, o fato de já termos aplicado Log anteriormente para normalização pode prejudicar a reaplicação do mesmo, gerando dados excessivamente compactos.

(2) **Coluna passthrough** (*exang*): por ser uma variável binária e sem valores ausentes, foi passada diretamente ao modelo sem transformação adicional.


(3) **Colunas nominais** (*cp, thal*): recebem imputação pela moda seguida de *OneHotEncoding*. A codificação one-hot é necessária pois estas variáveis não possuem ordenação numérica intrínseca - tratá-las como numéricas introduziria uma hierarquia artificial que distorce o cálculo de distâncias do KNN.

3.4 Treinamento por divisão simples e Cross-Validation

Esta seção avalia o desempenho do classificador KNN nas 7 features selecionadas, testando sistematicamente valores de k de 1 a 29 para cada uma das três normalizações, sob duas estratégias de avaliação distintas: divisão simples treino/teste (com estratificação pela variável alvo) e validação cruzada, também estratificada. O objetivo é identificar a melhor combinação de k e normalização e, simultaneamente, comparar a confiabilidade das duas abordagens de avaliação.

Treino por split simples

Para cada uma das três normalizações, um modelo KNN é treinado e avaliado no teste para cada valor de k entre 1 e 29, totalizando 87 modelos treinados. A métrica reportada é a acurácia no conjunto de teste. A configuração utilizada foi *weights='uniform'* e *metric='minkowski'* (padrão do scikit-learn), sendo variado apenas k e o escalonamento. Os resultados estão apresentados no gráfico a seguir.




Como era de se esperar o StandardScaler acabou por superar os demais, devido ao seu comportamento que tende a amenizar os outliers do conjunto. Como o MinMax não é tão robusto quanto aos valores discrepantes ficou bem abaixo dos demais. Os melhores valores para cada normalização estão destacados no gráfico.

Uma limitação inerente ao split simples é que a avaliação é feita sobre um único subconjunto fixo de 61 observações, o que torna o resultado sensível à divisão aleatória utilizada. Um conjunto de teste pequeno pode, por acaso, ser mais ou menos representativo da distribuição real dos dados, inflando ou deflando a acurácia estimada. Essa instabilidade motiva o uso da validação cruzada na etapa seguinte.

Validação cruzada estratificada (5-fold)

Na validação cruzada, o conjunto de treino é particionado em 5 folds de tamanho igual. Em cada uma das 5 iterações, 4 folds são usados para treinar o modelo e 1 fold é reservado para validação. O processo se repete até que cada fold tenha sido usado exatamente uma vez como validação. A acurácia final reportada é a média das 5 acurácias obtidas no teste, o que reduz o efeito da variância associada a uma única divisão. A estratificação (*StratifiedKfold*) garante que a proporção entre as classes seja mantida em cada fold, prevenindo que alguma partição fique desequilibrada por conta do tamanho relativamente pequeno do dataset. Os parâmetros utilizados foram *n_splits=5*, *shuffle=True* e *random_state=18*. O mesmo experimento é repetido para as três normalizações e para cada k de 1 a 29, totalizando 87 configurações avaliadas. Neste caso, o pré-processamento é encapsulado dentro do *Pipeline* do scikit-learn, garantindo que o ajuste dos parâmetros de escalonamento e imputação ocorra apenas dentro de cada fold de treino, sem contaminação dos dados de validação. Os resultados estão apresentados no gráfico abaixo.



Surpreendentemente houve um empate técnico entre as 3 normalizações quanto a acurácia final, mas os diferentes valores ótimos para k , evidenciam a sensibilidade do modelo quanto a escala dos dados, por mais que todos de certa forma tenham convergido para uma acurácia semelhante no conjunto de teste.

Comparação entre as abordagens

Conforme esperado, os resultados da validação cruzada são sistematicamente inferiores aos do split simples. Isso não indica pior desempenho do modelo, mas sim uma estimativa mais realista: no split, o modelo é avaliado em um único subconjunto fixo, enquanto no CV ele precisa generalizar para cinco partições distintas dos dados de treino. A diferença entre os valores evidencia o grau de otimismo intrínseco ao split - quanto maior essa diferença, maior o risco de o resultado do split não se confirmar em dados novos.

Em relação às normalizações, a variação de k ótimo entre as três abordagens de escalonamento indica que a escolha da normalização tem impacto real no desempenho - o KNN é sensível à escala dos dados e a distribuições muito assimétricas. Não é possível, contudo, concluir qual normalização é definitivamente superior com base apenas nestes experimentos, pois cada abordagem explorou apenas um subconjunto de configurações (k variável, mas métrica de distância e ponderação fixas). Essa limitação é endereçada na seção 3.5, com o Grid Search.

3.5 Treinamento por Grid-search e comparação com resultados anteriores

Nas seções anteriores, apenas k e a normalização foram variados, mantendo fixos os demais hiperparâmetros do KNN. O Grid Search expande essa busca ao testar todas as

combinações possíveis entre k , a métrica de distância e o esquema de ponderação dos vizinhos. O objetivo é encontrar a configuração globalmente mais robusta, aproveitando o mesmo esquema de validação cruzada estratificada (5-fold) já utilizado na seção 3.4 — garantindo comparabilidade direta entre os resultados.

Configuração do Grid Search

O *GridSearchCV* foi executado separadamente para cada normalização, utilizando o mesmo *Pipeline* (pré-processamento + KNN) e o mesmo *StratifiedKFold* da seção anterior. O espaço de busca definido foi novamente k de 1 a 29; métrica de distância euclidiana ou de Manhattan; e ponderação uniforme (todos os vizinhos com o mesmo peso) ou por distância (vizinhos mais próximos têm maior peso). A combinação de todos esses valores resulta em $29 \times 2 \times 2 = 116$ configurações testadas por normalização, totalizando 348 configurações no experimento completo, todas avaliadas via validação cruzada 5-fold sobre o conjunto de treino.

Melhores configurações encontradas pelo Grid Search por normalização

Normalização	Melhor k	Métrica	Ponderação	Acurácia CV	Acurácia Teste
MinMaxScaler	9	manhattan	uniforme	0.843	0.8525
StandardScaler	13	manhattan	uniforme	0.834	0.918
Log	14	euclidiana	uniforme	0.838	0.8689

Seleção da configuração final e avaliação no teste

Dentre as três normalizações avaliadas pelo Grid Search, a configuração selecionada como final foi aquela com a maior acurácia na validação cruzada (linha 1 da tabela), e não necessariamente a de maior acurácia no teste. Esse critério é deliberado: a acurácia CV é calculada inteiramente sobre o treino, sem qualquer contato com o conjunto de teste, tornando-a uma estimativa mais honesta da capacidade de generalização do modelo. A acurácia no teste serve apenas como confirmação final, avaliada uma única vez após a seleção.


O modelo final foi retreinado com os melhores hiperparâmetros sobre todo o conjunto de treino e avaliado no teste. O relatório de classificação completo (precisão, recall e F1-score por classe) é apresentado na a seguir, e a matriz de confusão vem em sequência.

Relatório de classificação do modelo final (Grid Search)

Classe	Precisão	Recall	F1-score
0 — Saudável	0.85	0.88	0.87
1 — Doente	0.85	0.82	0.84

Os valores semelhantes de precisão e recall entre as duas classes indicam que o modelo não favorece sistematicamente nenhuma delas — o que é um resultado positivo dado o leve desequilíbrio ainda presente após a binarização. A distribuição de erros na matriz de confusão confirma esse equilíbrio. Contudo, do ponto de vista clínico, o recall da classe 1 (doente) é o indicador mais crítico: um falso negativo — classificar um paciente doente como saudável — representa um risco maior do que um falso positivo.

Esclarecemos que decidimos abrir as métricas de precisão, recall e f1 apenas para este último modelo, para não gerarmos um número excessivo de tabelas que poluísse o documento. Segue a matriz de confusão.



Comparação geral: split vs. cross-validation vs. Grid Search

Normalização	Split k	Split acc.	CV k	CV acc.	GS CV acc.
MinMaxScaler	14	0.8852	6	0.8345	0.8430
StandardScaler	10	0.9344	17	0.8308	0.8347
Log	8	0.9180	14	0.8388	0.8388

O Grid Search produziu o melhor resultado entre as três abordagens, o que era esperado: ao ampliar o espaço de configurações testadas - incluindo métrica de distância e esquema de ponderação - ele encontrou combinações que as buscas anteriores, restritas a k e normalização, não conseguiram explorar. Os resultados do split simples, embora numericamente superiores em alguns casos, são os menos confiáveis por dependerem de uma única avaliação sobre um conjunto pequeno e fixo.

A validação cruzada simples, por sua vez, oferece uma estimativa mais estável, mas com espaço de busca mais limitado. O Grid Search combina o melhor dos dois mundos: busca ampla e avaliação via CV, tornando-se a abordagem mais recomendada para a seleção de hiperparâmetros neste problema.

4. Conclusões

O melhor modelo obtido teve recall de 0.88 (saúdáveis) e 0.82 (doentes). Esses valores são muito inferiores ao padrão requisitado para a área da saúde, pelo alto risco de faltar no diagnóstico de alguém realmente doente. A conclusão central é que o treinamento foi ineficiente para o propósito de identificar a doença do coração, sendo meramente um protótipo a ser aprimorado.

5. Próximos passos

Poderíamos aplicar diferentes pré-processamentos como *RobustScaler* e experimentar diferentes modelos de aprendizado supervisionado mais robustos, como Random Forest. Também é possível utilizar PCA para visualizações avançadas quanto as variáveis mais importantes e tornar também essa etapa mais robusta.