

TECHNICAL REPORT

Aluno: Antônio Sampaio de Marinho e Kevin Emmanuel Sousa Pontes

1. Introdução

*Este relatório apresenta o desenvolvimento de um pipeline de regressão aplicado ao dataset **Communities and Crime**, com o objetivo de prever a variável **ViolentCrimesPerPop**, que representa a taxa de crimes violentos por população nas comunidades analisadas.*

O conjunto de dados possui informações sociais, econômicas, demográficas e familiares das comunidades. Essas informações foram utilizadas para analisar quais atributos possuem maior relação estatística com a variável alvo.

*Inicialmente, o dataset possuía **1994 linhas e 128 colunas**, em que cada linha representa uma comunidade e cada coluna representa uma característica dessa comunidade. Durante a exploração inicial, foram analisadas as primeiras linhas, os tipos de dados, as estatísticas descritivas e a presença de inconsistências, como valores representados por ?.*

*O objetivo geral do trabalho foi construir um fluxo completo de regressão, envolvendo leitura e exploração do dataset, tratamento de dados, seleção de atributos relevantes, aplicação de modelos de regressão, avaliação por métricas, validação cruzada, Grid Search e comparação final dos resultados. Foram utilizados três modelos principais: **Regressão Linear, Ridge Regression e Lasso Regression**.*

2. Observações

Durante o desenvolvimento do trabalho, foram encontradas algumas inconsistências no dataset, principalmente valores representados pelo símbolo ?. Esses valores precisaram ser tratados antes da modelagem, pois poderiam impedir a conversão correta das colunas para valores numéricos.

*Também foi observado que algumas colunas apresentavam grande quantidade de valores ausentes. Por esse motivo, foi adotado o critério de remover colunas com 50% ou mais de valores faltantes. Além disso, a coluna **fold** foi removida, pois representa um artefato metodológico do dataset original e não uma característica útil para a previsão.*

Outro ponto observado foi a presença de colunas categóricas, como `state` e `communityname`. A coluna `communityname` apresentou alta esparsidade, funcionando praticamente como um identificador das comunidades, por isso foi removida. Já a variável `state` foi mantida, pois apresentou baixa esparsidade e foi codificada posteriormente com One-Hot Encoding.

3. Resultados e discussão

3.1 Leitura e exploração inicial do dataset

Durante a análise inicial, foi observado que algumas colunas apresentavam valores inconsistentes representados pelo símbolo `?`. Esses valores precisavam ser tratados, pois poderiam impedir a conversão correta das colunas para valores numéricos. Além disso, algumas colunas estavam classificadas como texto, mesmo representando informações numéricas, justamente pela presença desses símbolos.


Também foram identificadas colunas com muitos valores ausentes. Por esse motivo, foi adotado o critério de remover colunas com 50% ou mais de valores faltantes. Com esse filtro removemos 24 colunas.

Removemos ainda a coluna `fold` por ser um artefato de cross-validation presente nos dados, ademais verificamos que as colunas categóricas `state` e `communityname` poderiam ser viáveis para regressão, mas foi constatado uma alta esparsidade de `communityname` (0.91), que é praticamente um ID dos dados. Mantemos com tudo a variável `state`, com 0.02 de esparsidade, que posteriormente codificamos com one-hot-encoding para análise de correlação.


Após o tratamento inicial, o dataset passou de 128 colunas para 102 colunas, mantendo as 1994 linhas. Isso mostra que nenhuma comunidade foi removida nesta etapa, apenas colunas pouco úteis ou problemáticas foram descartadas.

A análise exploratória deste dataset é muito extensa pela quantidade de variáveis que ele possui, por tanto nos resumimos a analisar melhor apenas as variáveis mais linearmente correlatas com o alvo (15 no total) e expomos as suas distribuições com o seguinte gráfico **resumido** das variáveis correlatas (que também contém a distribuição do próprio alvo).

Histogramas das features selecionadas



Posteriormente usamos essas distribuições para aplicarmos transformações geométricas com o objetivo de mitigar os outliers detectados, como segue também pelo gráfico box-plot, também resumido.



Explicitamos as transformações realizadas e como as variáveis mais importantes foram identificadas nas seções seguintes.

Ademais, como gostaríamos de obter uma visão geral sobre o dataset que estamos trabalhando, para fins de apresentação e checagem de distribuições, geramos gráficos de algumas variáveis que caracterizam a base de dados, como expomos na seção seguinte.

3.2 Caracterização demográfica

Para a caracterização foram analisados quatro grupos principais: **composição racial, renda e pobreza, distribuição etária e estrutura familiar.**

O gráfico de composição racial mostrou a proporção média de diferentes grupos raciais nas comunidades. O gráfico de renda e pobreza apresentou variáveis como renda mediana, percentual da população abaixo da pobreza e percentual de desempregados. O gráfico de distribuição etária mostrou a proporção média de diferentes faixas etárias. Já o gráfico de estrutura familiar apresentou variáveis como **PctKids2Par**, **MalePctDivorce** e **FemalePctDiv**.

Inicialmente gostaríamos apenas de verificar possíveis desbalanceamentos e vieses dos dados, porém na seção seguinte percebemos que muitos dos atributos relevantes detectados estavam diretamente ligados com as características demográficas dos dados e acabaram sendo analisados nessa etapa, reforçando assim a importância de uma boa análise exploratória para a demografia populacional.

“ caracterização demográfica. ”


3.3 Análise de correlação e seleção de atributos relevantes

Depois da exploração inicial, foi feita uma análise de correlação entre os atributos do dataset e a variável alvo **ViolentCrimesPerPop**. A correlação foi utilizada para identificar quais variáveis possuem maior relação estatística com a taxa de crimes violentos.

Foram analisadas correlações lineares, tanto positivas quanto negativas. Correlação positiva indica que, quando uma variável aumenta, a variável alvo tende a aumentar. Já a correlação negativa indica que, quando uma variável aumenta, a variável alvo tende a diminuir.

Para a seleção dos atributos, foi utilizado o critério de correlação absoluta maior ou igual a **0.5042**, valor definido a partir das variáveis mais correlacionadas com a variável alvo. A correlação absoluta foi usada porque tanto relações positivas quanto negativas podem ser importantes para o modelo. Com esse critério, foram selecionadas **15 features** para a modelagem.

Essas features podem ser encontradas nos gráficos da seção 3.1, como já havíamos mencionado. Todos os atributos selecionados se encontram no gráfico adiante.



3.4 Transformações e tratamentos aplicados

Após a seleção das features, foram gerados histogramas para analisar a distribuição das variáveis selecionadas, como já dito. Esses histogramas permitiram observar se os valores estavam concentrados em faixas baixas, médias ou altas.

Em seguida, foram gerados boxplots para verificar a dispersão dos dados e a presença de possíveis outliers. Os boxplots ajudaram a identificar valores extremos e a entender melhor o comportamento das variáveis antes da modelagem.

Depois disso, foram aplicadas transformações em **16 colunas**, sendo **15 features + target**, utilizando as técnicas: **log** e **power**.

A transformação **log** foi usada para suavizar valores mais altos e reduzir assimetrias. Já a transformação **power**, que no código corresponde ao quadrado dos valores, foi usada para alterar a escala e o formato da distribuição de algumas variáveis.

Segue na tabela as transformações realizadas em cada feature

Feature	Transformação	Feature	Transformação
ViolentCrimesPerPop	log	PctKids2Par	power
PctIlleg	log	PctFam2Par	power
RacePctWhite	power	PctYoungKids2Par	power
PctTeen2Par	power	racepctblack	log
pctWInvInc	power	pctWPubAsst	log
FemalePctDiv	power	TotalPctDiv	power
PctPersOwnOccup	power	MalePctDivorce	log
PctPopUnderPov	log	PctUnemployed	log

Quanto ao tratamento de valores ausentes, não havia nenhum nos atributos selecionados. Como passo final aplicamos o escalonamento *StandartScaler* para ajustar os atributos para a mesma escala.

3.5 Divisão dos dados em treino e teste

Após o pré-processamento e as transformações, os dados foram divididos em treino e teste. A divisão utilizada foi **80% para treino e 20% para teste**.

O conjunto de treino foi utilizado para o modelo aprender os padrões dos dados. Já o conjunto de teste foi utilizado para avaliar se o modelo conseguiu realizar boas previsões em dados que ainda não tinha visto. Essa separação é importante para evitar avaliar o modelo apenas nos dados em que ele foi treinado.

3.6 Treinamento dos modelos: Regressão Linear, Ridge Regression e Lasso Regression

A Regressão Linear padrão foi usada como modelo base. O Ridge e o Lasso foram utilizados porque aplicam regularização, ou seja, adicionam penalizações aos coeficientes do modelo para tentar controlar sua complexidade.

O Ridge utiliza regularização **L2**, reduzindo os coeficientes sem zerá-los. Já o Lasso utiliza regularização **L1**, podendo reduzir alguns coeficientes até zero. Dessa forma, os

três modelos foram comparados para verificar qual apresentaria melhor desempenho na previsão de **ViolentCrimesPerPop**.


3.7 Avaliação dos modelos com MAE, MSE, RMSE e R^2

Descrição das métricas analisadas: **MAE** representa o erro médio absoluto. Quanto menor, melhor. **MSE** representa o erro quadrático médio. Ele penaliza mais erros grandes. Quanto menor, melhor. **RMSE** é a raiz do MSE, retornando o erro para uma escala mais próxima da variável original. Quanto menor, melhor. **R^2** mostra a capacidade explicativa do modelo. Quanto maior, melhor.

No conjunto de teste, os resultados foram:

Modelo	MAE	MSE	RMSE	R^2
Regressão Linear melhor	0.0707	0.0098	0.0988	0.6274
Ridge	0.0709	0.0098	0.0992	0.6247
Lasso	0.0734	0.0101	0.1004	0.6158

Com base nesses resultados, a **Regressão Linear** apresentou o melhor desempenho no conjunto de teste, pois teve o menor MAE, o menor RMSE e o maior R^2 . O Ridge ficou muito próximo da Regressão Linear, mas um pouco abaixo. O Lasso apresentou desempenho inferior, com maior erro e menor R^2 .




3.8 Validação cruzada

Além da avaliação no conjunto de teste, foi aplicada validação cruzada **5-fold**. Essa técnica divide os dados de treino em cinco partes e avalia o modelo em diferentes combinações. Isso permite uma avaliação mais robusta, pois o modelo não depende apenas de uma única divisão dos dados.

Modelo	MAE_CV	MSE_CV	RMSE_CV	R ² _CV
Regressão Linear	0.0751	0.0106	0.1029	0.6386
Ridge melhor R²	0.0751	0.0106	0.1029	0.6387
Lasso	0.0761	0.0108	0.1037	0.6331

Na validação cruzada, o **Ridge** apresentou o melhor R^2 médio, com valor de **0.6387**. No entanto, a diferença para a Regressão Linear foi muito pequena, pois a Regressão Linear obteve **0.6386**. Assim, pode-se concluir que Ridge e Regressão Linear tiveram desempenho praticamente igual na validação cruzada. O Lasso ficou um pouco abaixo, com maior erro e menor R^2 .



3.9 Grid Search

Foi aplicado Grid Search para buscar os melhores hiperparâmetros dos modelos Ridge e Lasso. O parâmetro ajustado foi o **alpha**, que controla a força da regularização.

Grid Search completo

modelo	melhor_R2_CV	MAE_teste	MSE_teste	RMSE_teste	R2_teste	fit_intercept	alpha	solver	selection
Regressão Linear	0.6386	0.0707	0.0098	0.0988	0.6274	True	NaN	NaN	NaN
Ridge	0.6387	0.0709	0.0098	0.0992	0.6247	True	1.000	auto	NaN
Lasso	0.6393	0.0717	0.0100	0.1001	0.6182	True	0.001	NaN	random

O Lasso apresentou o maior R^2 médio na validação cruzada do Grid Search, com valor de **0.6393**. Isso mostra que o Lasso, apesar de não ter um desempenho tão bom anteriormente, obteve uma melhora após as combinações de parâmetros com Grid Search. Apesar de não ter o melhor resultado no teste final, ele foi escolhido tendo em vista que o resultado da validação cruzada é mais consistente que o teste final, por se tratar de uma média de vários testes.

3.10 Análise final dos resultados

A comparação geral mostrou que cada etapa destacou um modelo de forma diferente.


Etapa	Melhor modelo	Métrica principal	Valor
Treino normal/teste	Regressão Linear	R ² teste	0.6274
Validação cruzada	Ridge	R ² médio CV	0.6387
Grid Search	Lasso	Melhor R ² médio CV	0.6393
Teste após Grid Search	Regressão Linear	R ² teste	0.6274

No teste simples, a **Regressão Linear** apresentou o melhor desempenho, com menor erro e maior R². Na validação cruzada, o **Ridge** apresentou o melhor R² médio, embora com diferença mínima em relação à Regressão Linear. Já no Grid Search, o **Lasso** obteve o maior R² médio na validação cruzada.

Dessa forma, os resultados indicam que os modelos tiveram desempenhos próximos, mas cada etapa destacou um modelo diferente. A Regressão Linear se destacou no teste simples, o Ridge apresentou maior estabilidade na validação cruzada e o Lasso obteve o melhor resultado após o ajuste de hiperparâmetros.

3.11 Visualização do modelo final

Para a visualização da reta de regressão, foi escolhido o atributo **PctKids2Par**, por possuir a maior correlação, **-0.7384**, dentre as variáveis escolhidas com o alvo. O valor dito indica uma relação forte e negativa. Isso significa que, no conjunto de dados analisado, quando **PctKids2Par** aumenta, **ViolentCrimesPerPop** tende a diminuir.



4. Conclusões

Os resultados esperados foram satisfeitos, pois foi desenvolvido um pipeline completo de regressão seguindo as etapas solicitadas: leitura do dataset, exploração inicial, tratamento de inconsistências, seleção de atributos, aplicação de modelos, avaliação por métricas, validação cruzada, Grid Search e comparação final dos resultados.

O modelo selecionado como melhor conseguiu explicar aproximadamente 63,93% da variação da variável alvo na validação cruzada com Grid Search. Considerando que o dataset envolve características sociais e criminais, esse resultado pode ser considerado satisfatório, pois esse tipo de fenômeno depende de muitos fatores e dificilmente é explicado completamente por um único modelo.

O Ridge apresentou desempenho muito próximo da Regressão Linear, principalmente na validação cruzada. Já o Lasso teve bom desempenho durante o Grid Search e acabou se destacando.

5. Próximos passos

Como próximos passos para o projeto, seria interessante testar outros modelos de regressão, como Árvore de Decisão, Random Forest, Gradient Boosting ou modelos mais robustos para lidar com relações não lineares.

Também seria possível testar novas formas de seleção de atributos, não apenas com correlação, mas também com métodos baseados em importância de variáveis ou análise de multicolinearidade. Outra possibilidade seria testar novas transformações nos dados e comparar se elas melhoram ou pioram o desempenho dos modelos.

Além disso, seria interessante aprofundar a análise dos resíduos, verificando onde o modelo mais erra e se existem padrões nesses erros. Isso ajudaria a entender melhor as limitações da Regressão Linear nesse problema.

Por fim, um próximo passo importante seria melhorar a interpretação dos resultados, analisando com mais cuidado o impacto das variáveis mais relevantes na previsão da taxa de crimes violentos, sempre evitando afirmar causalidade apenas com base em correlação.