

REGRESSÃO LINEAR, RIDGE E LASSO

Air Quality - UCI Machine Learning Repository

OBJETIVO DO PROJETO

Objetivo Geral

Desenvolver um pipeline completo de regressão utilizando:

- Regressão Linear
- Ridge Regression
- Lasso Regression

Objetivos Específicos

- Explorar o dataset
- Tratar valores ausentes
- Aplicar pré-processamento
- Comparar modelos de regressão
- Aplicar validação cruzada
- Aplicar Grid Search
- Analisar os resultados obtidos

DATASET UTILIZADO

Air Quality Dataset — UCI Repository

Características do dataset:

- 9357 instâncias
- 15 atributos
- Dados ambientais e de sensores químicos
- Variáveis numéricas e textuais

Exemplos de atributos:

- CO(GT) - Concentração real de monóxido de carbono no ar.
- NOx(GT) - Concentração de óxidos de nitrogênio.
- NO2(GT) - Concentração de dióxido de nitrogênio.
- RH (Umidade Relativa)
- AH (Umidade Absoluta)
- Temperatura (T)

VARIÁVEL ALVO

Variável prevista

- Temperatura (T)

O objetivo do projeto foi prever a temperatura do ambiente utilizando os demais atributos do dataset.

Atributos utilizados:

- Sensores químicos
- Gases atmosféricos
- Umidade relativa
- Umidade absoluta

EXPLORAÇÃO DOS DADOS

Etapas realizadas:

- Verificação de tipos dos dados
- Estatísticas descritivas
- Identificação de inconsistências
- Verificação de valores ausentes

Observação:

- O dataset utilizava o valor -200 para representar dados ausentes.

TRATAMENTO DOS DADOS

Tratamento de valores ausentes:

- Substituição de -200 por NaN
- Preenchimento com média da coluna

Remoção de colunas:


- Date
- Time

Normalização:

- Aplicação do MinMaxScaler para padronizar os atributos entre 0 e 1.

Variável	Quantidade
NMHC(GT)	8443
CO(GT)	1683
NOx(GT)	1639
NO2(GT)	1642

ANÁLISE DE CORRELAÇÃO



Principais Correlações:

- AH → correlação positiva forte com temperatura
- RH → correlação negativa relevante
- PT08.S4(NO2) → relação moderada com temperatura

DIVISÃO DOS DADOS

Separação treino e teste:

- 80% treino
- 20% teste

Modelos treinados:

- Regressão Linear
- Ridge Regression
- Lasso Regression

MÉTRICAS UTILIZADAS

Métricas de avaliação

MAE:

- Erro médio absoluto.

MSE:

- Erro quadrático médio.

RMSE:

- Raiz do erro quadrático médio.

R^2 :

- Capacidade do modelo explicar a variabilidade dos dados.

RESULTADOS: REGRESSÃO LINEAR

Resultados:

- MAE = 1.6735
- MSE = 5.1157
- RMSE = 2.2618
- $R^2 = 0.9332$

Análise:

O modelo apresentou excelente desempenho, conseguindo explicar grande parte da variação da temperatura.

RESULTADOS: RIDGE REGRESSION

Resultados:

- MAE = 1.6672
- MSE = 5.1374
- RMSE = 2.2666
- $R^2 = 0.9329$

Análise:

Os resultados foram muito próximos aos da regressão linear, porém com regularização para reduzir possíveis problemas de multicolinearidade.

RESULTADOS: LASSO REGRESSION

Resultados:

- MAE = 1.6857
- MSE = 6.3889
- RMSE = 2.5276
- $R^2 = 0.9166$

Análise:

O desempenho foi um pouco inferior, mas o modelo conseguiu simplificar os atributos ao reduzir coeficientes menos relevantes.

REGRESSÃO LINEAR SIMPLES

Atributo escolhido:


AH (Umidade Absoluta)

Resultados:

- MAE = 5.1348
- MSE = 43.1078
- RMSE = 6.5657
- $R^2 = 0.4372$

Análise:

Utilizar apenas um atributo reduziu significativamente a capacidade de previsão do modelo.



VALIDAÇÃO CRUZADA

Cross Validation (5 folds)

Média do R^2 :

- Linear Regression = 0.7172
- Ridge Regression = 0.7250
- Lasso Regression = 0.6993

Análise:

O Ridge apresentou a melhor média geral, indicando maior estabilidade entre diferentes divisões dos dados.

GRID SEARCH

Ajuste de hiperparâmetros

Melhor Ridge:

- $\alpha = 10$
- Melhor $R^2 = 0.7359$

Melhor Lasso:

- $\alpha = 0.01$
- Melhor $R^2 = 0.7459$

Importância:

O Grid Search ajudou a encontrar configurações mais adequadas para os modelos regularizados.

COMPARAÇÃO ENTRE MODELOS

Modelo	MAE	MSE	RMSE	R ²
Linear	1.6735	5.1157	2.2618	0.9332
Ridge	1.6672	5.1374	2.2666	0.9329
Lasso	1.6857	6.3889	2.5276	0.9166

Observações:

- Linear e Ridge tiveram desempenho muito parecido
- Lasso apresentou maior erro
- Ridge foi mais estável na validação cruzada
- O pré-processamento foi essencial para os resultados

CONCLUSÕES

Conclusões do projeto:

- Os modelos apresentaram bons resultados
- A Regressão Linear teve melhor desempenho geral
- Ridge trouxe maior estabilidade
- Lasso reduziu a influência de atributos menos relevantes
- O tratamento dos dados impactou diretamente os resultados
- A análise de correlação auxiliou na interpretação do problema

TRABALHOS FUTUROS

Possíveis melhorias:

- Testar modelos não lineares
- Avaliar Random Forest Regressor
- Avaliar XGBoost
- Aplicar seleção automática de atributos
- Investigar outliers
- Criar visualizações mais detalhadas

**OBRIGADO
PELA ATENÇÃO!**