



UFC

**Universidade Federal do Ceará
Campus de Itapajé**

Análise de Classificação e Regressão Aplicada aos Datasets Heart Disease e Communities And Crime

**Pipeline para classificar a presença de doença cardíaca a partir de dados
sociais e clínicos e prever Crimes Violentos**

Apresentação de Classificação

Desenvolver um pipeline completo de classificação para analisar e prever a presença de doença cardíaca utilizando o dataset Heart Disease.

1 Leitura e exploração inicial do dataset

2 Tratamento de valores ausentes e inconsistências

3 Binarização da variável alvo

4 Seleção de atributos relevantes por correlação

5 Pré-processamento com transformações e normalizações

6 Treinamento do modelo KNN

7 Avaliação com split simples, validação cruzada e Grid Search

Ideia central

O KNN compara pacientes por proximidade. Por isso, o pré-processamento e a normalização foram etapas fundamentais.

Dataset utilizado

O dataset Heart Disease reúne informações clínicas de pacientes da base de Cleveland. A partir desses dados, o objetivo foi classificar se o paciente apresenta ou não doença cardíaca.

Atributo	Tipo	Descrição
age	Contínua	Idade em anos
sex	Binária	Sexo (1=masc, 0=fem)
cp	Nominal	Tipo de dor no peito (1–4)
trestbps	Contínua	Pressão arterial em repouso
chol	Contínua	Colesterol sérico
fbs	Binária	Glicemia > 120 mg/dl (1=sim)
restecg	Ordinal	Resultado ECG em repouso (0–2)
thalach	Contínua	Frequência cardíaca máxima
exang	Binária	Angina induzida por exercício (1=sim)
oldpeak	Contínua	Depressão ST por exercício
slope	Ordinal	Inclinação do pico ST (1–3)
ca	Ordinal	N* de vasos principais coloridos (0–3)
thal	Nominal	Resultado talassemia (3=normal, 6=fixo, 7=reversível)
target	Ordinal	0 = sem doença, 1–4 = severidade da doença

Abordagem

Exploração → limpeza → seleção → KNN → validação.

Alvo


Prever presença de doença cardíaca: 0 = saudável, 1 = doente.

Dados

303 pacientes e 13 variáveis clínicas relacionadas a exames.

Exploração inicial

A análise exploratória foi utilizada para compreender a estrutura dos dados antes da modelagem.



Target original

Classes de 0 a 4, representando graus diferentes de doença.

Target binário

0 = saudável; 1 = presença de doença cardíaca.

Distribuição final

164 pacientes saudáveis e 139 pacientes com doença.

5


Ponto de atenção

6

A binarização deixou o problema mais simples e mais equilibrado para o KNN.


Exploração inicial

Distribuição das Variáveis Categóricas por Target




Exploração inicial

Box plot - Variáveis Contínuas



Normalização das variáveis contínuas


Distribuição das Variáveis Contínuas



Antes

Algumas variáveis tinham cauda à direita e valores extremos.


Distribuição das Variáveis Contínuas (após transformações)



Depois

As transformações deixaram as distribuições mais concentradas e comparáveis.

Features selecionadas




Variável	Descrição
ca	Nº de vasos principais coloridos
thal	Resultado de talassemia
cp	Tipo de dor no peito
exang	Angina induzida por exercício
oldpeak	Depressão ST por exercício
thalach	Frequência cardíaca máxima
slope	Inclinação do pico ST

Valores faltantes

ca	4
thal	2


Treinamento com KNN

Treino padrão — Acurácia por K com diferentes normalizações



Validação cruzada

A validação cruzada 5-fold avaliou o modelo em várias divisões do treino, trazendo uma estimativa mais estável que o split simples.



Ajuste com Grid Search

O Grid Search foi aplicado para encontrar a melhor combinação de hiperparâmetros do KNN, usando validação cruzada estratificada

Normalização	Melhor k	Métrica	Ponderação	Acurácia CV	Acurácia Teste
MinMaxScaler	9	Manhattan	Uniforme	0,843	0,8525
StandardScaler	13	Manhattan	Uniforme	0,834	0,918
Log	14	Euclidiana	Uniforme	0,838	0,8689

5
6

Parâmetros avaliados

k de 1 a 29, distância
Euclidiana/Manhattan e pesos
uniformes/por distância.

Melhor resultado

MinMaxScaler com k = 9, métrica
Manhattan e ponderação uniforme.


Critério de escolha

A melhor configuração foi escolhida pela
acurácia média na validação cruzada.

Total avaliado no experimento completo: 348 configurações.

Resultado final do modelo

O modelo final apresentou desempenho equilibrado entre as duas classes, mas o erro mais crítico está nos falsos negativos.



Classe	Precisão	Recall	F1-score
— Saudável	0,85	0,88	0,87
— Doente	0,85	0,82	0,84

Acertos

29 pacientes saudáveis e 23 pacientes doentes foram classificados corretamente.

Erro mais crítico

5 falsos negativos: pacientes doentes classificados como saudáveis.

Interpretação

O modelo funciona como protótipo, mas ainda precisa melhorar para uma aplicação real na saúde.

Conclusões

O trabalho desenvolveu um pipeline completo de classificação com KNN para prever a presença de doença cardíaca.

Resultados alcançados

1

Pipeline de classificação desenvolvido com sucesso

2

KNN aplicado ao dataset Heart Disease

4

Melhor configuração: MinMaxScaler + $k = 9$ + Manhattan

5

Acurácia média CV: 0,843

Recall da classe doente: 0,82

Conclusão geral

6

O desempenho foi razoável para um protótipo acadêmico, mas ainda insuficiente para uma aplicação real na área da saúde.

Próximos passos

Testar modelos mais robustos, como Random Forest

Avaliar outros pré-processamentos, como RobustScaler

Reduzir falsos negativos

Aprimorar o modelo antes de qualquer uso clínico

REGRESSÃO

Apresentação de Regressão

Desenvolver um pipeline completo de regressão para analisar e prever a variável ViolentCrimesPerPop utilizando o dataset Communities and Crime.

O processo envolveu:

- 1 Leitura e exploração inicial do dataset
- 2 Tratamento de inconsistências e valores ausentes
- 3 Seleção de atributos relevantes por correlação
- 4 Treinamento de modelos de regressão (Linear, Ridge, Lasso)
- 5 Avaliação com métricas de erro e R^2
- 6 Validação cruzada 5-fold e Grid Search

Dataset utilizado

O dataset Communities and Crime reúne informações sociais, econômicas, familiares e demográficas de diferentes comunidades dos EUA.

A partir desses dados, o objetivo foi investigar quais características possuem maior relação com a taxa de crimes violentos e construir modelos capazes de prever a variável ViolentCrimesPerPop.

Dados

1994 comunidades, 128 colunas com características sociais, econômicas e demográficas

Alvo

Prever ViolentCrimesPerPop — taxa de crimes violentos por população normalizada

Abordagem

Pipeline completo: exploração → limpeza → correlação → modelos → validação

Exploração inicial

O dataset utilizado foi o Communities and Crime. Ele contém informações sociais, econômicas, demográficas e familiares de comunidades dos Estados Unidos.

Características iniciais:

- 1994 linhas (comunidades)
- 128 colunas (features)
- Cada linha representa uma comunidade
- Variável alvo: ViolentCrimesPerPop
- Valores inconsistentes representados por '?'
- Colunas categóricas: state e communityname

128 → 102

Colunas após limpeza

24

Colunas removidas (>50% NaN)

15


Features selecionadas

80% / 20%

Treino / Teste

Exploração inicial

A análise exploratória foi utilizada para compreender o comportamento das variáveis antes da modelagem.



Grupos analisados:

Composição racial

Renda e pobreza




Distribuição etária

Estrutura familiar

A distribuição é assimétrica à direita: a maioria das comunidades tem baixa taxa de crimes violentos, com poucos casos extremos.

Distribuição / Histogramas


Histogramas das 15 features com maior correlação absoluta com ViolentCrimesPerPop ($|r| \geq 0,50$).



A análise exploratória deste dataset é muito extensa pela quantidade de variáveis que ele possui, por tanto nos resumimos a analisar melhor apenas as variáveis mais linearmente correlatas com o alvo (15 no total) e expomos as suas distribuições com o seguinte gráfico resumido das variáveis correlatas (que também contém a distribuição do próprio alvo).




Análise de outliers com boxplots

Análise de dispersão e outliers antes das transformações geométricas.



Distribuição após transformações

Após aplicar transformações log e power nas 16 colunas (15 features + target), as distribuições ficaram mais simétricas.



Transformação log

Usada para suavizar valores altos e reduzir assimetrias em variáveis com cauda longa.

Transformação power

No código, correspondeu ao quadrado dos valores, ajustando a forma de algumas distribuições.


Sem ausentes finais

Nos atributos selecionados, não havia valores ausentes após o tratamento.

Escalonamento

O StandardScaler foi aplicado para colocar as variáveis em escala comparável.

Features selecionadas



Critério de seleção

Correlação absoluta $\geq 0,5042$ com ViolentCrimesPerPop.

Correlação negativa

PctKids2Par, PctFam2Par, racePctWhite e PctYoungKids2Par tendem a crescer quando o alvo diminui.


Correlação positiva

PctIlleg, racepctblack, pctWPubAsst e PctPopUnderPov crescem na mesma direção do alvo.

A correlação mostra associação estatística, mas não comprova causalidade.

Avaliação inicial dos modelos

Na avaliação inicial, a Regressão Linear apresentou o melhor desempenho no conjunto de teste, com menor erro e maior capacidade explicativa.



Modelo	MAE	MSE	RMSE	R²
Lin. ★	0.0707	0.0098	0.0988	0.6274
Ridge	0.0709	0.0098	0.0992	0.6247
Lasso	0.0734	0.0101	0.1004	0.6158

Leitura do resultado


A Regressão Linear teve o menor MAE, menor RMSE e maior R² no conjunto de teste. Por isso, nessa primeira avaliação, foi o modelo com melhor desempenho geral.

Cuidado na interpretação

Essa comparação foi feita apenas com uma divisão entre treino e teste. Por isso, a validação cruzada foi usada depois para uma avaliação mais robusta e confiável.

Validação cruzada

A validação cruzada avaliou os modelos em diferentes divisões dos dados de treino.



Modelo	MAE_CV	MSE_CV	RMSE_CV	R²_CV
Lin.	0.0751	0.0106	0.1029	0.6386
Ridge ★	0.0751	0.0106	0.1029	0.6387
Lasso	0.0761	0.0108	0.1037	0.6331

Resultado principal

Ridge teve o melhor R^2 médio, mas a diferença para Regressão Linear foi de apenas 0.0001.

Por que usar 5-fold?

Porque o modelo é testado em várias combinações, reduzindo a dependência de uma única separação dos dados.

Ajuste com Grid Search

O Grid Search foi aplicado para buscar os melhores hiperparâmetros dos modelos Ridge e Lasso. O parâmetro ajustado foi o alpha, que controla a força da regularização.

Grid Search completo

modelo	melhor_R2_CV	MAE_teste	MSE_teste	RMSE_teste	R2_teste	fit_intercept	alpha	solver	selection
Regressão Linear	0.6386	0.0707	0.0098	0.0988	0.6274	True	NaN	NaN	NaN
Ridge	0.6387	0.0709	0.0098	0.0992	0.6247	True	1.000	auto	NaN
Lasso	0.6393	0.0717	0.0100	0.1001	0.6182	True	0.001	NaN	random

Parâmetro avaliado

Alpha

Controla a força da regularização nos modelos Ridge e Lasso.

Melhor resultado

Lasso

Obteve o maior R^2 médio na validação cruzada (0.6393) após o ajuste de hiperparâmetros.

Avaliação mais estável

Resultado mais robusto

O Lasso não foi o melhor no teste simples, mas apresentou o melhor R^2 médio na validação cruzada com Grid Search. Por isso, foi considerado o modelo mais consistente após o ajuste de hiperparâmetros.


Análise final após Grid Search

Etapa	Melhor modelo	Métrica principal	Valor
Treino normal/teste	Regressão Linear	R^2 teste	0.6274
Validação cruzada	Ridge	R^2 médio CV	0.6387
Grid Search	Lasso	Melhor R^2 médio CV	0.6393

A comparação mostrou que os modelos tiveram desempenhos próximos, mas cada etapa destacou um modelo diferente.

No teste final, a Regressão Linear apresentou o melhor desempenho. Já na validação cruzada o Ridge ficou ligeiramente melhor, enquanto o Lasso se destacou após o Grid Search.

Visualização do modelo final



Atributo escolhido

PctKids2Par foi usado na visualização por apresentar a maior correlação com o alvo: -0.7384.

Interpretação da reta

A inclinação negativa indica que, conforme PctKids2Par aumenta, ViolentCrimesPerPop tende a diminuir no conjunto analisado.

Limitação importante

Essa visualização mostra uma tendência estatística, mas não deve ser interpretada como causa direta.

Conclusões

Resultados alcançados

- Pipeline completo de regressão desenvolvido com sucesso
- Lasso (Grid Search) explicou ~63,93% da variação do alvo
- Regressão Linear e Ridge com desempenho muito próximo
- PctKids2Par: feature mais correlacionada ($-0,7384$)
- Transformações log/power melhoraram as distribuições

Próximos Passos

Novos modelos

Random Forest, Gradient Boosting, modelos não lineares

Seleção de features

Importância de variáveis, análise de multicolinearidade (VIF)

Análise de resíduos

Identificar padrões nos erros e limitações do modelo linear

Interpretabilidade

Aprofundar impacto das variáveis sem afirmar causalidade