



TECHNICAL REPORT

Aluno: Cecília Maria Lima da Silva - 585967

Dayane Magalhães Ferreira - 587972

Suiany Pinto Gomes - 582147

1. Introdução

Este relatório apresenta o desenvolvimento de um estudo prático de aprendizado não supervisionado utilizando o dataset Bank Marketing, disponibilizado pela UCI Machine Learning Repository. O trabalho teve como objetivo explorar os dados, identificar padrões naturais, aplicar diferentes técnicas de agrupamento, analisar o impacto do pré-processamento e avaliar a influência da redução de dimensionalidade por meio do PCA.

O dataset utilizado contém informações demográficas, financeiras e comportamentais de clientes de uma instituição bancária, além de uma variável categórica de referência relacionada à adesão ou não a um produto financeiro oferecido durante campanhas de marketing. A base possui 4.521 registros e 17 atributos, incluindo variáveis numéricas e categóricas.

Durante o desenvolvimento do projeto foram aplicadas diversas técnicas de aprendizado de máquina. Inicialmente realizou-se uma análise exploratória para compreender as características dos dados e identificar possíveis problemas de qualidade. Em seguida, foram realizadas análises visuais utilizando pares de atributos numéricos, permitindo investigar a existência de agrupamentos naturais.

Posteriormente, foram aplicados os algoritmos K-Means, DBSCAN e Clusterização Hierárquica, comparando seus resultados por meio de métricas de avaliação, visualizações gráficas e interpretação dos agrupamentos encontrados. Também foi investigado o impacto de diferentes métodos de normalização sobre a qualidade da clusterização, incluindo Z-score e Min-Max Scaling.

Por fim, foi realizada uma etapa complementar envolvendo redução de dimensionalidade com PCA e comparação do desempenho de modelos supervisionados treinados com e sem a aplicação dessa técnica. Essa análise teve como objetivo verificar se a redução dimensional preservava informações relevantes para tarefas de classificação.



O trabalho busca demonstrar, na prática, a aplicação de diferentes técnicas estudadas na disciplina de Inteligência Artificial, discutindo suas vantagens, limitações e adequação ao conjunto de dados analisado.

2. Observações

Durante o desenvolvimento do projeto, algumas observações importantes foram registradas:

- *O dataset Bank Marketing apresentou boa qualidade estrutural, não possuindo valores ausentes nem registros duplicados.*
- *Foi necessário selecionar apenas atributos numéricos para aplicação dos algoritmos de clusterização, uma vez que métodos baseados em distância não operam diretamente sobre variáveis categóricas.*
- *Observou-se a presença de atributos com escalas muito diferentes, especialmente nas variáveis balance, duration e pdays, tornando necessária a aplicação de técnicas de normalização para evitar distorções no cálculo das distâncias.*
- *A análise exploratória indicou a existência de valores extremos em algumas variáveis, particularmente em balance e duration, o que influenciou a interpretação dos gráficos de dispersão e dos agrupamentos.*
- *Durante a comparação entre os métodos de clusterização, verificou-se que diferentes algoritmos identificaram estruturas distintas nos dados, evidenciando que não existe uma única solução ótima para o problema de agrupamento.*
- *Na etapa de PCA, observou-se que a redução de dimensionalidade não produziu redução efetiva do número de componentes, uma vez que os atributos utilizados já possuíam baixa dimensionalidade e a variância total foi preservada integralmente.*
- *Fora essas observações, não foram encontrados problemas que comprometessem a execução das análises e dos experimentos realizados.*

3. Resultados e discussão



O desenvolvimento deste trabalho teve como objetivo aplicar técnicas de aprendizado não supervisionado e redução de dimensionalidade utilizando o dataset Bank Marketing, disponibilizado pela UCI Machine Learning Repository. Inicialmente, foi realizada uma análise exploratória dos dados para compreender a estrutura da base e identificar possíveis problemas que pudessem comprometer as etapas posteriores de modelagem.

A base analisada possui 4.521 registros e 17 atributos, contendo informações demográficas, financeiras e comportamentais de clientes de uma instituição bancária. Durante a inspeção inicial, verificou-se que não havia valores ausentes nem registros duplicados, o que simplificou significativamente o processo de preparação dos dados.

As estatísticas descritivas mostraram grande variabilidade em atributos como balance, duration e pdays, indicando a presença de valores extremos e distribuições assimétricas. Em especial, a variável balance apresentou valores variando entre -3313 e 71188, enquanto duration atingiu valores superiores a 3000 segundos, evidenciando a necessidade de avaliar técnicas de normalização antes da aplicação dos algoritmos de agrupamento.

A distribuição da variável alvo mostrou predominância da categoria "no", indicando que a maioria dos clientes não aderiu ao produto bancário oferecido durante a campanha de marketing.




Figura 1 – Distribuição da variável alvo (y).

A análise da matriz de correlação revelou que a maior associação linear ocorreu entre as variáveis *pdays* e *previous*, apresentando coeficiente de aproximadamente 0,58. As demais correlações apresentaram valores relativamente baixos, indicando baixa redundância entre os atributos numéricos.




Figura 2 – Matriz de correlação das variáveis numéricas.

Na etapa de análise visual, foram construídos gráficos de dispersão utilizando combinações de atributos considerados relevantes para a caracterização dos clientes. Os pares Age $\times$ Balance e Balance $\times$ Duration foram escolhidos por combinarem características demográficas, financeiras e comportamentais.




Figura 3 – Gráfico de dispersão Age x Balance.

A visualização não apresentou agrupamentos naturais claramente definidos, indicando que a utilização de apenas duas variáveis não é suficiente para representar toda a estrutura dos dados.




Figura 4– Gráfico de dispersão Balance x Duration.

Observou-se a presença de diversos valores extremos, principalmente relacionados ao saldo bancário e à duração dos contatos.

Em seguida, foi aplicado o algoritmo K-Means utilizando os atributos *age*, *balance*, *duration* e *campaign*. Antes da clusterização, os dados foram normalizados utilizando o método Z-score por meio do *StandardScaler*.

Para definir a quantidade ideal de clusters, foram utilizados simultaneamente o Método do Cotovelo e o Silhouette Score.




Figura 5 – Método do Cotovelo para definição do número de clusters.

Os resultados indicaram uma redução significativa da inércia até aproximadamente $K = 6$, sugerindo esse valor como possível ponto de equilíbrio entre simplicidade e qualidade dos agrupamentos. O maior valor do Silhouette Score foi obtido para $K = 7$ (0,3462), sendo este o valor adotado para a construção do modelo final.

A análise dos centroides permitiu identificar diferentes perfis de clientes. Alguns grupos apresentaram elevados saldos bancários, enquanto outros se destacaram por maior duração das ligações ou maior quantidade de contatos realizados durante as campanhas.




Figura 6 – Visualização dos clusters gerados pelo K-Means (K = 7).

A análise da variável alvo dentro de cada cluster revelou diferenças importantes nas taxas de conversão. O Cluster 2 apresentou aproximadamente 43,12% de respostas positivas, destacando-se significativamente em relação aos demais grupos.

Posteriormente, realizou-se a comparação entre o K-Means e o algoritmo DBSCAN. Diferentemente do K-Means, o DBSCAN utiliza critérios de densidade para formar agrupamentos e identificar ruídos.

Os resultados mostraram a formação de dois clusters e a identificação de 392 observações classificadas como ruído, representando aproximadamente 8,67% da base de dados.




Figura 7– Agrupamentos identificados pelo algoritmo DBSCAN.

Embora tenha sido eficiente na detecção de outliers, o DBSCAN apresentou agrupamentos menos detalhados quando comparados ao K-Means.

Na sequência, foi investigado o impacto da normalização sobre a qualidade da clusterização. Foram comparados três cenários: dados sem normalização, dados normalizados por Z-score e dados normalizados por Min-Max.

Sem normalização, o melhor resultado foi obtido com $K = 2$ e Silhouette Score igual a 0,8337. Entretanto, os grupos encontrados foram excessivamente amplos e pouco informativos. A normalização por Z-score permitiu identificar sete agrupamentos distintos, produzindo uma segmentação mais detalhada dos clientes. O método Min-Max também apresentou melhora em relação aos dados brutos, porém produziu apenas dois agrupamentos principais.




Figura 8– Comparação dos resultados da clusterização utilizando diferentes métodos de normalização (Sem Normalização, Z-score e Min-Max).

Também foi aplicada a clusterização hierárquica utilizando os mesmos atributos empregados anteriormente.




Figura 9– Dendrograma utilizando Single Linkage.

O método Single identificou três clusters e apresentou Silhouette Score igual a 0,7408.




Figura 10– Dendrograma utilizando Average Linkage.

O método Average produziu dois clusters e apresentou Silhouette Score de 0,7941.




Figura 11– Dendrograma utilizando Complete Linkage.

O método Complete apresentou o melhor desempenho entre os métodos hierárquicos, alcançando Silhouette Score de 0,8307.

Por fim, foi avaliado o impacto da redução de dimensionalidade utilizando a Análise de Componentes Principais (PCA). Como apenas quatro atributos foram utilizados, o PCA preservou 100% da variância dos dados.




Figura 12– Variância explicada pelo PCA.

Para avaliar os efeitos da redução de dimensionalidade, foi utilizado o algoritmo KNN com e sem a aplicação do PCA. Os resultados mostraram que a acurácia permaneceu em 87,40% em ambos os cenários, indicando que a redução dimensional não impactou significativamente o desempenho do modelo.

Conforme observado na matriz de confusão, tanto no conjunto original quanto após a aplicação do PCA, o modelo classificou corretamente 1157 clientes da classe "no" e 29 da classe "yes". Além disso, ocorreram 44 falsos positivos e 127 falsos negativos, demonstrando que o PCA preservou praticamente todas as informações relevantes para a classificação.

De maneira geral, os resultados demonstraram que o PCA apresentou impacto reduzido devido à baixa dimensionalidade dos atributos utilizados. As análises realizadas ao longo do trabalho permitiram compreender o comportamento dos diferentes métodos estudados e reforçaram a importância das etapas de pré-processamento, normalização e escolha adequada de parâmetros para obtenção de resultados consistentes.



4. Conclusões

Os resultados obtidos ao longo deste trabalho demonstraram que o dataset Bank Marketing apresenta características adequadas para a aplicação de técnicas de aprendizado não supervisionado. A análise exploratória permitiu compreender a estrutura dos dados e identificar a existência de atributos com elevada variabilidade, reforçando a importância das etapas de pré-processamento e normalização.

A aplicação do algoritmo K-Means mostrou resultados satisfatórios, sendo identificado $K = 7$ como a melhor configuração segundo o critério de Silhouette Score. Os agrupamentos encontrados revelaram perfis distintos de clientes, especialmente em relação ao saldo bancário, duração dos contatos e quantidade de campanhas realizadas. A análise da variável de referência indicou que determinados clusters apresentaram taxas de conversão significativamente superiores às demais, evidenciando que os grupos encontrados possuem relevância prática para segmentação de clientes.

Na comparação entre os algoritmos, o DBSCAN demonstrou capacidade de identificar ruídos e observações atípicas, porém apresentou uma estrutura de agrupamento menos detalhada quando comparada ao K-Means. Já a clusterização hierárquica forneceu uma visão complementar dos dados, produzindo agrupamentos consistentes e confirmando parcialmente os padrões observados anteriormente.

A análise do impacto da normalização evidenciou que os resultados da clusterização são fortemente influenciados pela escala dos atributos. Embora os cenários sem normalização tenham apresentado valores elevados de Silhouette Score, a normalização por Z-score permitiu obter agrupamentos mais equilibrados e interpretáveis, favorecendo a análise dos perfis de clientes.

Na etapa de PCA e classificação supervisionada, verificou-se que a redução de dimensionalidade não alterou significativamente o desempenho do modelo avaliado. O KNN apresentou resultados idênticos antes e depois da aplicação do PCA, mantendo

acurácia de 87,40%. Isso indica que os atributos selecionados já representavam adequadamente a informação presente na base de dados.

De forma geral, os objetivos propostos para o trabalho foram alcançados com sucesso. As técnicas estudadas permitiram identificar padrões relevantes nos dados, comparar diferentes estratégias de agrupamento e compreender o impacto do pré-processamento e da redução de dimensionalidade sobre os resultados obtidos.

5. Próximos passos

Após a conclusão deste estudo, algumas possibilidades podem ser exploradas para aprofundar as análises realizadas. Uma delas consiste em utilizar um conjunto maior de atributos, incorporando variáveis categóricas por meio de técnicas de codificação apropriadas, como One-Hot Encoding, permitindo uma representação mais completa dos clientes.

Outra possibilidade é investigar algoritmos de clusterização mais avançados, como Gaussian Mixture Models (GMM), OPTICS ou Spectral Clustering, comparando seus resultados com aqueles obtidos pelo K-Means, DBSCAN e métodos hierárquicos.

Também seria interessante realizar uma análise mais aprofundada dos clusters encontrados, desenvolvendo perfis detalhados dos clientes e avaliando como essas segmentações poderiam ser utilizadas em estratégias reais de marketing bancário.

Em relação à etapa de classificação supervisionada, futuros trabalhos podem explorar diferentes configurações do algoritmo KNN e avaliar outros classificadores, permitindo verificar se a redução de dimensionalidade apresenta impacto mais significativo em cenários distintos

Por fim, recomenda-se a construção de dashboards interativos e visualizações mais avançadas para facilitar a interpretação dos resultados e apoiar processos de tomada de decisão baseados nos agrupamentos identificados. Dessa forma, o trabalho pode evoluir para aplicações mais próximas de cenários reais de análise de dados e inteligência artificial.