

Análise Estratégica e Modelagem de Dados

Cecília Maria Lima da Silva
Dayane Magalhães Ferreira
Suiany Pinto Gomes



UFC

Disciplina: Inteligência Artificial
Professor: Alysson Bezerra



Introdução

- Dataset utilizado: Bank Marketing
- Disponível no UCI Machine Learning Repository
- O Problema: Otimizar campanhas de marketing telefônico para depósitos a prazo.
- Objetivo: Identificar perfis naturais de clientes e avaliar a viabilidade de prever o sucesso das ligações.

Descrição do Dataset:

- 4.521 amostras
- 16 atributos (variáveis numéricas e categóricas)
- 1 variável alvo ('yes, no')

Visão Geral do Projeto

FLUXOGRAMA DO PROJETO





Análise Exploratória

Variáveis numéricas:

['age', 'balance', 'day', 'duration', 'campaign', 'pdays', 'previous'],
representam diferentes aspectos no comportamento de interação e históricos dos clientes.







Variáveis categóricas:

['job', 'marital', 'education', 'default', 'housing', 'loan', 'contact', 'month', 'poutcome', 'y'],
descrevem aspectos demográficos e comportamentais dos clientes.



Verificação de Problemas:

- Nenhum valor ausente;
- Nenhum registro duplicado;

Análise Exploratória




Análise Exploratória



Análise Exploratória


Comparação: Balance x Duration



K-Means e Escolha do Melhor K

Atributos utilizados:


- Age (Idade)
- Balance (Saldo Bancário)
- Duration (Duração do Contato)
- Campaign (Número de Contatos realizados durante a campanha)




Melhor K=7

Interpretação dos Cluters

Cluster	Idade Média	Saldo Médio	Duração Média (s)	Contatos Médios	Conversão (yes)
0	53 anos	R\$ 934	203 s (~3 min)	2,0	10,45%
1	41 anos	R\$ 715	160 s (~2 min)	7,8	2,11%
2	40 anos	R\$ 960	871 s (~14 min)	2,4	43,12% ★
3	40 anos	R\$ 7.158	222 s (~3 min)	2,4	9,12%
4	47 anos	R\$ 21.126	199 s (~3 min)	2,4	6,52%
5	33 anos	R\$ 679	200 s (~3 min)	1,9	7,89%
6	38 anos	R\$ 1.382	174 s (~3 min)	21,0	3,33%



Segmentação por Densidade (DBSCAN)



Resultado Obtido:

- Valor escolhido para $\text{eps} = 0.6$
- Valor adotado para $\text{min_samples} = 8$


Segmentação por Densidade e Detecção de Ruídos (DBSCAN)

RESULTADOS DO DBSCAN


Clusters encontrados: 2

Ruídos encontrados: 392

Percentual de ruídos: 8.67%



Técnica da escolha do melhor k




MELHOR K EM CADA CENÁRIO:

Sem normalização -> K=2 | Silhouette=0.8337

Z-score -> K=7 | Silhouette=0.3462

Min-Max -> K=2 | Silhouette=0.4387

Normalização na Clusterização



Normalização na Clusterização

Cenário de Escala	Melhor K	<u>Silhouette</u>	Cluster	<u>Qtd.</u> Absoluta de Clientes	Distribuição (%)	Conversão <u>no</u> (%)	Conversão <u>yes</u> (%)
Sem Normalização (Escala Original)	2	0.8337	0 1	4.295 226	95,0% 5,0%	88,34% 91,15%	11,66% 8,85%
Z-Score (<u>StandardScaler</u>)	7	0.3462	0 1 2 3 4 5 6	1.263 380 436 296 46 2.040 60	27,9% 8,4% 9,6% 6,5% 1,0% 45,1% 1,3%	89,55% 97,89% 56,88% 90,88% 93,48% 92,11% 96,67%	10,45% 2,11% 43,12% 9,12% 6,52% 7,89% 3,33%
Min-Max (<u>MinMaxScaler</u>)	2	0.4387	0 1	2.823 1.698	62,4% 37,6%	89,20% 87,28%	10,80% 12,72%



Clusterização Hierárquica e Dendrograma

- Dados normalizados utilizando StandardScaler (Z-score).
- Amostra utilizada para os dendrogramas: 300 registros

Métodos de Ligação Testados:

Single Linkage (Menor distância entre clusters)

Average Linkage (Distância média entre clusters)

Complete Linkage (Maior distância entre clusters)




Métrica de Avaliação (Silhouette Score):

- Coesão interna dos clusters
- Separação entre grupos

Quanto mais próximo de 1:

- Melhor a qualidade da clusterização

Dendrogramas Gerados



COMPARAÇÃO DOS MÉTODOS

Método | Clusters | Silhouette

Single | 3 | 0.7408

Average | 2 | 0.7941

Complete | 2 | 0.8307

PCA(Análise de Componentes Principais)

Etapas realizadas:

- Seleção dos atributos: Age, Balance, Duration, Campaign
- Normalização dos dados com StandardScaler.
- Aplicação do PCA.
- Treinamento do algoritmo KNN: 30% teste - 70% treino
 - Sem PCA.
 - Com PCA.
- Aplicação do PCA ((n_components=0.95)

Variável-alvo

- $y = \text{yes}$ (aceitou o depósito)
- $y = \text{no}$ (não aceitou o depósito)

Aplicação KNN com ou sem PCA

KNN - DADOS ORIGINAIS e COM PCA

ANÁLISE DO PCA

Componentes originais: 4


Componentes após PCA: 4

Variância preservada: 100.00%

=====

	precision	recall	f1-score	support
no	0.90	0.96	0.93	1201
yes	0.40	0.19	0.25	156
accuracy			0.87	1357
macro avg	0.65	0.57	0.59	1357
weighted avg	0.84	0.87	0.85	1357

Comparação e Conclusão



Métrica	Sem PCA	Com PCA
Accuracy	87,4%	87,4%
Precisão (yes)	0,40	0,40
Recall (yes)	0,19	0,19
F1-score (yes)	0,25	0,25
Tempo (s)	0,0082	0,0070

Análise e Conclusão

Principais Resultados:

- ✓ Dataset consistente sem valores ausentes e sem registros duplicados.
- ✓ A análise visual indicou que dois atributos não representam toda a estrutura dos dados.
- ✓ O K-Means encontrou 7 clusters após normalização Z-score.
- ✓ O DBSCAN identificou 2 clusters principais e pontos de ruído.
- ✓ A clusterização hierárquica também sugeriu 2 grandes grupos.
- ✓ O PCA não reduziu a dimensionalidade e não alterou o desempenho do KNN.

Conclusão

- ✓ A normalização influenciou significativamente os resultados da clusterização.
- ✓ Diferentes algoritmos identificaram estruturas distintas nos dados.
- ✓ A combinação das técnicas permitiu uma análise mais completa e confiável dos agrupamentos.

Próximos Passos

- Incluir novos atributos (pdays, previous, housing e loan).
- Comparar K-Means e DBSCAN com outros algoritmos de agrupamento.
- Aplicar técnicas de balanceamento .
- Testar modelos supervisionados adicionais.
- Realizar seleção de atributos para reduzir redundâncias e melhorar o desempenho dos modelos.

OBRIGADO!