

TECHNICAL REPORT

Relatório de Aprendizado Não Supervisionado – Análise de Clusterização e Redução de Dimensionalidade

Alunos: Kevin Emmanuel Sousa Pontes, Antonio Sampaio De Marinho, Ramon Jordão Gomes Barroso

1. Introdução

O presente relatório documenta o desenvolvimento de um estudo prático de aprendizado não supervisionado e avaliação de impacto de redução de dimensionalidade. O objetivo principal foi explorar um conjunto de dados, investigar padrões naturais de comportamento de consumo, aplicar técnicas de agrupamento (Clustering) e analisar o impacto da extração de características via PCA utilizando modelos classificadores para validação.

Para este estudo, foi utilizado o Credit Card Dataset for Clustering, disponível publicamente no Kaggle. O dataset resume o comportamento de uso de aproximadamente 9.000 clientes de cartão de crédito durante um período de 6 meses. Ao todo, o conjunto contém 18 variáveis originais: uma variável de identificação (CUST_ID), que identifica unicamente cada cliente e foi desconsiderada na modelagem, e 17 atributos operacionais e financeiros detalhados a seguir:

Atributo	Descrição	Tipo
CUST_ID	Identificação do titular do cartão	Nominal
BALANCE	Saldo disponível na conta	Contínua
BALANCE_FREQUENCY	Frequência de atualização do saldo (0–1)	Contínua
PURCHASES	Valor total de compras	Contínua
ONEOFF_PURCHASES	Valor máximo de compra em uma só vez	Contínua
INSTALLMENTS_PURCHASES	Valor total de compras parceladas	Contínua
CASH_ADVANCE	Adiantamento em dinheiro (saque)	Contínua
PURCHASES_FREQUENCY	Frequência de compras (0–1)	Contínua
ONEOFF_PURCHASES_FREQUENCY	Frequência de compras à vista (0–1)	Contínua
PURCHASES_INSTALLMENTS_FREQUENCY	Frequência de compras parceladas (0–1)	Contínua
CASH_ADVANCE_FREQUENCY	Frequência de uso do saque	Contínua
CASH_ADVANCE_TRX	Nº de transações de saque	Discreta
PURCHASES_TRX	Nº de transações de compra	Discreta
CREDIT_LIMIT	Limite do cartão	Contínua
PAYMENTS	Valor total de pagamentos	Contínua
MINIMUM_PAYMENTS	Valor mínimo de pagamentos	Contínua
PRC_FULL_PAYMENT	Percentual de pagamento total	Contínua
TENURE	Tempo de uso do serviço (meses)	Discreta


2. Observações

O dataset original, composto por 8.950 registros e 18 colunas, foi inicialmente inspecionado em busca de inconsistências. Dado este conjunto, 14 variáveis são do tipo contínuas, 3 são discretas e a coluna CUST_ID foi removida já que sua função é resumida apenas à identificação dos clientes. Em seguida, verificou-se a presença de duplicatas (nenhuma encontrada) e de valores negativos em variáveis contínuas ou de frequência. Os valores ausentes concentraram-se em duas colunas: CREDIT_LIMIT (1 valor faltante) e MINIMUM_PAYMENTS (313 valores faltantes). O único registro com CREDIT_LIMIT nulo foi removido. Para MINIMUM_PAYMENTS, utilizou-se imputação pela mediana, procedimento que preserva a distribuição central da variável sem ser influenciado por valores extremos.


Disparidade de Escalas e Multicolinearidade: Variáveis baseadas em valores monetários absolutos (ex: BALANCE, CREDIT_LIMIT) operam em ordens de grandeza de milhares de unidades, enquanto taxas de frequência (ex: PURCHASES_FREQUENCY) variam estritamente entre 0 e 1. Essa diferença massiva de escala exigiu a aplicação rigorosa de normalização antes de qualquer algoritmo de agrupamento geométrico. Além disso, a altíssima correlação observada entre algumas variáveis de frequência e volume financeiro confirmou a necessidade de uma compressão via PCA (Análise de Componentes Principais).

Resultados e discussão

O dataset original, composto por 8.950 registros e 18 colunas totais (17 das quais são numéricas e preditivas), passou por inspeção visual inicial. Os boxplots confirmaram a existência de outliers massivos na cauda superior de variáveis financeiras de fluxo e obrigações, evidenciados de forma mais crítica em MINIMUM_PAYMENTS (apresenta o valor discrepante mais extremo do conjunto de dados), seguido por PAYMENTS, PURCHASES e CASH_ADVANCE.




Para investigar a viabilidade de identificar agrupamentos naturais de forma puramente visual, foram testadas exaustivamente 12 combinações de atributos numéricos por meio de análises de densidade via KDE (Kernel Density Estimation), conforme apresentado na figura a seguir. A partir desse mapeamento preliminar, o par de variáveis $PRC_FULL_PAYMENT \times CREDIT_LIMIT$ foi selecionado para a construção do gráfico de dispersão por unir uma forte interpretabilidade de negócio — cruzando o comportamento de pagamento integral com o porte financeiro do cliente — à necessidade metodológica de evitar variáveis redundantes que gerassem padrões artificiais na distribuição dos dados.



Contudo, mesmo com a seleção do par mais promissor, a inspeção visual revela uma intensa sobreposição dos dados, sem qualquer separação natural ou delimitação de fronteiras claras entre potenciais grupos. Esse cenário funciona como uma evidência

prática de que apenas dois atributos originais são insuficientes para representar a estrutura complexa e de alta dimensionalidade do dataset, justificando de forma sólida a aplicação das técnicas de clusterização multivariada abordadas nas próximas questões.

Para identificar o grau de associação linear entre as variáveis preditivas e avaliar a presença de multicolinearidade no conjunto de dados, foi gerada a matriz de correlação apresentada na figura a seguir. Essa etapa é fundamental para validar a viabilidade da redução de dimensionalidade por meio do PCA.



A análise da matriz de correlação linear revelou fortes padrões de associação e multicolinearidade entre as variáveis do dataset, o que justifica e reforça a aplicação da Análise de Componentes Principais (PCA) para a redução de dimensionalidade. Dentro desse cenário, destacam-se blocos principais de alta correlação positiva com valores próximos ou superiores a 0.80, a começar pelo comportamento de saques em dinheiro (Cash Advance), que apresenta uma correlação quase perfeita entre o número de transações de saque e a sua frequência (CASH_ADVANCE_TRX e




CASH_ADVANCE_FREQUENCY com 0.98), além de uma associação muito forte com o valor total sacado (CASH_ADVANCE com 0.94 e 0.95). Paralelamente, o volume e a frequência de compras também exibem forte colinearidade, visto que o volume total de compras (PURCHASES) está intimamente ligada ao número total de transações (PURCHASES_TRX com 0.89) e à frequência geral de compras (PURCHASES_FREQUENCY com 0.79). Essa dinâmica se estende à segmentação de compras parceladas versus compras à vista, onde a frequência de compras parceladas (PURCHASES_INSTALLMENTS_FREQUENCY) está altamente associada ao valor total parcelado (INSTALLMENTS_PURCHASES com 0.92), assim como a frequência de compras de pagamento único (ONEOFF_PURCHASES_FREQUENCY) vincula-se fortemente ao valor total de compras à vista (ONEOFF_PURCHASES com 0.95). Por fim, nota-se a forte correlação de 0.87 entre o saldo devedor (BALANCE) e os pagamentos mínimos realizados (MINIMUM_PAYMENTS), indicando que o endividamento acumulado dita diretamente o patamar das obrigações mínimas de pagamento dos clientes.

A análise detalhada da matriz permitiu isolar os pares de variáveis com coeficiente de correlação linear absoluto igual ou superior a 0,75, indicando um cenário de multicolinearidade severa que poderia distorcer o peso dos componentes no PCA. Para mitigar essa redundância com a menor perda possível de informação, aplicou-se um critério de filtragem onde a variável menos informativa ou mais redundante sob a ótica do negócio foi removida de cada par. No bloco de saques, priorizou-se o valor financeiro total (CASH_ADVANCE) em detrimento da frequência e do número de transações (CASH_ADVANCE_FREQUENCY e CASH_ADVANCE_TRX), uma vez que o volume monetário reflete melhor o risco e o perfil de crédito do cliente. De forma análoga, no bloco focado no consumo, o volume total de compras (PURCHASES), as compras parceladas (INSTALLMENTS_PURCHASES) e as compras à vista (ONEOFF_PURCHASES) foram mantidos como as métricas financeiras centrais de volume, resultando na eliminação de suas respectivas frequências (PURCHASES_FREQUENCY, PURCHASES_INSTALLMENTS_FREQUENCY, ONEOFF_PURCHASES_FREQUENCY) e contagens agregadas (PURCHASES_TRX), que operavam de forma puramente colinear. Por fim, no par de endividamento, optou-se pela preservação do saldo devedor (BALANCE) como indicador macro do comportamento financeiro, descontinuando a variável de pagamentos mínimos (MINIMUM_PAYMENTS). Essa estratégia de seleção garante um espaço de atributos otimizado, mantendo a integridade do comportamento financeiro e preparando o dataset para uma projeção de componentes principais mais enxuta e interpretável.




Para descobrir o número ideal de grupos (clusters), o algoritmo K-Means foi testado com diferentes quantidades de k e com duas metodologias diferentes. Essa análise foi feita usando a ferramenta KElbowVisualizer, que mede o nível de erro (inércia) de cada tentativa.



A definição do número ideal de clusters k para o algoritmo K-Means foi realizada a partir da análise comparativa e visual de duas abordagens métricas: o Método do


Cotovelo (*Distortion Elbow*) e o Método da Silhueta (*Silhouette Score*). Pela inspeção visual direta das marcações de corte estabelecidas nas ferramentas, observou-se uma divergência entre os indicadores: o gráfico de distorção sugeriu uma estrutura baseada em $k=5$ grupos, enquanto o comportamento do coeficiente de silhueta apontou o pico máximo de separação e coesão dos dados em $k=2$. Diante desse impasse métrico entre os dois extremos validados visualmente, adotou-se o valor de $k=3$ como um ponto de equilíbrio estrito (meio do caminho inteiro). Essa escolha concilia de forma estratégica os dois cenários, permitindo uma segmentação de clientes que não é tão restrita quanto a solução de dois grupos, nem tão pulverizada quanto a de cinco, garantindo relevância prática para a regra de negócio e para a posterior interpretação dos perfis de consumo.



O gráfico de dispersão gerado a partir do agrupamento do K-Means ($k=3$) demonstra uma separação nítida dos perfis de clientes com base no limite de crédito e no comportamento de quitação de faturas. O Cluster 0 (roxo/escuro) concentra majoritariamente a base de clientes com limites mais baixos (concentrados abaixo de 5.000), independentemente do seu percentual de pagamento integral. Em contrapartida, os clientes com limites mais elevados foram divididos pelo comportamento de pagamento: o Cluster 1 (verde/azul) engloba os usuários de alto limite com uma distribuição intermediária ou nula de pagamento integral, enquanto o

Cluster 2 (amarelo/claro) destaca-se por mapear os clientes de alto limite que possuem maior recorrência e concentração em faixas superiores de pagamento total da fatura. Essa visualização confirma a capacidade do modelo em segmentar os clientes combinando o poder de compra instalado com a sua respectiva saúde financeira.


A análise da tabulação cruzada obtida após a aplicação da regra de Sturges revela de forma empírica as limitações matemáticas desse método de discretização quando confrontado com variáveis financeiras altamente assimétricas e repletas de valores discrepantes. Conforme observado no mapa de calor de contingência, a fórmula dividiu o limite de crédito em quinze intervalos de larguras idênticas com base na amplitude total, que é estendida até o limite máximo pelos outliers da cauda superior mapeados no início do trabalho.




Como consequência direta dessa divisão em intervalos uniformes, a vasta maioria dos dados acabou concentrada exclusivamente nos primeiros blocos. O Cluster 0 distribui seus milhares de registros somente entre os intervalos de zero a três, indicando de forma clara que este grupo reúne a fatia de clientes com menor poder de compra instalado na base de dados. O Cluster 1 demonstra um deslocamento sutil para o centro da distribuição, concentrando o grosso de seus usuários entre as faixas dois e cinco, o que sinaliza um perfil de limite intermediário. Por fim, o Cluster 2, embora possua um volume amostral significativamente menor, mostra-se pulverizado ao longo de quase todos os intervalos, alcançando de forma isolada as últimas faixas da discretização.


Para avaliar a sensibilidade do algoritmo K-Means frente à preparação dos dados, estruturou-se uma análise comparativa submetendo o dataset a quatro diferentes estratégias de pré-processamento: StandardScaler, RobustScaler, MinMaxScaler e a

transformação logarítmica Log1p . A avaliação combinada das curvas de distorção e dos coeficientes de silhueta revelou comportamentos métricos muito distintos para cada cenário. O `MinMaxScaler` apresentou a menor variação de inércia, sugerindo uma estrutura matemática ideal com apenas três clusters, enquanto os escaladores baseados em padronização linear indicaram soluções mais fragmentadas, apontando para seis grupos no `RobustScaler` e sete ou oito grupos no `StandardScaler`. Por sua vez, a aplicação da transformação Log1p destacou-se ao alcançar o maior coeficiente de silhueta absoluto do experimento, superior a 0.50, estabelecendo um ponto de corte sugerido em três ou quatro clusters.







Essa divergência métrica reflete-se diretamente na inspeção visual dos gráficos de dispersão finais, onde os dados foram projetados sob os eixos do limite de crédito e do percentual de pagamento integral. Nos cenários utilizando StandardScaler, RobustScaler e MinMaxScaler, a forte assimetria original e a presença de outliers massivos continuaram exercendo grande influência geométrica, resultando em uma clusterização que pulveriza os dados em faixas verticais e sobreposições densas de cores, o que dificulta a distinção clara de perfis independentes. Em contrapartida, o mapeamento gerado após a aplicação do Log1p com três clusters exibiu a distribuição mais homogênea e bem delimitada do experimento. Ao estabilizar a variância das caudas longas e suavizar o efeito dos valores extremos, a transformação logarítmica permitiu que o K-Means segmentasse a base de forma mais equilibrada e geometricamente interpretável, consolidando-se como a abordagem de pré-processamento mais eficaz para evidenciar os verdadeiros padrões de comportamento financeiro dos clientes.





A análise comparativa das tabelas cruzadas reforça o impacto de cada método de pré-processamento na organização interna dos grupos. Nos modelos utilizando *StandardScaler*, *RobustScaler* e *MinMaxScaler*, a manutenção da escala linear original fez com que o algoritmo gerasse soluções com maior número de clusters (de cinco a sete), porém mantendo uma alta concentração de registros espremidos estritamente nas primeiras faixas de limite de crédito (colunas zero a três) devido ao peso dos outliers de limite alto que isolam as últimas colunas. Em contrapartida, a abordagem utilizando *Log1p*, configurada com apenas três clusters, promoveu a distribuição mais equilibrada e progressiva da base de dados. Ao suavizar o efeito dos valores extremos, o *Log1p* permitiu separar os clientes de forma clara entre um grupo de limites baixos (Cluster 1), limites intermediários (Cluster 0) e limites altos (Cluster 2), preenchendo as faixas de discretização de maneira muito mais suave, contínua e útil para a interpretação do negócio.

A fim de mapear os agrupamentos por densidade espacial e identificar potenciais anomalias no comportamento dos clientes, aplicou-se o algoritmo DBSCAN sem normalização e também sob as quatro estruturas de normalização previamente testadas. A parametrização do raio de vizinhança (Epsilon) foi definida metodologicamente a partir do gráfico de k-distância ao 18º vizinho, buscando o ponto de inflexão máximo (método do cotovelo) para cada cenário. Essa estratégia resultou em valores de Epsilon drasticamente distintos devido à escala geométrica de cada preparação, variando de 0.18 no MinMaxScaler até 2.13 no RobustScaler.











A análise cruzada entre os gráficos de dispersão e os mapas de calor de contingência revela que o DBSCAN expôs com clareza a severa concentração de densidade induzida pelas escalas lineares. Nas abordagens com *StandardScaler* e *RobustScaler*, a quase totalidade dos clientes foi compactada em um único grande agrupamento central (Cluster 0), restando apenas um pequeno volume periférico classificado como ruído (Cluster -1). O *MinMaxScaler* conseguiu fracionar a base de forma sutil em três grupos de densidade, mas ainda manteve um gigantismo absoluto concentrado no Cluster 0.

O melhor equilíbrio estrutural foi alcançado novamente pela transformação *Log1p*. Ao atenuar a assimetria das caudas longas, o *Log1p* permitiu ao DBSCAN mapear quatro agrupamentos de densidade bem delimitados e com distribuições progressivas ao

longo das faixas de limite de crédito (Sturges), além de isolar eficientemente as verdadeiras anomalias de alta renda na classe de ruídos (-1). Esse resultado consolida a transformação logarítmica como o pré-processamento indispensável para viabilizar tanto algoritmos de partição quanto de densidade nesta base de dados.

Para expandir a investigação sobre a estrutura de agrupamento do dataset, implementou-se a clusterização hierárquica aglomerativa utilizando a métrica de distância euclidiana sobre os dados preparados com o RobustScaler. O comportamento do algoritmo foi testado sob quatro diferentes critérios de ligação (linkage), mapeando as últimas cinquenta fusões de ramificações por meio de dendrogramas estruturados para identificar a consistência geométrica de cada abordagem.






A análise comparativa dos dendrogramas expõe de forma evidente os efeitos colaterais provocados pela assimetria e presença de valores discrepantes nos critérios baseados em distâncias extremas ou médias. No método single linkage, que adota a distância mínima entre membros de grupos distintos, observou-se o clássico fenômeno do encadeamento (chaining effect). Ao estabelecer uma linha de corte na distância quinze, o modelo isolou dois ruídos nas ramificações iniciais da esquerda e condensou os milhares de clientes restantes em um único bloco massivo, inviabilizando uma segmentação comercial útil. Comportamento semelhante ocorreu no método average linkage, onde o corte na altura trinta e cinco gerou apenas duas partições, das quais uma é composta por um único registro isolado na extrema esquerda, demonstrando a sensibilidade excessiva da média perante os outliers preservados pelo RobustScaler.


O método complete linkage, que avalia a distância máxima entre pontos, ofereceu uma estrutura ligeiramente mais equilibrada ao fatar o dendrograma na altura quarenta, o que resultou em três agrupamentos. Contudo, a melhor distribuição volumétrica e

coerência topológica foi alcançada pelo critério de mínima variância de Ward. Ao focar na minimização da inércia interna a cada fusão, o método de Ward atenuou o impacto visual dos outliers nas ramificações superiores e gerou uma estrutura em árvore altamente simétrica e compacta. O estabelecimento de uma linha de corte na distância duzentos resultou na criação de quatro clusters equilibrados e bem delimitados, consolidando o critério de Ward como a única abordagem hierárquica capaz de criar perfis de consumo proporcionais e com relevância prática para as regras de negócio de cartões de crédito neste cenário.



A fim de criar uma variável alvo para alimentar a etapa de aprendizado supervisionado, consolidou-se a clusterização hierárquica aglomerativa com o critério de ligação de Ward configurada para quatro grupos. O algoritmo segmentou a base de dados de forma bem distribuída, concentrando o maior volume amostral no cluster dois (6.108 registros) e dividindo o restante de forma progressiva entre os clusters um, zero e três. A projeção visual dos rótulos gerados nos eixos do limite de crédito e do percentual de pagamento integral confirma que a combinação do RobustScaler com a métrica de Ward obteve sucesso em criar fronteiras geometricamente nítidas e perfis de consumo proporcionais, prontos para serem previstos e validados pelos modelos classificadores subsequentes.

Para reduzir a dimensionalidade do dataset e concentrar a maior quantidade possível de informação estatística em eixos ortogonais e linearmente independentes, aplicou-se a Análise de Componentes Principais (PCA) sobre as variáveis previamente normalizadas com o RobustScaler. O gráfico de barras gerado permite avaliar a importância individual de cada componente a partir da sua respectiva razão de variância explicada.



Observa-se que o primeiro componente principal (PC1) destaca-se de forma absoluta, concentrando sozinho pouco mais de 30% de toda a variabilidade contida no conjunto de dados original. O segundo componente (PC2) retém uma fatia complementar relevante perto de 20%, enquanto os demais eixos (do PC3 ao PC10) apresentam um decaimento progressivo e suave na captura da variância residual. Esse comportamento demonstra a eficiência do PCA para esta base de dados: ao condensar metade de toda a informação do dataset apenas nas duas primeiras dimensões (PC1 e PC2), o método valida a viabilidade de simplificar o espaço vetorial e otimizar o processamento dos algoritmos, permitindo representações visuais bidimensionais ou tridimensionais altamente fiéis à estrutura original dos dados de consumo e crédito dos clientes.

Para validar a consistência geométrica e o grau de separação dos quatro agrupamentos gerados pelo método hierárquico aglomerativo de Ward, realizou-se a projeção dos dados sobre os espaços latentes bidimensional e tridimensional gerados pela Análise de Componentes Principais (PCA). Os gráficos de dispersão foram mapeados colorindo cada registro estritamente de acordo com o seu respectivo cluster alvo.



A visualização do PCA em duas dimensões, que retém metade de toda a variabilidade dos dados originais, demonstra uma setorização nítida dos perfis. O primeiro componente principal atua como um divisor primário eficiente, isolando de forma clara o cluster dois na região central e esquerda da distribuição. O segundo componente principal assume o papel de discriminar os agrupamentos restantes de forma vertical, estabelecendo fronteiras bem definidas para os clusters zero, um e três nas faixas superiores e inferiores do plano.

Essa separação e a transição suave de densidade tornam-se ainda mais evidentes na projeção tridimensional, onde a inclusão do terceiro componente eleva a variância acumulada explicada para a faixa de sessenta por cento. A distribuição tridimensional das cores confirma que o modelo aglomerativo foi capaz de capturar e preservar a estrutura de vizinhança natural dos clientes. O mapeamento valida empiricamente a alta coesão interna dos grupos construídos e atesta a qualidade da variável target que será utilizada para orientar e treinar os algoritmos de aprendizado supervisionado subsequentes.

Quando adicionamos a terceira dimensão (PC3), o gráfico ganha profundidade. Como o PC3 captura uma variância residual mais sutil — e que provavelmente está associada a

variações de comportamento dos outros grupos maiores (como o grupo verde/azul claro e o amarelo) —, os milhares de pontos desses outros grupos se espalham como uma "nuvem" tridimensional espessa. Como o Cluster 0 compartilha valores muito baixos e concentrados nessas dimensões extras, ele acaba ficando geometricamente "escondido" ou envelopado logo atrás ou por baixo dessa grande massa de dados quando giramos o gráfico em 3D.


Para dar início à etapa de modelagem supervisionada, implementou-se o algoritmo de classificação vizinhos mais próximos (KNN) com o objetivo de prever o pertencimento dos clientes nos quatro clusters previamente estabelecidos pelo método hierárquico de Ward. A divisão entre os conjuntos de treino (oitenta por cento) e teste (vinte por cento) foi realizada de forma puramente estratificada para preservar a distribuição volumétrica original das classes. A fim de encontrar a especificação ótima para o classificador, estruturou-se uma busca experimental avaliando o comportamento do hiperparâmetro k (variando de dois a vinte vizinhos) sob a combinação de três técnicas de preparação de dados (StandardScaler, MinMaxScaler e Log1p) e dois conjuntos de atributos distintos (todas as colunas originais versus os quatro primeiros componentes principais extraídos via PCA).

	normalizacao	features	n_neighbors	accuracy	precision	recall	f1
0	StandardScaler	Todas as colunas	3	0.984916	0.984882	0.984916	0.984874
1	StandardScaler	Top 4 PCA	8	0.951955	0.951522	0.951955	0.950891
2	MinMaxScaler	Todas as colunas	7	0.956983	0.956416	0.956983	0.954190
3	MinMaxScaler	Top 4 PCA	4	0.931285	0.927421	0.931285	0.921285
4	Log1p	Todas as colunas	3	0.894972	0.893057	0.894972	0.893615
5	Log1p	Top 4 PCA	20	0.851397	0.853684	0.851397	0.848773

Os resultados experimentais apontam que o classificador KNN obteve um desempenho preditivo excelente, alcançando índices de acerto quase perfeitos. A configuração de desempenho máximo absoluto foi obtida pela associação do StandardScaler ao conjunto completo de colunas originais e parametrizada com apenas 3 vizinhos próximos, atingindo a marca de 98,49% de acurácia e f1-score ponderado. O MinMaxScaler com todas as colunas e 7 vizinhos também demonstrou alta capacidade preditiva ao registrar 95,70% de acurácia. Nota-se que a transformação Log1p e as reduções de dimensionalidade para os 4 componentes principais do PCA, embora tenham mantido desempenhos sólidos acima de 85%, ficaram consistentemente abaixo

da padronização linear completa, confirmando que a manutenção do espaço vetorial original via *StandardScaler* preservou os gradientes e as distâncias ideais para a perfeita segregação e classificação dos perfis de clientes.

A análise comparativa das 6 matrizes de confusão geradas para o classificador KNN confirma visualmente o comportamento das métricas globais observadas na tabela de desempenho. Na primeira matriz, correspondente ao *StandardScaler* utilizando todas as colunas, a diagonal principal apresenta-se altamente concentrada e limpa, reiterando a capacidade máxima do modelo em discriminar os 4 clusters com o menor índice de erro do experimento.



À medida que se avança para os cenários com *MinMaxScaler* e para as reduções dimensionais via *Top 4 PCA*, nota-se o surgimento gradual de registros fora da diagonal principal, indicando pequenas dispersões e erros de classificação, principalmente entre os grupos de menor volume amostral. Por fim, as duas últimas matrizes vinculadas à transformação *Log1p* exibem os maiores volumes de falsos positivos e falsos negativos espalhados fora da diagonal, o que corrobora o menor rendimento preditivo dessa abordagem e evidencia geometricamente a dificuldade do algoritmo KNN em estabelecer fronteiras de vizinhança nítidas quando submetido à escala logarítmica.

3. Conclusões

A jornada experimental evidenciou que a escolha da técnica de preparação de dados é o fator determinante para o sucesso dos modelos em cada etapa do pipeline. Na fase não supervisionada, a consolidação da variável alvo por meio da Clusterização Hierárquica Aglomerativa com o critério de Ward provou-se a decisão metodológica mais acertada para a base de cartões de crédito. Ao focar na minimização da variância interna dos grupos, o método de Ward gerou 4 agrupamentos geometricamente equilibrados e altamente interpretáveis para o negócio, distribuindo os 8949 clientes de forma progressiva, sendo 6108 no Cluster 2, 1173 no Cluster 1, 983 no Cluster 0 e 685 no Cluster 3.

A redução de dimensionalidade para o espaço latente da Análise de Componentes Principais (PCA) cumpriu um papel crítico de auditoria estatística, retendo aproximadamente 50% da variabilidade total do dataset nos 2 primeiros componentes e cerca de 60% no terceiro, o que confirmou a alta coesão interna e as fronteiras de separação nítidas dos grupos de clientes. Esse mapeamento também revelou nuances importantes, como o comportamento do Cluster 0, que se mostrou isolado na lateral esquerda do plano 2D, mas acabou visualmente envelopado pela expansão dos demais grupos na perspectiva 3D, validando a necessidade técnica de cruzar diferentes perspectivas dimensionais.

Na etapa de classificação supervisionada, o experimento de busca em grade com o classificador KNN revelou que, embora a transformação Log1p tenha sido testada como uma alternativa de normalização, ela acabou entregando o pior rendimento do teste, limitando a acurácia do classificador à faixa de 85% a 89%. O desempenho máximo absoluto foi alcançado pelo StandardScaler utilizando o espaço vetorial completo de atributos com $k=3$ vizinhos, atingindo a marca de 98,49% de acurácia e f1-score. Esse resultado confirma que a manutenção das distâncias lineares padronizadas fornece o cenário ideal para o poder preditivo do KNN, superando inclusive a redução por PCA.

Com um classificador operando com mais de 98% de assertividade, o pipeline consolida-se como uma ferramenta automatizada de inteligência de mercado pronta para entrar em ambiente de produção. Isso permite que o sistema preveja instantaneamente o perfil de consumo de novos clientes a partir de suas variáveis originais padronizadas, viabilizando tomadas de decisão estratégicas em tempo real,



como a concessão inteligente de limites de crédito e a personalização de campanhas de engajamento financeiro.

4. Próximos passos

Como próximos passos para a continuidade deste projeto, sugere-se a realização do profiling dos 4 clusters descobertos, analisando as médias das variáveis originais para atribuir um significado comercial e operacional claro a cada perfil comportamental de cliente. Na sequência, deve-se estruturar o deploy do pipeline automatizado baseado no modelo campeão (StandardScaler com KNN de 3 vizinhos) para classificar novos registros em tempo real diretamente no momento do cadastro. Essa implementação prática viabilizará a tomada de decisão estratégica instantânea, permitindo a aplicação automatizada de políticas personalizadas para concessão de limites de crédito, a mitigação proativa de riscos financeiros e o direcionamento de campanhas de marketing focadas na realidade de consumo de cada grupo identificado.