



Segmentação de Clientes de Cartão de Crédito

Clusterização, comparação de algoritmos, normalização e PCA

Visão Geral do Estudo

Objetivo

- Explorar os dados e investigar padrões naturais de comportamento dos clientes.
- Aplicar clusterização (K-Means, DBSCAN, hierárquica) e comparar os algoritmos.
- Avaliar o impacto do pré-processamento (normalização) na qualidade dos grupos.
- Reduzir a dimensionalidade com PCA e medir o efeito na classificação supervisionada.

As 7 questões da avaliação

Q	Tema	Pts
Q1	Análise exploratória dos dados	0,5
Q2	Análise visual com dois atributos	0,5
Q3	K-Means: cotovelo, Silhouette e crosstab	2,0
Q4	Comparação K-Means × DBSCAN	2,0
Q5	Impacto da normalização	1,0
Q6	Clusterização hierárquica e dendrograma	1,0
Q7	PCA × classificação supervisionada	2,0

O Conjunto de Dados — 18 Atributos

Atributo	Descrição	Tipo
CUST_ID	Identificação do titular do cartão	Nominal
BALANCE	Saldo disponível na conta	Contínua
BALANCE_FREQUENCY	Frequência de atualização do saldo (0–1)	Contínua
PURCHASES	Valor total de compras	Contínua
ONEOFF_PURCHASES	Valor máximo de compra em uma só vez	Contínua
INSTALLMENTS_PURCHASES	Valor total de compras parceladas	Contínua
CASH_ADVANCE	Adiantamento em dinheiro (saque)	Contínua
PURCHASES_FREQUENCY	Frequência de compras (0–1)	Contínua
ONEOFF_PURCHASES_FREQUENCY	Frequência de compras à vista (0–1)	Contínua
PURCHASES_INSTALLMENTS_FREQUENCY	Frequência de compras parceladas (0–1)	Contínua
CASH_ADVANCE_FREQUENCY	Frequência de uso do saque	Contínua
CASH_ADVANCE_TRX	Nº de transações de saque	Discreta
PURCHASES_TRX	Nº de transações de compra	Discreta
CREDIT_LIMIT	Limite do cartão	Contínua
PAYMENTS	Valor total de pagamentos	Contínua
MINIMUM_PAYMENTS	Valor mínimo de pagamentos	Contínua
PRC_FULL_PAYMENT	Percentual de pagamento total	Contínua
TENURE	Tempo de uso do serviço (meses)	Discreta

Leitura inicial

- **8.950 clientes e 18 colunas.**
- **CUST_ID é só identificador → removida (restam 17 atributos).**
- **14 contínuas e 3 discretas de contagem.**
- **Sem variável-alvo → agrupamento não supervisionado.**

Qualidade dos Dados e Estatísticas

Problemas e decisões

Problema	Achado	Decisão
Duplicatas	0	Nenhuma ação
Negativos	0	Nenhuma ação
CASH_ADV_FREQ	8 valores > 1	Removida na seleção
MINIMUM_PAYMENTS	313 nulos (3,50%)	Imputação pela mediana
CREDIT_LIMIT	1 nulo (0,01%)	Linha removida





Observações

- Imputar o único nulo de CREDIT_LIMIT não compensava → linha descartada.
- MINIMUM_PAYMENTS: imputação pela mediana (robusta a outliers).
- TENURE quase constante: 84,75% dos clientes com 12 meses — mantida por ainda segmentar.

Estatísticas descritivas (variáveis-chave)

Variável	Média	DP	Mín	Median a	Máx
BALANCE	1.564	2.082	0	873	19.043
PURCHASES	1.003	2.137	0	361	49.040
CASH_ADVANCE	979	2.097	0	0	47.137
CREDIT_LIMIT	4.494	3.639	50	3.000	30.000
PAYMENTS	1.733	2.895	0	857	50.721
MINIMUM_PAYMENTS	864	2.372	0,02	312	76.406
PRC_FULL_PAYMENT	0,15	0,29	0	0	1
TENURE	11,5	1,34	6	12	12

Distribuições das Variáveis Contínuas







Leitura inicial

- Monetárias (saldo, gasto, limite, pgto mín.): pico no zero + cauda → assimetria à direita
- % paga fatura toda: concentrado no zero → maioria raramente paga integral
- Frequência de compra: bimodal (picos em 0 e 1) → dois perfis: quase não compra × compra sempre

Forte assimetria à direita nas variáveis monetárias (saldo, compras, saques) — distribuições muito concentradas perto de zero, com cauda longa.



Variáveis Discretas e Outliers



Observações

- Algumas colunas têm uma nuvem enorme de pontinhos(outliers) subindo, ou seja, são valores extremos confirmando a assimetria que vimos anteriormente.
- CASH_ADVANCE_TRX (nº de saques): barra gigante no 0 e logo despenca. Basicamente a maioria nunca sacou dinheiro (zero saques). Bate com a mediana 0 que você viu na tabela.
- TENURE tem uma barra gigantesca em 12 com um leve decaimento, isso mostra que a maioria dos clientes tem 12 meses

Análise Visual com Dois Atributos





NUNCA PAGA A FATURA INTEIRA

Justificativa e crítica

- Testamos 12 combinações por densidade KDE para escolher o melhor par. Priorizamos **PRC_FULL_PAYMENT × CREDIT_LIMIT** por dois motivos: é o par mais interpretável de negócio — perfil de pagamento contra porte do cliente. Evitamos pares de variáveis redundantes, que mostrariam padrões artificiais. Mesmo escolhendo o melhor par, não há separação visual de grupos — o que comprova que dois atributos são insuficientes e justifica a clusterização multivariada das próximas questões

Seleção de Variáveis — Correlação de Spearman



Pares com |correlação| ≥ 0,75

ρ	Variável A	Variável B
0,98	CASH_ADVANCE_FREQUENCY	CASH_ADVANCE_TRX
0,95	ONEOFF_PURCHASES	ONEOFF_PURCHASES_FREQ
0,95	CASH_ADVANCE	CASH_ADVANCE_TRX
0,94	CASH_ADVANCE	CASH_ADVANCE_FREQUENCY
0,92	PURCHASES_FREQUENCY	PURCHASES_TRX
0,92	INSTALLMENTS_PURCHASES	PURCHASES_INSTALL_FREQ
0,89	PURCHASES	PURCHASES_TRX
0,87	BALANCE	MINIMUM_PAYMENTS
0,85	PURCHASES_FREQUENCY	PURCHASES_INSTALL_FREQ
0,80	PURCHASES	PURCHASES_FREQUENCY
0,79	INSTALLMENTS_PURCHASES	PURCHASES_FREQUENCY
0,78	INSTALLMENTS_PURCHASES	PURCHASES_TRX
0,78	PURCHASES_INSTALL_FREQ	PURCHASES_TRX
0,75	PURCHASES	ONEOFF_PURCHASES

Variáveis Removidas (Redundantes)



8 variáveis removidas — uma de cada par redundante, pela regra de negócio e menor perda de informação

Removida	Justificativa
CASH_ADVANCE_TRX	Contagem bruta $\approx$ CASH_ADVANCE_FREQUENCY (ρ 0,98)
CASH_ADVANCE_FREQUENCY	Substituída por CASH_ADVANCE (montante, mais informativo p/ risco)
MINIMUM_PAYMENTS	Derivada $\rightarrow$ substituída por BALANCE (ρ 0,87)
PURCHASES_TRX	Contagem bruta $\rightarrow$ substituída por PURCHASES
ONEOFF_PURCHASES	Subcomponente $\rightarrow$ capturado por PURCHASES
PURCHASES_FREQUENCY	Frequência $\rightarrow$ optou-se pelo montante PURCHASES
INSTALLMENTS_PURCHASES	Subcomponente $\rightarrow$ capturado por PURCHASES
PURCHASES_INSTALLMENTS_FREQUENCY	Frequência de parcelamento $\rightarrow$ removida em cascata



Resultado

- De 17 $\rightarrow$ 9 atributos para a clusterização.
- Spearman é adequada: dados com outliers e assimetria seguem relação monotônica, não linear.
- Critério do par: manter a variável mais informativa para o negócio.

K-Means sem normalização



Clusters e Tabela Cruzada (K = 3)




Interpretação

- Sem variável-alvo, a crosstab usa `CREDIT_LIMIT` discretizado pela regra de Sturges (15 bins).
- Os clusters separam faixas de limite/saldo, mas com sobreposição — correspondência apenas parcial.
- Indica a necessidade de testar normalização e outros algoritmos.

K-Means com normalização


Elbow Method (Inertia)

Pre-processamento



Silhouette Score


Pre-processamento




Valores para K selecionados

- StandarScaler - 7
- RobustScaler - 6
- MinMaxScaler - 6
- Log1p - 3

K-Means com normalização



K-Means com normalização



Conceito e Definição de Parâmetros


K-Means vs DBSCAN

Aspecto	K-Means	DBSCAN
Base	Centroides / distância	Densidade
Nº de clusters	Fixado (K)	Automático
Ruído	Não identifica	Marca outliers (-1)
Formato	Tende a esférico	Formas arbitrárias
Escala	Muito sensível	Muito sensível (via eps)



Parâmetros do DBSCAN

- `min_samples = 18` ($\approx 2 \times n^\circ$ de dimensões = 9).
- `eps` definido pelo cotovelo da curva de k-distância (distância ao 18º vizinho), no ponto antes da subida mais íngreme.

Gráfico de k-distância — dados sem normalização




DBSCAN sem Normalização



Diagnóstico

- **DBSCAN** ($\text{eps} \approx 2.451,6 \cdot \text{min_samples} = 18$): apenas 1 cluster + 5,84% de pontos como ruído (silhouette indefinido).
- Sem escala, as distâncias são dominadas pelas variáveis de maior magnitude e o algoritmo não separa grupos.
- **K-Means** ($K=3$) produz partição utilizável; o **DBSCAN** cru colapsa em um único grupo.

DBSCAN com normalização




Resultado do DBSCAN por normalização

Norm.	eps	min_s	clusters	ruído %	silhouette
StandardScaler	1,475	18	1	5,05%	—
RobustScaler	2,126	18	1	5,43%	—
MinMaxScaler	0,182	18	3	8,40%	0,115
Log1p	1,040	18	4	11,01%	0,568

A normalização ajudou?


- Sim, mas depende da escala.
- Standard e Robust ainda colapsam em 1 cluster.
- MinMax forma 3 grupos, porém com silhouette fraco (0,115).
- Log1p é a melhor: 4 clusters e silhouette 0,568.

DBSCAN — Clusters por Normalização




Clusterização Hierárquica — 4 Métodos de Ligação (50 últimos nós)


Dendrograma — single (últimas 40 uniões)




Dendrograma — average (últimas 40 uniões)



Dendrograma — ward (últimas 40 uniões)



Dendrograma — complete (últimas 40 uniões)




Escolha do Corte e do Alvo Supervisionado

Cortes (maior gap vertical)


Ligação	Altura do corte
single	15
average	35
ward	200
complete	40

Alvo escolhido

- ward (corte 200) → 4 grupos, usado como alvo dos modelos supervisionados.
- Escala RobustScaler antes das ligações.




Redução de Dimensionalidade — Variância Explicada



	Componente	Variancia_Explicada	Variancia_Acumulada
0	PC1	0.299873	0.299873
1	PC2	0.224638	0.524511
2	PC3	0.176359	0.700870
3	PC4	0.126221	0.827091
4	PC5	0.071638	0.898728
5	PC6	0.039178	0.937906
6	PC7	0.027391	0.965297
7	PC8	0.024581	0.989878
8	PC9	0.010122	1.000000

Visualização dos Clusters no Espaço PCA



Classificação supervisionada (KNN e Árvore de Decisão)


Montagem

- Alvo: 4 clusters do hierárquico ward.
- Treino/teste: 80/20 estratificado (1.790 amostras no teste).
- Features: todas as colunas × Top 4 PCA.
- Normalizações testadas: StandardScaler, MinMaxScaler e Log1p.
- PCA ajustado (4 componentes) sempre dentro do conjunto de treino.

Acurácia do KNN (todas as combinações)


	normalizacao	features	n_neighbors	accuracy	precision	recall	f1
0	StandardScaler	Todas as colunas	3	0.984916	0.984882	0.984916	0.984874
1	StandardScaler	Top 4 PCA	8	0.951955	0.951522	0.951955	0.950891
2	MinMaxScaler	Todas as colunas	7	0.956983	0.956416	0.956983	0.954190
3	MinMaxScaler	Top 4 PCA	4	0.931285	0.927421	0.931285	0.921285
4	Log1p	Todas as colunas	3	0.894972	0.893057	0.894972	0.893615
5	Log1p	Top 4 PCA	20	0.851397	0.853684	0.851397	0.848773

KNN — Matrices de Confusão (todas as combinações)




Árvore de Decisão — Desempenho

Árvore de Decisão - Matriz de Confusão (Todas as colunas)



Árvore de Decisão - Matriz de Confusão (Top 4 PCA)



	features	accuracy	precision	recall	f1
0	Todas as colunas	0.962570	0.963703	0.962570	0.962939
1	Top 4 PCA	0.931285	0.930995	0.931285	0.930966

PCA × Classificação — Veredito Final

Comparação final (F1)

- **KNN — todas: 0,941 · Top 5 PCA: 0,903** (médias entre normalizações).
- **Árvore — todas: 0,963 · Top 5 PCA: 0,950.**
- **Em ambos os modelos, o PCA (Top 5) reduziu um pouco o desempenho frente a usar todas as colunas.**
- **Melhor modelo único: KNN + StandardScaler (todas as colunas) — acurácia 0,983.**

Por que o PCA cai?

- **Top 5 PCA descarta variância útil para separar a classe minoritária (grupo 3, ~685 clientes).**
- **Trade-off: menos dimensões e leitura mais simples, com pequena perda de acurácia.**

Síntese por Etapa

Dados	8.950 clientes; forte assimetria e outliers → Spearman na seleção e escala robusta/log.
Seleção	De 17 para 9 atributos, removendo redundâncias ($ \rho \geq 0,75$) pela regra de negócio.
K-Means	K = 3 sem normalização; a normalização altera o K (6–7) e melhora a separação.
DBSCAN	Sem escala colapsa em 1 grupo; com Log1p forma 4 clusters (silhouette 0,57).
Hierárquica	ward (corte 200) → 4 grupos interpretáveis; usado como alvo supervisionado.
PCA	4 componentes $\approx 82,7\%$ da variância; grupos 0 e 3 bem definidos no espaço PCA.
Classificação	KNN + StandardScaler (todas) = 0,983 de acurácia; PCA reduz levemente o desempenho.

Obrigado!

Perguntas?

Kevin · Antônio · Ramon — AV3 Ciência de Dados · Universidade Federal do Ceará