


PROJETO DE CLASSIFICAÇÃO E REGRESSÃO - Adult Income & California Housing

Cecília Maria Lima da Silva
Disciplina: Inteligência Artificial




UNIVERSIDADE
FEDERAL DO CEARÁ




OBJETIVO

- Aplicar modelos de Machine Learning
 - Classificação (KNN)
 - Regressão (Linear, Ridge, Lasso)
 - Avaliar desempenho dos modelos
- 



CLASSIFICAÇÃO




CLASSIFICAÇÃO - DATASET

- Dataset: Adult Income
- 32.561 registros (aprox.)
- Variáveis: idade, educação, ocupação, renda
- Tipo: dados numéricos e categóricos
- Problema: classificação binária ($\leq 50K$ / $> 50K$)

CARACTERÍSTICAS DOS DADOS

- Dados categóricos predominantes
- Presença de valores ausentes ("?")
- Classes desbalanceadas
- Necessidade de transformação




PRÉ-PROCESSAMENTO

- Remoção de valores ausentes
 - One-Hot Encoding (variáveis categóricas)
 - Normalização (Log, MinMax, Z-score)
 - Preparação para KNN
- 


KNN E VALOR DE K

- K de 1 a 30
- Melhor entre 20–25
- Acurácia $\approx$ 85%




NORMALIZAÇÃO


- Log → melhor desempenho
- MinMax e Z-score próximos



MATRIZ DE CONFUSÃO

- Melhor na classe $\leq 50K$
- Mais erro na classe $> 50K$







CONCLUSÃO DE CLASSIFICAÇÃO

- Modelo KNN apresentou bom desempenho (~85%)
- Melhor resultado com valores intermediários de K
- Normalização influenciou diretamente os resultados
- Limitação na classe minoritária



REGRESSÃO





REGRESSÃO - DATASET

- Dataset: California Housing
- 20.640 registros
- Variáveis: renda, localização, população
- Tipo: dados numéricos e categóricos
- Problema: regressão (prever preço das casas)

PRÉ-PROCESSAMENTO

- Remoção de valores ausentes
- One-Hot Encoding
- Padronização (Z-score)





MODELOS UTILIZADOS



- Regressão Linear
 - Ridge (regularização L2)
 - Lasso (regularização L1)
- 

RESULTADOS

- $R^2 \approx 0.64$
- RMSE $\approx$ 69 mil
- MAE $\approx$ 50 mil
- Desempenho semelhante


ANÁLISE DOS RESULTADOS

- Relação linear predominante
- Sem overfitting relevante
- Regularização sem impacto




REGRESSÃO LINEAR SIMPLES

- Variável: median_income
- Relação positiva com preço




REAL VS PREDITO

- Boa tendência geral
- Dispersão nos valores altos




VALIDAÇÃO CRUZADA


- R^2 médio ≈ 0.64
- Resultados consistentes
- Baixa variação



BOXPLOT

- Distribuição semelhante
- Sem grandes variações







CONCLUSÃO DE REGRESSÃO

- Modelos com desempenho semelhante ($R^2 \approx 0.64$)
- Regressão linear já suficiente
- Regularização sem ganho significativo
- Limitações na previsão de valores altos



PRÓXIMOS PASSOS

- Testar algoritmos mais sofisticados (Random Forest, XGBoost, SVM).
 - Aplicar técnicas de balanceamento no dataset Adult Income.
 - Explorar engenharia de atributos.
 - Testar modelos não lineares para regressão.
 - Construir dashboards ou visualizações interativas.
- 



OBRIGADA PELA ATENÇÃO!

