

TECHNICAL REPORT

Aluno: Cecília Maria Lima da Silva

1. Introdução

Neste projeto foi utilizado o dataset **California Housing**, cujo objetivo é prever o valor médio das casas (*median_house_value*) com base em variáveis socioeconômicas e geográficas, como renda média da população, localização, número de quartos, população e idade das construções.

O problema abordado caracteriza-se como uma tarefa de **regressão supervisionada**, na qual a variável-alvo é numérica e contínua.

O objetivo principal do trabalho foi construir e comparar diferentes modelos de regressão, sendo eles:

- Regressão Linear
- Ridge Regression
- Lasso Regression

Além disso, foram aplicadas técnicas de:

- pré-processamento e tratamento de dados
- normalização
- validação cruzada
- otimização de hiperparâmetros com Grid Search

Por fim, os modelos foram avaliados utilizando métricas como **MAE, MSE, RMSE e R^2** , permitindo uma análise detalhada do desempenho.

2. Observações

Durante a análise inicial do dataset, foi identificado que a variável *total_bedrooms* apresentava valores ausentes. Esses registros foram removidos com o uso da função *dropna()*.

Além disso, a variável categórica *ocean_proximity* foi transformada em formato numérico utilizando One-Hot Encoding, garantindo compatibilidade com os modelos de regressão.

Outro ponto importante foi a aplicação da padronização dos dados (Z-score), uma vez que modelos como Ridge e Lasso são sensíveis à escala dos atributos.

3. Resultados e discussão

3.1 Exploração Inicial do Dataset

A exploração inicial foi realizada utilizando funções como head(), info() e describe().

O dataset apresenta:

- 20640 registros
- 10 variáveis
- maioria dos atributos numéricos contínuos

A variável-alvo (median_house_value) apresenta grande variabilidade, o que justifica a necessidade de modelos robustos.

3.2 Tratamento de Dados (versão resumida e formal)

A etapa de tratamento de dados teve como objetivo garantir a qualidade e consistência do dataset. Inicialmente, foi identificada a presença de valores ausentes na variável total_bedrooms, os quais foram removidos utilizando a função dropna(), evitando problemas no treinamento dos modelos.

Em seguida, a variável categórica ocean_proximity foi convertida em formato numérico por meio da técnica de One-Hot Encoding, permitindo sua utilização nos modelos de regressão.

Posteriormente, realizou-se a separação entre variáveis de entrada e variável-alvo (median_house_value), estruturando o problema de forma adequada para aprendizagem supervisionada.

Por fim, aplicou-se a padronização dos dados (Z-score), etapa essencial para garantir que todas as variáveis contribuam de forma equilibrada no modelo, especialmente nos métodos que utilizam regularização, como Ridge e Lasso.

3.3 Análise de Correlação e Relevância dos Atributos




Figura 1 – Heatmap de correlação entre os atributos do dataset.

A matriz de correlação foi utilizada para identificar relações lineares entre as variáveis.

Observou-se que a variável **median_income** apresenta a maior correlação com a variável-alvo (**median_house_value**), destacando-se como o principal fator explicativo do modelo. Esse resultado é consistente com a realidade, uma vez que regiões com maior renda tendem a possuir imóveis mais valorizados.

Outras variáveis, como localização (latitude e longitude) e densidade populacional, apresentam correlação moderada, indicando que também contribuem para a explicação do preço dos imóveis.

A identificação dessas relações foi essencial para compreender o comportamento dos dados e justificar a escolha de atributos na regressão simples.

3.4 Separação dos Dados

Após o pré-processamento, os dados foram divididos em conjuntos de treino (80%) e teste (20%), utilizando a função `train_test_split()`.

Essa divisão permite avaliar o desempenho dos modelos em dados não utilizados durante o treinamento, garantindo uma estimativa mais realista da capacidade de generalização.

Além disso, a definição de um `random_state` fixo assegura a reprodutibilidade dos experimentos.

3.5 Treinamento e Avaliação dos Modelos

Foram treinados três modelos de regressão: **Linear**, **Ridge** e **Lasso**, sendo avaliados com as métricas MAE, MSE, RMSE e R^2 .

Os resultados obtidos foram:

- $R^2 \approx 0.64$ para todos os modelos
- RMSE ≈ 69 mil
- MAE ≈ 50 mil

Análise crítica:

Os três modelos apresentaram desempenho praticamente idêntico, indicando que:

- a relação entre as variáveis é predominantemente linear
- não há forte presença de overfitting
- a regularização (Ridge e Lasso) não trouxe ganhos significativos

Esse comportamento sugere que o modelo linear já é suficiente para capturar os padrões principais do dataset.

3.6 Regressão Linear Simples




Figura 2 – Regressão linear simples utilizando o atributo `median_income`.

A regressão linear simples foi aplicada utilizando a variável **`median_income`**, selecionada com base na análise de correlação.

Observa-se uma relação linear positiva entre renda média e valor das casas, indicando que regiões com maior renda tendem a apresentar imóveis mais valorizados.

Entretanto, também é possível perceber dispersão significativa dos pontos em torno da reta, o que indica que outros fatores também influenciam o valor dos imóveis.

3.7 Análise de Valores Reais vs Preditos




Figura 3 – Comparação entre valores reais e preditos.

O gráfico de dispersão entre os valores reais e os valores preditos demonstra que o modelo consegue capturar a tendência geral dos dados, evidenciado pela concentração dos pontos próximos à linha de referência (reta ideal).

Entretanto, observa-se uma dispersão considerável dos pontos ao redor dessa linha, indicando a presença de erros nas previsões. Essa dispersão se torna mais evidente para valores mais elevados, sugerindo que o modelo apresenta maior dificuldade em estimar corretamente imóveis de maior valor.

Além disso, nota-se um limite superior nos valores reais (em torno de 500.000), o que gera uma concentração vertical de pontos, indicando uma possível limitação do próprio dataset. Esse comportamento pode impactar a capacidade do modelo de aprender padrões mais complexos.

De forma geral, o gráfico evidencia que o modelo possui boa capacidade de capturar a tendência linear, porém apresenta limitações na precisão das previsões.

3.8 Boxplot da Validação Cruzada




Figura 4 – Boxplot dos resultados da validação cruzada.

O boxplot apresenta a distribuição dos valores de R^2 obtidos durante a validação cruzada para os modelos Linear, Ridge e Lasso.

Observa-se que os três modelos apresentam distribuições praticamente idênticas, com valores centrais próximos de 0.64, o que indica consistência nos resultados.

Além disso:

- não há presença significativa de outliers
- a variação entre os folds é relativamente pequena
- os intervalos interquartis são semelhantes

Esses fatores indicam que os modelos possuem boa estabilidade e capacidade de generalização, reforçando que o desempenho observado não depende de uma divisão específica dos dados.

3.9 Análise dos Resultados dos Modelos

Os três modelos avaliados apresentaram desempenho praticamente equivalente:

- $R^2 \approx 0.6488$
- $RMSE \approx 69.297$
- $MAE \approx 50.413$

Essa similaridade indica que a regularização aplicada nos modelos Ridge e Lasso não trouxe ganhos significativos em relação à regressão linear simples.

4. Conclusões

Os modelos de regressão avaliados apresentaram desempenho consistente, com coeficiente de determinação (R^2) aproximado de 0.64, indicando que são capazes de explicar uma parcela significativa da variabilidade dos dados, embora ainda existam limitações na precisão das previsões.

A comparação entre Regressão Linear, Ridge e Lasso mostrou resultados praticamente idênticos, evidenciando que a aplicação de regularização não trouxe ganhos relevantes de desempenho. Esse comportamento sugere que o problema possui predominância de relações lineares e não apresenta sinais significativos de overfitting.

A análise gráfica, especialmente por meio do gráfico de valores reais versus preditos, confirmou que o modelo consegue capturar a tendência geral dos dados, porém com dispersão considerável, principalmente em valores mais elevados. Isso indica que, apesar da boa capacidade de generalização, o modelo apresenta dificuldades em representar completamente a complexidade do problema.

Além disso, a estabilidade observada na validação cruzada reforça a confiabilidade dos resultados, demonstrando que o desempenho dos modelos não depende de uma divisão específica dos dados.

De forma geral, conclui-se que os modelos lineares são adequados para capturar o comportamento global do dataset, porém apresentam limitações na modelagem de padrões mais complexos, indicando a necessidade de abordagens mais avançadas para melhoria da performance preditiva.

Os resultados sugerem que a modelagem linear é adequada para capturar tendências globais, porém insuficiente para representar relações não lineares complexas presentes nos dados.



5. Próximos passos

Como continuidade do projeto, recomenda-se a aplicação de modelos mais sofisticados, como Random Forest, Gradient Boosting e Redes Neurais, com o objetivo de capturar relações não lineares presentes nos dados e, consequentemente, melhorar a precisão das previsões.

Além disso, torna-se relevante a realização de engenharia de atributos, explorando combinações e transformações das variáveis existentes, o que pode contribuir para uma representação mais rica dos dados e melhor desempenho dos modelos.

Outro ponto importante consiste na análise de possíveis limitações do dataset, como a presença de valores extremos e o limite superior imposto ao valor das casas, fatores que podem impactar diretamente a capacidade preditiva dos modelos.

Por fim, sugere-se aprofundar a etapa de otimização de hiperparâmetros e explorar diferentes abordagens de validação, visando obter modelos mais robustos e com maior capacidade de generalização.