

Relatório AV3

Alunos: Abimael Gomes Mesquita Filho 583351 & Kauê Cruz Gomes

Disciplina: Inteligência Artificial

Trabalho: Aprendizado Não Supervisionado – Online Retail

1. Introdução

O presente trabalho teve como objetivo aplicar técnicas de aprendizado não supervisionado utilizando o dataset Online Retail, disponibilizado pela UCI Machine Learning Repository. Trata-se de uma base transacional contendo registros de compras realizadas por clientes de uma empresa de comércio eletrônico.

Como o objetivo principal era realizar análises de agrupamento, os dados foram reorganizados em uma estrutura centrada no cliente. Cada cliente passou a ser representado por atributos agregados que descrevem seu comportamento de compra.

Após o pré-processamento, foram utilizados os seguintes atributos:

- recency_days
- frequency
- total_quantity
- monetary
- avg_unit_price
- num_products
- avg_basket_value

Esses atributos representam características relevantes do comportamento dos consumidores e permitem identificar padrões naturais de agrupamento.

2. Observações

Durante a análise foram encontrados alguns problemas no dataset:

- Clientes sem identificação (CustomerID ausente);
- Notas fiscais canceladas;
- Quantidades menores ou iguais a zero;
- Preços unitários menores ou iguais a zero.

Esses registros foram removidos antes das etapas de clusterização para evitar distorções nos resultados.

Além disso, observou-se forte assimetria em variáveis financeiras, especialmente:

- monetary;
- frequency;
- total_quantity.

Por esse motivo foram avaliadas técnicas de transformação logarítmica e normalização ao longo do trabalho.

3. Resultados e Discussão

Questão 1 – Análise Exploratória dos Dados

Inicialmente foi realizada uma análise exploratória para compreender a estrutura dos dados.

Processamento realizado

Fluxo da etapa:

Dataset Original → Limpeza → Agregação por Cliente → Estatísticas → Visualizações

Foram produzidos:

- Estatísticas descritivas;
- Histogramas;
- Boxplots;
- Matriz de correlação.

A análise mostrou forte concentração de clientes com baixos valores de compra e poucos clientes com valores extremamente elevados, caracterizando a presença de outliers.

Os atributos considerados mais relevantes para agrupamento foram:

- recency_days;
- frequency;
- monetary;
- total_quantity;
- num_products.

Essas variáveis representam frequência de compra, valor gasto e engajamento do cliente.

Questão 2 – Análise Visual com Dois Atributos

Foram selecionados:

- recency_days
- monetary

A escolha foi baseada no modelo RFM, amplamente utilizado em segmentação de clientes.

Foi construído um gráfico de dispersão utilizando esses atributos e colorindo os pontos de acordo com a variável categórica de referência.

Resultados

Visualmente foi possível observar regiões distintas de clientes:

- Clientes recentes e com alto gasto;
- Clientes recentes com baixo gasto;
- Clientes antigos com diferentes níveis de gasto.

Entretanto, verificou-se grande sobreposição entre os grupos.

Conclusão

Os dois atributos fornecem uma visão inicial importante, mas não são suficientes para representar toda a estrutura dos dados. Dessa forma, tornou-se necessária a utilização de múltiplos atributos nas etapas posteriores.

Questão 3 – Clusterização com K-Means

Para a clusterização foram utilizados os sete atributos comportamentais definidos anteriormente.

Pré-processamento

Foi aplicada:

- Transformação logarítmica ($\log_{10}$);
- Padronização utilizando StandardScaler.

Esse procedimento foi necessário devido à grande diferença de escala entre as variáveis.

Escolha do Melhor K

Foram avaliados valores de K entre 2 e 10.

Os critérios utilizados foram:

- Método do Cotovelo;
- Silhouette Score.

Resultados

Melhor valor encontrado:

- $K = 2$
- Silhouette Score = 0,3187

Após a escolha do valor ótimo de K , foi executado novamente o algoritmo K-Means.

Foram geradas:

- Visualização 2D dos clusters;
- Visualização via PCA;
- Crosstab entre clusters e variável de referência.

Discussão

Os agrupamentos encontrados refletem principalmente padrões de comportamento de compra dos clientes.

Embora exista alguma relação com os países dos consumidores, os clusters parecem estar mais associados à frequência, valor gasto e diversidade de produtos adquiridos.

Questão 4 – Comparação entre K-Means e DBSCAN

Nesta etapa foi realizada uma comparação entre dois algoritmos de clusterização.

K-Means

Características:

- Necessita definição prévia de K ;
- Baseado em distância;
- Não identifica ruídos.

DBSCAN

Características:

- Baseado em densidade;
- Não exige informar K ;
- Identifica ruídos automaticamente.

Parâmetros Utilizados

- $\text{eps} = 1,5589$
- $\text{min_samples} = 14$

Os parâmetros foram definidos utilizando o gráfico k-distance.

Resultados

K-Means:

- 2 clusters

DBSCAN:

- 1 cluster
- 97 pontos classificados como ruído

Discussão

O DBSCAN conseguiu identificar observações atípicas, porém encontrou apenas um agrupamento principal.

Já o K-Means produziu uma segmentação mais interpretável para o contexto de análise de clientes.

Conclusão

O algoritmo K-Means apresentou desempenho mais adequado para este dataset, fornecendo agrupamentos mais úteis para segmentação de consumidores.

Questão 5 – Impacto da Normalização

Foram comparadas três abordagens:

1. Sem normalização;
2. Log1p + StandardScaler;
3. Log1p + MinMaxScaler.

Resultados

Melhor configuração:

- Sem normalização
- K = 2
- Silhouette Score = 0,9829

Discussão

Apesar do elevado Silhouette Score sem normalização, esse resultado deve ser interpretado com cautela.

A ausência de normalização faz com que variáveis de maior magnitude, como monetary e total_quantity, dominem o cálculo das distâncias.

Por outro lado, a normalização permite uma participação mais equilibrada de todos os atributos.

Conclusão

O maior Silhouette Score foi observado sem normalização (0,9829). Entretanto, esse resultado indica que variáveis de maior magnitude exercem forte influência no cálculo das distâncias. Os cenários normalizados apresentaram valores menores de Silhouette, mas produziram agrupamentos mais equilibrados ao considerar simultaneamente todos os atributos. Dessa forma, a normalização continua sendo uma prática recomendada para análise de comportamento dos clientes.

Questão 6 – Clusterização Hierárquica

Foi realizada clusterização hierárquica utilizando:

- Single Linkage;
- Complete Linkage;
- Average Linkage.

Também foi aplicada transformação logarítmica e normalização.

Resultados

Melhor método:

- Single Linkage

Silhouette Score:

- 0,7204

Os dendrogramas sugeriram aproximadamente:

- 2 clusters

Discussão

O número de grupos sugerido pelos dendrogramas coincidiu com o valor encontrado pelo K-Means.

Esse resultado fornece evidências adicionais de que a estrutura natural dos dados pode ser representada por dois agrupamentos principais.

Conclusão

A análise hierárquica confirmou os resultados obtidos anteriormente e serviu como validação visual da clusterização.

Questão 7 – PCA e Classificação Supervisionada

Nesta etapa foi avaliado o impacto da redução de dimensionalidade utilizando PCA.

Pré-processamento

Foram aplicados:

- Transformação logarítmica;
- StandardScaler.

PCA

A base original possuía:

- 7 atributos

Após o PCA:

- 5 componentes principais

Variância preservada:

- 99,40%

Classificação

Foi utilizado o algoritmo:

- KNN

Comparação:

Sem PCA

Acurácia:

- 0,8971

Com PCA

Acurácia:

- 0,8963

Diferença:

- -0,0008

Discussão

A redução dimensional praticamente não afetou o desempenho do classificador.

Isso indica que os componentes principais preservaram quase toda a informação relevante presente nos atributos originais.

Conclusão

O PCA mostrou-se eficiente, reduzindo a dimensionalidade dos dados sem perda significativa de desempenho.

4. Conclusões

Os objetivos propostos pela atividade foram alcançados.

A análise exploratória permitiu compreender a estrutura dos dados e identificar problemas que precisavam ser tratados antes da clusterização.

O algoritmo K-Means apresentou o melhor desempenho geral para segmentação dos clientes, identificando dois agrupamentos principais.

O DBSCAN mostrou-se útil para identificação de ruídos, mas apresentou menor capacidade de segmentação neste conjunto de dados.

A clusterização hierárquica confirmou a existência de aproximadamente dois grupos naturais.

Por fim, o PCA reduziu a dimensionalidade mantendo 99,40% da variância e praticamente sem alterar o desempenho do classificador KNN.

5. Próximos Passos

Como continuidade deste trabalho, recomenda-se:

- Testar outros algoritmos de clusterização, como Gaussian Mixture Models;
- Investigar técnicas avançadas de detecção de anomalias;
- Aplicar métodos de seleção de atributos;
- Utilizar UMAP e t-SNE para visualizações mais avançadas;

- Construir um sistema real de segmentação de clientes para campanhas de marketing;
- Comparar diferentes classificadores supervisionados após o PCA, como Random Forest e SVM.

Essas etapas podem fornecer uma compreensão ainda mais detalhada do comportamento dos consumidores e melhorar a qualidade dos agrupamentos encontrados.